

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG ĐIỆN – ĐIỆN TỬ

ĐỒ ÁN TỐT NGHIỆP

Hệ thống phát hiện trạng thái buồn ngủ thời gian thực sử dụng tín hiệu PPG

NGUYỄN DUY HUY

`huy.nd210442@sis.hust.edu.vn`

Ngành Kỹ thuật Điện tử - Viễn thông

Chuyên ngành Kỹ thuật Điện tử - Kỹ thuật máy tính

Giảng viên hướng dẫn:

PGS. TS. Hoàng Mạnh Thắng

KHOA:

Điện tử

HÀ NỘI, 6/2025

ĐỀ TÀI TỐT NGHIỆP

“Hệ thống phát hiện trạng thái buồn ngủ thời gian thực sử dụng tín hiệu PPG”.

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG ĐIỆN – ĐIỆN TỬ

ĐÁNH GIÁ ĐỒ ÁN TỐT NGHIỆP
(DÀNH CHO CÁN BỘ HƯỚNG DẪN)

Tên đề tài: HỆ THỐNG PHÁT HIỆN TRẠNG THÁI BUỒN NGỦ THỜI GIAN THỰC SỬ
DỤNG TÍN HIỆU PPG

Họ tên SV: NGUYỄN DUY HUY

MSSV: 20210442

Cán bộ hướng dẫn: PGS. TS. HOÀNG MẠNH THẮNG

STT	Tiêu chí (Điểm tối đa)	Hướng dẫn đánh giá tiêu chí	Điểm tiêu chí
1	Thái độ làm việc (2,5 điểm)	Nghiêm túc, tích cực và chủ động trong quá trình làm ĐATN	
		Hoàn thành đầy đủ và đúng tiến độ các nội dung được GVHD giao	
2	Kỹ năng viết quyển ĐATN (2 điểm)	Trình bày đúng mẫu quy định, bố cục các chương logic và hợp lý: Bảng biểu, hình ảnh rõ ràng, có tiêu đề, được đánh số thứ tự và được giải thích hay đề cập đến trong đồ án, có căn lề, dấu cách sau dấu chấm, dấu phẩy, có mở đầu chương và kết luận chương, có liệt kê tài liệu tham khảo và có trích dẫn, v.v.	
		Kỹ năng diễn đạt, phân tích, giải thích, lập luận: Cấu trúc câu rõ ràng, văn phong khoa học, lập luận logic và có cơ sở, thuật ngữ chuyên ngành phù hợp, v.v.	
3	Nội dung và kết quả đạt được (5 điểm)	Nêu rõ tính cấp thiết, ý nghĩa khoa học và thực tiễn của đề tài, các vấn đề và các giả thuyết, phạm vi ứng dụng của đề tài. Thực hiện đầy đủ quy trình nghiên cứu: Đặt vấn đề, mục tiêu đề ra, phương pháp nghiên cứu/ giải quyết vấn đề, kết quả đạt được, đánh giá và kết luận.	
		Nội dung và kết quả được trình bày một cách logic và hợp lý, được phân tích và đánh giá thỏa đáng. Biện luận phân tích kết quả mô phỏng/ phần mềm/ thực nghiệm, so sánh kết quả đạt được với kết quả trước đó có liên quan.	
		Chỉ rõ phù hợp giữa kết quả đạt được và mục tiêu ban đầu đề ra đồng thời cung cấp lập luận đề đề xuất hướng giải quyết có thể thực hiện trong tương lai. Hàm lượng khoa học/ độ phức tạp cao, có tính mới/tính sáng tạo trong nội dung và kết quả đồ án.	
4	Điểm thành tích (1 điểm)	Có bài báo KH được đăng hoặc chấp nhận đăng/ đạt giải SV NCKH giải 3 cấp Trường trở lên/ Các giải thưởng khoa học trong nước, quốc tế từ giải 3 trở lên/ Có đăng ký bằng phát minh sáng chế. (1 điểm)	
		Được báo cáo tại hội đồng cấp Trường trong hội nghị SV NCKH nhưng không đạt giải từ giải 3 trở lên/ Đạt giải khuyến khích trong cuộc thi khoa học trong nước, quốc tế/ Kết quả đồ án là sản phẩm ứng dụng có tính hoàn thiện cao, yêu cầu khối lượng thực hiện lớn. (0,5 điểm)	
		Điểm tổng các tiêu chí:	
		Điểm hướng dẫn:	

Cán bộ hướng dẫn
(Ký và ghi rõ họ tên)

Điểm từng tiêu chí cho lẻ đến 0,5. Nếu Điểm tổng các tiêu chí > 10 thì Điểm hướng dẫn làm tròn thành 10

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG ĐIỆN – ĐIỆN TỬ

ĐÁNH GIÁ ĐỒ ÁN TỐT NGHIỆP
(DÀNH CHO CÁN BỘ PHẢN BIỆN)

Tên đề tài: HỆ THỐNG PHÁT HIỆN TRẠNG THÁI BUỒN NGỦ THỜI GIAN THỰC SỬ
DỤNG TÍN HIỆU PPG

Họ tên SV: NGUYỄN DUY HUY

MSSV: 20210442

Cán bộ phản biện:

STT	Tiêu chí (Điểm tối đa)	Hướng dẫn đánh giá tiêu chí	Điểm tiêu chí
1	Trình bày quyển ĐATN (4 điểm)	Đồ án trình bày đúng mẫu quy định, bố cục các chương logic và hợp lý: Bảng biểu, hình ảnh rõ ràng, có tiêu đề, được đánh số thứ tự và được giải thích hay đề cập đến trong đồ án, có căn lề, dấu cách sau dấu chấm, dấu phẩy, có mở đầu chương và kết luận chương, có liệt kê tài liệu tham khảo và có trích dẫn, v.v. Kỹ năng diễn đạt, phân tích, giải thích, lập luận: cấu trúc câu rõ ràng, văn phong khoa học, lập luận logic và có cơ sở, thuật ngữ chuyên ngành phù hợp, v.v.	
2	Nội dung và kết quả đạt được (5,5 điểm)	Nêu rõ tính cấp thiết, ý nghĩa khoa học và thực tiễn của đề tài, các vấn đề và các giả thuyết, phạm vi ứng dụng của đề tài. Thực hiện đầy đủ quy trình nghiên cứu: Đặt vấn đề, mục tiêu đề ra, phương pháp nghiên cứu/ giải quyết vấn đề, kết quả đạt được, đánh giá và kết luận. Nội dung và kết quả được trình bày một cách logic và hợp lý, được phân tích và đánh giá thỏa đáng. Biện luận phân tích kết quả mô phỏng/ phần mềm/ thực nghiệm, so sánh kết quả đạt được với kết quả trước đó có liên quan. Chỉ rõ phù hợp giữa kết quả đạt được và mục tiêu ban đầu đề ra đồng thời cung cấp lập luận đề đề xuất hướng giải quyết có thể thực hiện trong tương lai. Hàm lượng khoa học/ độ phức tạp cao, có tính mới/ tính sáng tạo trong nội dung và kết quả đồ án.	
3	Điểm thành tích (1 điểm)	Có bài báo KH được đăng hoặc chấp nhận đăng/ đạt giải SV NCKH giải 3 cấp Trường trở lên/ các giải thưởng KH quốc tế/ trong nước từ giải 3 trở lên/ Có đăng ký bằng phát minh sáng chế. (1 điểm) Được báo cáo tại hội đồng cấp Trường trong hội nghị SV NCKH nhưng không đạt giải từ giải 3 trở lên/ Đạt giải khuyến khích trong các kỳ thi quốc gia và quốc tế khác về chuyên ngành. (0,5 điểm)	
Điểm tổng các tiêu chí:			
Điểm phản biện:			

Cán bộ phản biện
(Ký và ghi rõ họ tên)

Điểm từng tiêu chí cho lẻ đến 0,5. Nếu Điểm tổng các tiêu chí > 10 thì Điểm hướng dẫn làm tròn thành 10

Lời cảm ơn

Trước hết, em xin gửi lời cảm ơn trân trọng đến PGS. TS. Hoàng Mạnh Thắng, người đã trực tiếp hướng dẫn, tận tình chỉ bảo, góp ý chuyên môn và hỗ trợ em trong suốt quá trình thực hiện đề án tốt nghiệp này. Nhờ sự định hướng và động viên kịp thời của thầy, em đã có thể vượt qua nhiều khó khăn để hoàn thành đề tài.

Em cũng xin cảm ơn các thầy cô trong hội đồng bảo vệ, đã dành thời gian xem xét và đánh giá đề án của em.

Do thời gian thực hiện đề án có phần gấp rút và giới hạn, chắc chắn không thể tránh khỏi những thiếu sót. Em rất mong nhận được sự thông cảm và các ý kiến đóng góp quý báu từ quý thầy cô và mọi người để em có thể tiếp tục hoàn thiện hơn trong tương lai.

Một lần nữa, em xin chân thành cảm ơn!

Tóm tắt nội dung đồ án

Hiện nay, tình trạng buồn ngủ khi lái xe là nguyên nhân phổ biến gây tai nạn giao thông, đặc biệt trên các tuyến đường dài hoặc cao tốc. Việc phát hiện sớm trạng thái buồn ngủ là vấn đề cấp thiết nhằm nâng cao độ an toàn cho người lái và cộng đồng.

Đồ án tập trung xây dựng hệ thống dự đoán trạng thái buồn ngủ của người lái xe theo thời gian thực dựa trên tín hiệu PPG (Photoplethysmography). Tín hiệu PPG được thu thập từ cảm biến MAX30102 qua vi điều khiển ESP32, sau đó được xử lý để trích xuất các đặc trưng ở miền thời gian, tần số (wavelet), và phi tuyến. Các đặc trưng này được đưa vào mô hình học máy để dự đoán trạng thái tỉnh táo hoặc buồn ngủ.

Phần mềm được xây dựng bằng ngôn ngữ Python, bao gồm xử lý tín hiệu, huấn luyện mô hình và giao diện trực quan. Hệ thống hoạt động ổn định theo thời gian thực và cho kết quả dự đoán có độ chính xác cao, phù hợp với mục tiêu đề ra.

Đồ án có tính ứng dụng cao trong lĩnh vực lái xe an toàn, với tiềm năng mở rộng kết hợp thêm cảm biến EEG hoặc camera để tăng độ tin cậy. Đồ án đã giúp em rèn luyện kỹ năng lập trình, xử lý tín hiệu sinh học và ứng dụng học máy trong thực tế.

Sinh viên thực hiện

Ký và ghi rõ họ tên

MỤC LỤC

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI	1
1.1 Đặt vấn đề	1
1.2 Mục tiêu nghiên cứu	2
1.3 Phạm vi và giới hạn nghiên cứu	2
1.4 Phương pháp thực hiện	3
1.5 Ý nghĩa khoa học và thực tiễn	4
1.6 Các công trình nghiên cứu liên quan	4
1.6.1 Phương pháp dựa trên hành vi điều khiển phương tiện	4
1.6.2 Phương pháp dựa trên hình ảnh và video khuôn mặt.....	5
1.6.3 Phương pháp dựa trên tín hiệu sinh lý	6
1.7 Kết luận chương.....	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT.....	8
2.1 Tín hiệu PPG	8
2.1.1 Nguồn gốc sinh lý	8
2.1.2 Đặc điểm của tín hiệu PPG	8
2.1.3 Thu nhận tín hiệu.....	10
2.2 Xử lý tín hiệu PPG.....	11
2.2.1 Tiền xử lý tín hiệu	11
2.2.2 Phân đoạn tín hiệu theo cửa sổ trượt.....	12
2.2.3 Loại bỏ nhiễu và phát hiện bất thường.....	13
2.3 Các thang đo mức độ buồn ngủ	13
2.3.1 Thang đo mức độ buồn ngủ của Epworth	13
2.3.2 Thang đo mức độ buồn ngủ của Karolinska	14
2.3.3 Thang đo mức độ buồn ngủ của Stanford	15
2.4 Trích xuất đặc trưng từ tín hiệu PPG.....	16
2.4.1 Đặc trưng miền thời gian.....	16
2.4.2 Đặc trưng từ biến đổi Fourier.....	17
2.4.3 Đặc trưng từ biến đổi Wavelet	20
2.4.4 Đặc trưng phi tuyến trong không gian pha.....	22
2.5 Kết luận chương.....	26
CHƯƠNG 3. MÔ HÌNH HỌC MÁY	27
3.1 Tổng quan về học máy (Machine Learning)	27

3.1.1	Các loại mô hình học máy chính.....	27
3.1.2	Các bước chính trong quy trình học máy.....	27
3.2	Các mô hình học máy được sử dụng	30
3.2.1	K-Nearest Neighbors (KNN)	30
3.2.2	Support Vector Machines (SVM)	34
3.2.3	Random Forest (RF).....	38
3.3	Đánh giá hiệu suất mô hình	43
3.3.1	Phân chia dữ liệu	43
3.3.2	Các chỉ số đánh giá cho bài toán phân loại	44
3.3.3	Các chỉ số đánh giá cho bài toán hồi quy.....	45
3.3.4	Phương pháp kiểm định chéo (Cross-validation).....	45
3.4	Kết luận chương.....	46
	CHƯƠNG 4. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG.....	47
4.1	Phần cứng sử dụng.....	47
4.1.1	Cảm biến MAX30102	47
4.1.2	Vi điều khiển ESP32	48
4.1.3	Cáp USB – TTL / Cáp nạp ESP32	48
4.1.4	Máy tính xử lý dữ liệu.....	48
4.1.5	Kết nối phần cứng	49
4.2	Phần mềm sử dụng.....	49
4.2.1	PlatformIO – Môi trường phát triển cho ESP32	49
4.2.2	Python – Xử lý tín hiệu và học máy.....	50
4.3	Kiến trúc tổng thể của hệ thống.....	50
4.3.1	Giai đoạn huấn luyện mô hình	51
4.3.2	Giai đoạn kiểm tra	52
4.4	Kết luận chương.....	53
	CHƯƠNG 5. THỰC NGHIỆM VÀ KẾT QUẢ	54
5.1	Thu thập dữ liệu thực nghiệm.....	54
5.1.1	Thiết lập môi trường thử nghiệm	54
5.1.2	Đối tượng thử nghiệm	54
5.1.3	Quy trình thu thập và gán nhãn dữ liệu.....	54
5.1.4	Kết quả tiền xử lý dữ liệu.....	55
5.2	Kết quả trích xuất đặc trưng	55
5.2.1	Đặc trưng miền thời gian.....	55

5.2.2	Đặc trưng từ biến đổi Fourier.....	56
5.2.3	Đặc trưng từ biến đổi Wavelet	57
5.2.4	Đặc trưng phi tuyến.....	57
5.2.5	Đánh giá sự tương quan giữa các đặc trưng.....	58
5.3	Kết quả huấn luyện và đánh giá mô hình học máy.....	60
5.3.1	Thiết lập thử nghiệm huấn luyện.....	60
5.3.2	Kết quả đánh giá trên tập kiểm tra	60
5.4	Kết luận chương.....	72
	CHƯƠNG 6. KẾT LUẬN.....	73
6.1	Kết luận.....	73
6.2	Hướng phát triển của đề án trong tương lai.....	73
	TÀI LIỆU THAM KHẢO	76
	PHỤ LỤC	78
A1.	So sánh kết quả với các nghiên cứu trước.....	78
A2.	Giao diện người dùng hệ thống	80
A2.1	Công nghệ phát triển.....	80
A2.2	Các thành phần chính của giao diện	80
A2.3	Mã nguồn dự án	81
A.3	Kiểm tra thực nghiệm.....	82
A3.1	Điều kiện thực nghiệm dự đoán.....	82
A3.2	Kết quả thực nghiệm.....	82

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Từ viết tắt	Ý nghĩa	Ý nghĩa Tiếng Việt
CNNs	Convolutional Neural Networks	Mạng nơ-ron tích chập
DFT	Discrete Fourier Transform	Biến đổi Fourier rời rạc
DWT	Discrete Wavelet Transform	Biến đổi Wavelet rời rạc
ECG	Electrocardiogram	Điện tâm đồ
EEG	Electroencephalogram	Điện não đồ
EMG	Electromyogram	Điện cơ đồ
EOG	Electrooculogram	Điện nhãn đồ
ESS	Epworth Sleepiness Scale	Thang đo buồn ngủ Epworth
FIR	Finite Impulse Response	Bộ lọc đáp ứng xung hữu hạn
FFT	Fast Fourier Transform	Biến đổi Fourier nhanh
IIR	Infinite Impulse Response	Bộ lọc đáp ứng xung vô hạn
IQR	Interquartile Range	Khoảng tứ phân vị
KNN	K-Nearest Neighbors	Thuật toán K láng giềng gần nhất
KSS	Karolinska Sleepiness Scale	Thang đo buồn ngủ Karolinska
LSTM	Long Short-Term Memory	Bộ nhớ ngắn dài hạn
MOL	Mean Opinion Level	Mức đánh giá trung bình
PPG	Photoplethysmogram	Đồ thị quang trở
RF	Random Forest	Rừng ngẫu nhiên
RBF	Radial Basis Function	Hàm cơ sở hướng tâm
RNN	Recurrent Neural Network	Mạng nơ-ron hồi tiếp
SSS	Stanford Sleepiness Scale	Thang đo buồn ngủ Stanford
SVM	Support Vector Machine	Máy vector hỗ trợ
TCE	Time Complexity Estimation	Ước lượng độ phức tạp thời gian

DANH MỤC HÌNH VẼ

Hình 2.1 Nguồn gốc đơn giản hóa của tín hiệu PPG.	8
Hình 2.2 Sóng xung PPG điển hình.	9
Hình 2.3 Các lớp của hình dạng sóng xung PPG.	9
Hình 2.4 Các ví dụ về tín hiệu PPG sạch và nhiễu.	10
Hình 2.5 Hai loại cảm biến đo PPG chính.	10
Hình 2.6 Thuật toán phát hiện đỉnh và đáy.	16
Hình 2.7 Biến đổi tần số của tín hiệu PPG.	19
Hình 2.8 Quá trình phân rã của DWT.	21
Hình 2.9 Tổng quan tái tạo không gian pha.	22
Hình 2.10 Phân tích phi tuyến PPG trong không gian pha.	23
Hình 3.1 Quy trình triển khai thuật toán học máy.	30
Hình 3.2 Thuật toán K - Nearest Neighbors.	30
Hình 3.3 Thuật toán Support Vector Machines.	34
Hình 3.4 Chuyển đổi dữ liệu với SVM.	35
Hình 3.5 Thuật toán Random Forest.	38
Hình 4.1 Module MAX30102.	47
Hình 4.2 Vi điều khiển ESP32.	48
Hình 4.3 Sơ đồ kết nối phần cứng.	49
Hình 4.4 Kiến trúc giai đoạn huấn luyện.	51
Hình 4.5 Kiến trúc giai đoạn kiểm tra.	53
Hình 5.1 Tín hiệu PPG thô.	55
Hình 5.2 Tín hiệu PPG sau khi loại bỏ thành phần DC.	55
Hình 5.3 Tín hiệu PPG sau khi đi qua bộ lọc FIR.	55
Hình 5.4 Sự thay đổi của các đặc trưng miền thời gian ứng với nhãn KSS.	56
Hình 5.5 Sự thay đổi của các đặc trưng từ biến đổi Fourier nhãn KSS.	56
Hình 5.6 Sự thay đổi của Kurtosis từ các hệ số Wavelet ứng với nhãn KSS.	57
Hình 5.7 Sự thay đổi của các đặc trưng phi tuyến ứng với nhãn KSS.	57
Hình 5.8 Ma trận tương quan của các đặc trưng miền thời gian.	58
Hình 5.9 Ma trận tương quan của các đặc trưng từ biến đổi Fourier.	59
Hình 5.10 Ma trận tương quan của các đặc trưng từ biến đổi Wavelet.	59
Hình 5.11 Ma trận tương quan của các đặc trưng phi tuyến.	60
Hình 5.12 Độ chính xác của các mô hình theo từng miền đặc trưng.	65
Hình 5.13 Ma trận nhầm lẫn của RF với đặc trưng miền thời gian.	66
Hình 5.14 Ma trận nhầm lẫn của SVM với đặc trưng miền thời gian.	66
Hình 5.15 Ma trận nhầm lẫn của KNN với đặc trưng miền thời gian.	67
Hình 5.16 Ma trận nhầm lẫn của RF với đặc trưng từ biến đổi Fourier.	67

Hình 5.17 Ma trận nhầm lẫn của SVM với đặc trưng từ biến đổi Fourier.....	68
Hình 5.18 Ma trận nhầm lẫn của KNN với đặc trưng từ biến đổi Fourier.....	68
Hình 5.19 Ma trận nhầm lẫn của RF với đặc trưng từ biến đổi Wavelet.....	69
Hình 5.20 Ma trận nhầm lẫn của SVM với đặc trưng từ biến đổi Wavelet.....	69
Hình 5.21 Ma trận nhầm lẫn của KNN với đặc trưng từ biến đổi Wavelet.....	70
Hình 5.22 Ma trận nhầm lẫn của RF với đặc trưng phi tuyến.	70
Hình 5.23 Ma trận nhầm lẫn của SVM với đặc trưng phi tuyến.....	71
Hình 5.24 Ma trận nhầm lẫn của KNN với đặc trưng phi tuyến.....	71
Hình 0.1 Giao diện hiển thị tín hiệu PPG và trạng thái dự đoán.	80
Hình 0.2 Giao diện hiển thị giá trị các đặc trưng.....	81
Hình 0.3 Giao diện cảnh báo được gửi qua Telegram.	81
Hình 0.4 Ma trận nhầm lẫn kết quả dự đoán trong thực nghiệm.	83

DANH MỤC BẢNG BIỂU

Bảng 2.1 Thang đo mức độ buồn ngủ của Epworth.....	14
Bảng 2.2 Thang đo mức độ buồn ngủ của Karolinska.....	15
Bảng 2.3 Thang đo mức độ buồn ngủ của Stanford.....	15
Bảng 2.4 Đặc trưng miền thời gian.	16
Bảng 2.5 Đặc trưng từ biến đổi Fourier.	19
Bảng 2.6 Đặc trưng từ biến đổi Wavelet.....	21
Bảng 2.7 Đặc trưng phi tuyến.	23
Bảng 2.8 Thuật toán False Nearest Neighbors.....	24
Bảng 2.9 Thuật toán Detrended Fluctuation Analysis.	26
Bảng 3.1 Ví dụ đơn giản thuật toán KNN.....	32
Bảng 3.2 Ví dụ thuật toán Random Forest.....	41
Bảng 5.1 Hiệu suất của các thuật toán với đặc trưng miền thời gian.	61
Bảng 5.2 Hiệu suất của các thuật toán với đặc trưng từ biến đổi Fourier.....	62
Bảng 5.3 Hiệu suất của các thuật toán với đặc trưng từ biến đổi Wavelet.	63
Bảng 5.4 Hiệu suất của các thuật toán với đặc trưng phi tuyến.....	64
Bảng 0.1 So sánh hiệu suất dự đoán buồn ngủ với các nghiên cứu trước.	79

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI

Chương 1 trình bày tổng quan về vấn đề buồn ngủ khi lái xe và sự cần thiết của việc phát hiện sớm nhằm đảm bảo an toàn giao thông. Chương cũng trình bày mục tiêu, phạm vi nghiên cứu, phương pháp thực hiện và ý nghĩa của nghiên cứu.

1.1 Đặt vấn đề

Buồn ngủ khi lái xe là một vấn đề nghiêm trọng về an toàn giao thông đường bộ, góp phần gây ra một số lượng lớn các vụ tai nạn dẫn đến thương tích và tử vong hàng năm. Theo thống kê của Bộ Công an, trong năm 2023 Việt Nam có tới 72 vụ tai nạn giao thông do tài xế buồn ngủ. Theo Cục Quản lý An toàn Giao thông Đường cao tốc Quốc gia Hoa Kỳ (NHTSA), ước tính có gần 100.000 vụ tai nạn và hơn 1.500 ca tử vong mỗi năm. Nghiên cứu của Quỹ An toàn Giao thông AAA (AAAFTS) chỉ ra rằng hơn 40% tài xế đã thừa nhận đã ngủ quên khi lái xe. Một môi trường làm suy giảm nghiêm trọng khả năng lái xe bằng cách làm chậm thời gian phản ứng, giảm khả năng tập trung và làm suy yếu khả năng ra quyết định. Đáng chú ý, lái xe sau hơn 24 giờ không ngủ có thể gây suy giảm tương đương với việc lái xe có nồng độ cồn trong máu ở mức giới hạn hợp pháp. Các cơn ngủ ngắn (microsleeps) không kiểm soát là mối nguy hiểm nghiêm trọng vì chúng có thể xảy ra mà không có cảnh báo và dẫn đến mất kiểm soát phương tiện.

Các nghiên cứu đã chỉ ra rằng buồn ngủ thường xảy ra vào các thời điểm mà cơ thể có xu hướng nghỉ ngơi tự nhiên, đặc biệt là từ nửa đêm đến 6 giờ sáng, sau bữa trưa và vào cuối buổi chiều. Các nhóm có nguy cơ cao bao gồm người trẻ tuổi (đặc biệt là nam giới), người làm việc theo ca, tài xế thương mại và những người mắc các rối loạn giấc ngủ chưa được điều trị. Việc phát triển các hệ thống phát hiện buồn ngủ hiệu quả là điều rất quan trọng để ngăn ngừa các tai nạn như vậy.

Tuy nhiên, hầu hết các phương tiện hiện nay chưa được trang bị hệ thống cảnh báo buồn ngủ hiệu quả. Các phương pháp hiện có như theo dõi hình ảnh khuôn mặt hoặc sử dụng cảm biến EEG, ECG, EOG có độ chính xác cao nhưng lại gặp nhiều hạn chế như chi phí lớn, gây bất tiện cho người lái xe hoặc khó triển khai trên quy mô rộng. Do đó, việc phát triển một hệ thống phát hiện buồn ngủ có chi phí thấp, dễ triển khai, hoạt động thời gian thực và chính xác là nhu cầu cấp thiết.

Trong bối cảnh đó, tín hiệu Photoplethysmography (PPG) – một loại tín hiệu sinh lý phản ánh biến thiên thể tích máu trở thành một giải pháp tiềm năng. PPG có thể thu thập bằng cảm biến quang học, dễ dàng tích hợp vào các thiết bị đeo thông minh như đồng hồ thông minh, vòng tay sức khỏe, ... Nhờ tính tiện lợi, không xâm lấn và chi phí thấp, PPG đang được nghiên cứu rộng rãi trong các ứng dụng theo dõi sức khỏe và trạng thái tâm sinh lý.

Bên cạnh đó, sự phát triển nhanh chóng của trí tuệ nhân tạo và các mô hình học máy đã mở ra khả năng tự động phân tích tín hiệu sinh lý để nhận biết trạng thái con người một cách thông minh và chính xác.

Xuất phát từ những lý do trên, đề tài “Dự đoán sớm trạng thái buồn ngủ theo thời gian thực dựa trên tín hiệu PPG và học máy” được thực hiện nhằm xây dựng một hệ thống có thể hoạt động độc lập, dễ triển khai và có tính ứng dụng cao trong việc nâng cao an toàn giao thông. Hệ thống này có thể mở rộng và tích hợp vào các thiết bị đeo thông minh trong tương lai gần.

1.2 Mục tiêu nghiên cứu

Mục tiêu chính của đề tài là xây dựng một hệ thống có khả năng dự đoán sớm trạng thái buồn ngủ của người dùng dựa trên tín hiệu PPG theo thời gian thực, ứng dụng các kỹ thuật xử lý tín hiệu và mô hình học máy. Hệ thống nhằm hỗ trợ phát hiện sớm tình trạng buồn ngủ từ đó đưa ra cảnh báo kịp thời, góp phần đảm bảo an toàn khi lái xe.

Các mục tiêu cụ thể của nghiên cứu:

- Thu thập tín hiệu PPG từ cảm biến quang học (MAX30102) thông qua vi điều khiển ESP32 và giao tiếp nối tiếp với máy tính.
- Xây dựng quy trình xử lý tín hiệu PPG, bao gồm lọc nhiễu, phân đoạn theo cửa sổ trượt và trích xuất các đặc trưng nhiều miền:
 - Miền thời gian.
 - Biến đổi Fourier.
 - Biến đổi Wavelet.
 - Phân tích phi tuyến trong không gian pha.
- Ứng dụng các thuật toán học máy như K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Random Forest (RF), ... để huấn luyện mô hình dự đoán trạng thái của người dùng.
- Xây dựng hệ thống thời gian thực trên máy tính, có thể hiển thị tín hiệu PPG, dự đoán trạng thái người dùng và lưu dữ liệu phục vụ phân tích.
- Đánh giá độ chính xác và hiệu quả của mô hình trên tập dữ liệu thực nghiệm, từ đó phân tích khả năng áp dụng trong các tình huống thực tế.

Với những mục tiêu này, đề tài hướng đến việc tạo ra một giải pháp cảnh báo sớm buồn ngủ đơn giản, hiệu quả và có tiềm năng tích hợp vào các thiết bị thông minh trong tương lai, phục vụ nhu cầu theo dõi sức khỏe và an toàn cá nhân.

1.3 Phạm vi và giới hạn nghiên cứu

Do giới hạn về thời gian, thiết bị và nguồn lực, phạm vi của đề tài được xác định như sau:

- Loại tín hiệu sử dụng: đề tài chỉ tập trung vào việc thu thập và phân tích tín hiệu PPG để đánh giá trạng thái buồn ngủ của người dùng. Các tín hiệu sinh lý khác như EEG, ECG, EOG, EMG... không được xem xét trong phạm vi nghiên cứu này.

- Thiết bị phần cứng: Tín hiệu PPG được thu thập từ cảm biến MAX30102 kết nối với vi điều khiển ESP32, sau đó truyền về máy tính qua giao tiếp UART (COM port) để xử lý và phân tích.
- Đối tượng thử nghiệm: Dữ liệu được thu thập từ một số người dùng có giới hạn, trong điều kiện môi trường yên tĩnh, kiểm soát ánh sáng và tư thế ngồi cố định. Đề tài chưa tiến hành đánh giá trên quy mô lớn hoặc trong các tình huống lái xe thực tế.
- Mô hình học máy: Một số thuật toán phân loại cơ bản được sử dụng, bao gồm KNN, SVM, Decision Tree, RF. Các mô hình học sâu như RNN, LSTM chưa được áp dụng do yêu cầu cao về dữ liệu và tính toán.
- Giao diện ứng dụng: Hệ thống được triển khai trên máy tính cá nhân với giao diện hiển thị tín hiệu và kết quả dự đoán. Việc tích hợp lên thiết bị di động hoặc đồng hồ thông minh chưa được thực hiện trong khuôn khổ đề tài.
- Dữ liệu và nhãn trạng thái: Nhãn trạng thái được gán thủ công dựa trên thời điểm, biểu hiện hành vi và báo cáo từ người tham gia. Việc đánh giá khách quan bằng cách thiết bị chuyên dụng không nằm trong phạm vi đề tài.

1.4 Phương pháp thực hiện

Để đạt được mục tiêu của đề tài, quá trình nghiên cứu được triển khai theo các bước chính sau:

1. Thu thập dữ liệu PPG
 - Sử dụng cảm biến MAX30102 kết nối với ESP32 để đo tín hiệu PPG của người dùng trong thời gian thực.
 - Dữ liệu được truyền từ ESP32 về máy tính thông qua giao tiếp nối tiếp (UART) và lưu trữ bằng chương trình Python.
 - Quá trình thu thập diễn ra trong các trạng thái tỉnh táo và buồn ngủ, do người tham gia tự báo cáo kết hợp quan sát biểu hiện.
2. Tiền xử lý dữ liệu
 - Áp dụng bộ lọc thông thấp, thông cao để loại bỏ nhiễu và sóng chậm.
 - Chuẩn hóa và phân đoạn tín hiệu thành các cửa sổ trượt có độ dài cố định để phục vụ quá trình trích xuất đặc trưng.
3. Trích xuất đặc trưng đa miền
 - Từ mỗi cửa sổ tín hiệu, trích xuất các đặc trưng trong các miền:
 - Miền thời gian: nhịp tim, trung bình, phương sai,...
 - Biến đổi Fourier: phổ pha, biên độ, năng lượng,...
 - Biến đổi Wavelet: Kurtosis từ các hệ số phân rã,...
 - Phi tuyến: AMI, FNN, Lyapunov exponent,...
4. Xây dựng và huấn luyện mô hình học máy
 - Tập dữ liệu đặc trưng sau xử lý được gán nhãn và chia thành chín nhóm theo thang đo buồn ngủ Karolinska.

- Áp dụng các thuật toán học máy như KNN, SVM, Decision Tree, RF để huấn luyện mô hình phân loại.
 - Đánh giá độ chính xác của từng mô hình bằng phương pháp cross-validation và các chỉ số như accuracy, precision, recall, f1-score.
5. Xây dựng hệ thống dự đoán thời gian thực
- Thiết kế giao diện Python hiển thị tín hiệu PPG trực tiếp, thực hiện tính đặc trưng và dự đoán buồn ngủ liên tục.
 - Hiển thị trạng thái và cảnh báo người dùng nếu phát hiện dấu hiệu buồn ngủ.
6. Phân tích, đánh giá và định hướng phát triển
- Phân tích kết quả thu được để đánh giá tính hiệu quả của mô hình và tính khả thi của hệ thống.
 - Đề xuất hướng phát triển mở rộng như thu thập thêm dữ liệu, thử nghiệm trên thực tế, tích hợp lên thiết bị đeo thông minh,...

1.5 Ý nghĩa khoa học và thực tiễn

Ý nghĩa khoa học:

- Đề tài góp phần làm rõ khả năng ứng dụng tín hiệu PPG trong việc dự đoán trạng thái tâm sinh lý của con người, cụ thể là dự đoán trạng thái buồn ngủ - một vấn đề có giá trị nghiên cứu cao trong lĩnh vực y sinh và kỹ thuật điều khiển.
- Việc kết hợp trích xuất đặc trưng đa miền với các mô hình học máy thể hiện hướng tiếp cận hiện đại, có cơ sở lý thuyết vững chắc trong lĩnh vực trí tuệ nhân tạo ứng dụng cho tín hiệu sinh học.
- Kết quả của đề tài có thể làm nền tảng cho các nghiên cứu sức khỏe không xâm lấn tiếp theo, đặc biệt là trong bối cảnh nhu cầu chăm sóc sức khỏe cá nhân ngày càng tăng.

Ý nghĩa thực tiễn:

- Hệ thống được xây dựng có khả năng hoạt động thời gian thực, sử dụng cảm biến rẻ tiền, dễ triển khai, phù hợp để tích hợp vào các thiết bị đeo tay thông minh hoặc hệ thống giám sát lái xe trên phương tiện giao thông.
- Góp phần nâng cao an toàn giao thông bằng cách cung cấp một giải pháp cảnh báo sớm tình trạng mệt mỏi khi lái xe – một nguyên nhân chính dẫn đến tai nạn nghiêm trọng.
- Hệ thống có thể mở rộng để theo dõi sức khỏe người dùng trong các môi trường làm việc đòi hỏi sự tỉnh táo cao như: lái tàu, điều khiển máy móc, trực vận hành,...

1.6 Các công trình nghiên cứu liên quan

1.6.1 Phương pháp dựa trên hành vi điều khiển phương tiện

Phương pháp này phân tích các thay đổi trong cách người lái xe vận hành phương tiện, giả định rằng buồn ngủ sẽ ảnh hưởng đến khả năng điều khiển. Các

thông số thường được theo dõi bao gồm: chệch làn đường, góc vô lăng, tốc độ xe, thời gian phản ứng,...

Ưu điểm:

- Không xâm lấn: Không yêu cầu thiết bị gắn trực tiếp lên người lái xe.
- Dễ triển khai: Một số thông số có thể được thu thập từ các cảm biến có sẵn trên xe.
- Phản ánh trực tiếp tác động: Trực tiếp phản ánh sự suy giảm khả năng điều khiển do buồn ngủ.

Nhược điểm:

- Độ chính xác hạn chế: Các thay đổi trong hành vi lái xe có thể do nhiều yếu tố khác ngoài buồn ngủ (ví dụ: đường xấu, giao thông phức tạp,...).
- Phát hiện muộn: Phương pháp này thường chỉ phát hiện được buồn ngủ khi tình trạng đã trở nên nghiêm trọng.
- Yêu cầu dữ liệu lớn để huấn luyện: Cần lượng lớn dữ liệu hành vi lái xe trong các tình huống khác nhau để xây dựng mô hình.

Các công trình nghiên cứu:

1. Nghiên cứu của Zhang và cộng sự [1] đã phát triển một phương pháp mới để phát hiện buồn ngủ ở tài xế với độ chính xác cao (62.84%). Họ sử dụng mô hình ordered logit hiệu ứng hỗn hợp (MOL) có tích hợp hiệu ứng tích lũy theo thời gian (TCE) của tình trạng buồn ngủ. Điều này cho thấy việc xem xét sự khác biệt cá nhân và mức độ buồn ngủ tích lũy là rất quan trọng để phát hiện buồn ngủ chính xác hơn.
2. Nghiên cứu của Yuichi và cộng sự [2] tập trung vào việc nâng cao an toàn trong hệ thống lái xe tự động. Họ phát triển một cơ chế cảnh báo kép: nếu tài xế không tương tác với vô lăng trong tình huống cần "hands-on-wheel", hệ thống sẽ cảnh báo. Nếu tài xế vẫn không phản ứng, xe sẽ tự động phanh và dừng lại an toàn trong làn đường. Cơ chế này đã được chứng minh là hiệu quả trong việc ngăn chặn xe chệch làn đường và đảm bảo an toàn khi tài xế mất khả năng kiểm soát.

1.6.2 Phương pháp dựa trên hình ảnh và video khuôn mặt

Phương pháp này sử dụng camera để theo dõi các đặc điểm trên khuôn mặt và mắt của người lái xe, vì buồn ngủ thường thể hiện qua các dấu hiệu nhìn thấy được. Các chỉ số phổ biến bao gồm: thời gian nhắm mắt, ngáp, gật đầu, hướng nhìn, ...

Ưu điểm:

- Không xâm lấn: Chỉ cần một camera đặt trong xe.
- Độ chính xác tương đối cao: Các dấu hiệu trên khuôn mặt và mắt thường là chỉ báo đáng tin cậy của buồn ngủ.
- Dễ triển khai.

Nhược điểm:

- Ảnh hưởng bởi điều kiện môi trường: Ánh sáng yếu, kính râm, khẩu trang, mũ lưỡi trai hoặc các vật cản khác có thể ảnh hưởng đến khả năng nhận diện chính xác.
- Phát hiện muộn.
- Tính riêng tư: Một số người lái xe cảm thấy không thoải mái khi bị quay phim liên tục.
- Yêu cầu xử lý hình ảnh phức tạp: Cần thuật toán xử lý hình ảnh và học máy mạnh mẽ để phân tích thời gian thực.

Các công trình nghiên cứu:

1. Nghiên cứu của Delwar và cộng sự [3] đề xuất một phương pháp hiệu quả để phát hiện buồn ngủ bằng cách phân tích trạng thái mắt (nhắm/mờ) và tần suất nháy mắt. Họ sử dụng mạng Nơ-ron tích chập (CNNs), đặc biệt là mô hình MobileNet, để tự động trích xuất các mẫu phức tạp từ dữ liệu hình ảnh. Hệ thống này đạt độ chính xác cao 92.75%.
2. Nghiên cứu của Makhmudov và cộng sự [4] phát triển một hệ thống phát hiện mệt mỏi theo thời gian thực thông qua phân tích trạng thái mắt và hành vi ngáp của người lái xe. Họ sử dụng kiến trúc CNN và bộ phân loại Haar cascade để xác định vùng khuôn mặt. Với dữ liệu video thu thập từ camera trong xe, hệ thống này đạt độ chính xác thử nghiệm ấn tượng 96.54%, cho thấy tiềm năng lớn trong việc giải quyết vấn đề an toàn giao thông.

1.6.3 Phương pháp dựa trên tín hiệu sinh lý

Đây là phương pháp tiên tiến nhất, trực tiếp đo lường các phản ứng sinh học của cơ thể để đánh giá mức độ buồn ngủ. Các tín hiệu sinh lý thường được sử dụng bao gồm: điện não đồ (EEG), điện tim đồ (ECG), điện cơ đồ (EMG), điện mắt đồ (EOG), ...

Ưu điểm:

- Độ chính xác cao nhất: Cung cấp thông tin trực tiếp và đáng tin cậy về trạng thái sinh lý của cơ thể.
- Cảnh báo sớm và chính xác: Có khả năng phát hiện buồn ngủ ở giai đoạn rất sớm, trước khi các dấu hiệu hành vi xuất hiện.
- Ít bị ảnh hưởng bởi các yếu tố bên ngoài: Ít nhạy cảm với điều kiện ánh sáng hay các vật cản thông thường.

Nhược điểm:

- Xâm lấn và gây khó chịu: Yêu cầu gắn các điện cực lên cơ thể người lái xe, có thể gây bất tiện và mất tập trung.
- Chi phí cao và phức tạp: Thiết bị đo lường chuyên dụng thường đắt tiền và việc phân tích dữ liệu yêu cầu kiến thức chuyên sâu.

- Yêu cầu hiệu chuẩn cá nhân: Các tín hiệu sinh lý có thể khác nhau đáng kể giữa các cá nhân, đòi hỏi hiệu chuẩn riêng.
- Khó triển khai trong môi trường thực tế: Tính phức tạp và sự xâm lấn khiến phương pháp này khó áp dụng rộng rãi trong các hệ thống xe thương mại hiện nay.

Các công trình nghiên cứu:

1. Nghiên cứu của Z. Ren và cộng sự [5] tập trung vào việc phát hiện mệt mỏi khi lái xe dựa trên tín hiệu điện não đồ (EEG). Họ đã phát triển một mô hình tiên tiến sử dụng hàm cơ sở xuyên tâm (RBF) với phân cấp học tập hai cấp độ, được thiết kế để tối ưu hóa hiệu suất nhận dạng mệt mỏi. Phương pháp này tận dụng các đặc điểm phức tạp của sóng não để xác định chính xác các dấu hiệu của sự mệt mỏi, mang lại một cách tiếp cận mạnh mẽ để nâng cao an toàn giao thông. Kết quả nghiên cứu của họ rất đáng chú ý, với độ chính xác đạt 92.71% trong việc phân loại mức độ mệt mỏi của người lái. Nghiên cứu cho thấy hiệu quả cao và tiềm năng ứng dụng thực tiễn của mô hình RBF hai cấp độ này trong các hệ thống giám sát mệt mỏi.
2. F. Wang và cộng sự [6] (2025) đã nghiên cứu việc phát hiện mệt mỏi khi lái xe trong thời gian thực thông qua tín hiệu điện tâm đồ (ECG) được thu thập bằng các điện cực mới lạ, sau đó phân tích bằng mạng tán xạ wavelet. Việc sử dụng mạng tán xạ wavelet cho thấy tiềm năng xử lý hiệu quả các tín hiệu sinh học phức tạp để đưa ra đánh giá chính xác về tình trạng mệt mỏi với độ chính xác lên đến 97.93%.

1.7 Kết luận chương

Chương 1 đã trình bày tổng quan về đề tài nghiên cứu, từ bối cảnh xã hội cấp thiết liên quan đến tai nạn giao thông do buồn ngủ, đến việc lựa chọn tín hiệu PPG và mô hình học máy làm hướng tiếp cận nhằm xây dựng hệ thống cảnh báo sớm tình trạng buồn ngủ theo thời gian thực.

Nội dung chương bao gồm mục tiêu nghiên cứu, phạm vi và giới hạn, phương pháp thực hiện, ý nghĩa khoa học và thực tiễn, cũng như các công trình nghiên cứu có liên quan.

Qua đó, chương đã đặt nền tảng lý thuyết và định hướng triển khai cho các nội dung tiếp theo của đề án, góp phần làm rõ tính khả thi và giá trị ứng dụng cao của đề tài trong lĩnh vực an toàn giao thông và chăm sóc sức khỏe thông minh.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT


Trong chương này, các kiến thức nền tảng liên quan đến tín hiệu PPG, phương pháp xử lý và trích xuất đặc trưng sẽ được trình bày nhằm làm cơ sở cho việc xây dựng hệ thống dự đoán buồn ngủ.

2.1 Tín hiệu PPG

2.1.1 Nguồn gốc sinh lý

Tín hiệu PPG có nguồn gốc sinh lý từ sự thay đổi thể tích máu trong mô ngoại vi, xảy ra đồng thời với hoạt động co bóp tim. Mỗi chu kỳ, tim bơm máu vào các động mạch, làm thay đổi áp suất và thể tích trong các mạch máu, từ đó ảnh hưởng đến tính chất hấp thụ ánh sáng của mô. Cường độ ánh sáng được ghi lại dưới dạng tín hiệu điện áp, chính là PPG. Những thay đổi này có thể được ghi nhận bằng cảm biến quang học, phản ánh nhịp tim và các trạng thái sinh lý liên quan như mức độ tỉnh táo, căng thẳng, hoặc buồn ngủ. Vì vậy, tín hiệu PPG là một chỉ báo sinh lý gián tiếp nhưng hiệu quả của hoạt động tim mạch.

Tín hiệu PPG thô phản ánh sự thay đổi trong việc suy giảm bức xạ quang học do các thành phần mô khác nhau gây ra. Phần “AC” (tần số cao) của tín hiệu PPG xuất phát từ sự thay đổi thể tích máu động mạch theo mỗi nhịp tim, trong khi phần “DC” (tần số thấp) là do sự thay đổi của các thành phần mô khác như máu tĩnh mạch, động mạch hoặc các mô không chứa máu.



Hình 2.1 Nguồn gốc đơn giản hóa của tín hiệu PPG.

Sự suy giảm ánh sáng trong mô được mô tả bằng định luật Beer-Lambert cải tiến, phụ thuộc vào quãng đường quang học và hệ số suy giảm của môi trường:

$$\ln\left(\frac{I_t}{I_0}\right) = -K \cdot d \cdot C \quad PT 2.1$$


ở đây:

- K là hằng số tỷ lệ.
- d là độ dài đường dẫn quang học.
- C là chiết suất.

2.1.2 Đặc điểm của tín hiệu PPG


Tín hiệu PPG có dạng gần như tuần hoàn, với mỗi nhịp tim tương ứng với một sóng mạch động mạch. Dù giống sóng huyết áp động mạch, nhưng hình

dạng đường viền sóng PPG có những khác biệt quan trọng. Mỗi sóng PPG có hai pha rõ rệt: pha lên (anacrotic phase) và pha xuống (catacrotic phase).




Hình 2.2 Sóng xung PPG điển hình.

Hình thái sóng PPG chịu ảnh hưởng bởi nhiều yếu tố sinh lý. Tim tác động qua nhịp tim, nhịp điệu và thể tích nhát bóp. Hệ tuần hoàn ảnh hưởng thông qua các đặc tính tim mạch như độ cứng động mạch và huyết áp. Ngoài ra, các quá trình sinh lý khác như hô hấp và hệ thần kinh tự chủ (có thể bị ảnh hưởng bởi căng thẳng), cùng với tình trạng bệnh lý, cũng làm thay đổi hình dạng sóng PPG. Ví dụ, hình dạng sóng PPG cũng thay đổi theo quá trình lão hóa ở người khỏe mạnh.



Hình 2.3 Các lớp của hình dạng sóng xung PPG.

Việc phân tích tín hiệu PPG gặp nhiều thách thức, khiến việc trích xuất thông tin đáng tin cậy trở nên phức tạp. Tín hiệu PPG chứa nhiều biến động sinh lý, nhưng không phải tất cả đều phù hợp cho một phân tích cụ thể. Hơn nữa, tín hiệu này rất dễ bị nhiễu, bao gồm nhiễu do chuyển động, nhiễu đường dây điện, nhiễu tần số thấp/cao. Các yếu tố kỹ thuật như loại cảm biến và vị trí đo cũng ảnh hưởng đến hình dạng sóng. Sự đa dạng của các yếu tố tác động này làm tăng thêm độ phức tạp cho việc phân tích PPG.



Hình 2.4 Các ví dụ về tín hiệu PPG sạch và nhiễu.


2.1.3 Thu nhận tín hiệu

2.1.3.1. Các loại cảm biến

Cảm biến đo tín hiệu PPG thông thường bao gồm một nguồn phát sáng (thường là đèn LED) và một bộ tách sóng quang cực nhạy (thường là photodiode silicon).

Có hai loại cảm biến đo PPG chính:

- Chế độ truyền (Transmission mode): đèn LED và photodiode được đặt ở hai phía đối diện của kẹp. Ánh sáng từ LED xuyên qua mô và được photodiode phát hiện. Loại cảm biến này được sử dụng rộng rãi trong y tế đo độ bão hòa oxy động mạch, nhưng bị giới hạn ở các vị trí ngoại vi mà kẹp có thể gắn vào, như ngón tay, dải tai hoặc ngón chân.
- Chế độ phản xạ (Reflectance mode): đèn LED và photodiode được gắn cạnh nhau, cách nhau vài milimet. Ánh sáng từ LED xuyên vào mô và photodiode phát hiện ánh sáng bị tán xạ ngược trở lại. Cảm biến này có thể sử dụng ở hầu hết mọi vị trí có mô mạch máu và được ứng dụng rộng rãi trong các thiết bị đeo thông minh tiêu dùng.



Hình 2.5 Hai loại cảm biến đo PPG chính: (a) Chế độ truyền, (b) Chế độ phản xạ.

2.1.3.2. Cấu hình cảm biến

Chất lượng tín hiệu PPG phụ thuộc vào cả thiết bị và cách thiết lập cảm biến. Để thu được tín hiệu PPG chất lượng cao nhất, cần tối ưu hóa các thông số cảm biến như bước sóng hoạt động, cường độ, tần số lấy mẫu, vì chúng ảnh

hưởng trực tiếp đến chất lượng và hình dạng của sóng PPG. Việc cấu hình các thông số này sẽ khác nhau tùy theo ứng dụng cụ thể:

1. Đo nhịp tim ở cổ tay:

- Chế độ cảm biến: sử dụng chế độ phản xạ.
- Tần số lấy mẫu: Thấp (ví dụ: < 40 Hz) là đủ vì băng thông tim mạch thường nhỏ hơn 5 Hz.
- Bước sóng: Ngắn hơn (ví dụ: xanh lá cây hoặc đỏ) để thu tín hiệu PPG từ mô dưới da, vì không cần xuyên sâu hơn.
- Khoảng cách nguồn – tách sóng: Nhỏ (lý tưởng là $< 3\text{mm}$) vì ánh sáng bước sóng ngắn khó xuyên sâu.

2. Đo nhịp tim ở ngón tay:

- Chế độ cảm biến: Sử dụng chế độ truyền để đảm bảo tín hiệu PPG bị ảnh hưởng bởi các động mạch chính ở ngón tay.
- Tần số lấy mẫu: Cao hơn (ví dụ > 500 Hz) để đánh giá thời gian sóng mạch.
- Bước sóng: Dài hơn (ví dụ: hồng ngoại, $\lambda \approx 940\text{ nm}$) để xuyên sâu hơn và đảm bảo tín hiệu PPG phản ánh sự thay đổi thể tích máu động mạch.
- Khoảng cách nguồn – tách sóng: Dài hơn (ví dụ $\approx 5\text{ mm}$) để phù hợp với ngón tay.

2.2 Xử lý tín hiệu PPG

Tín hiệu PPG thu được từ cảm biến thường bị ảnh hưởng bởi nhiều yếu tố như chuyển động cơ thể, nhiễu ánh sáng môi trường, và nhiễu thiết bị. Do đó, việc xử lý tín hiệu trước khi trích xuất đặc trưng là bước quan trọng nhằm nâng cao độ chính xác của hệ thống dự đoán buồn ngủ.

2.2.1 Tiền xử lý tín hiệu

Tín hiệu PPG thô thường chứa nhiều tần số thấp và nhiều tần số cao. Một số bước tiền xử lý bao gồm:

- Lọc thông dải: loại bỏ thành phần DC và nhiễu tần số cao, thường dùng dải $0.5 - 5\text{ Hz}$ để giữ lại phần chứa nhịp tim.
- Chuẩn hóa tín hiệu: giúp cân bằng biên độ giữa các cửa sổ phân tích.
- Làm mượt: áp dụng trung bình trượt hoặc bộ lọc để giảm nhiễu cục bộ.

Trong đồ án này, quá trình tiền xử lý tín hiệu đóng vai trò quan trọng trong việc trích xuất thông tin từ dữ liệu thô. Mục tiêu chính là loại bỏ nhiễu và thành phần không mong muốn, đồng thời làm nổi bật các đặc điểm của nhịp đập để phát hiện chính xác. Các kỹ thuật chính được sử dụng bao gồm lọc bỏ thành phần một chiều (DC), lọc thông thấp và phát hiện nhịp tim.

2.2.1.1. Lọc bỏ thành phần DC

Tín hiệu hồng ngoại (IR) thô thường chứa một thành phần DC lớn, là phần không đổi hoặc thay đổi rất chậm theo thời gian. Thành phần này có thể do ánh

sáng xung quanh hoặc sự thay đổi vị trí của cảm biến. Để phân tích các biến đổi nhỏ liên quan đến nhịp tim, cần phải loại bỏ thành phần DC.

Quá trình lọc bỏ thành phần DC được thực hiện bằng một bộ lọc thông thấp IIR (Infinite Impulse Response) bậc một. Trong quá trình lọc, mỗi mẫu tín hiệu mới đo được từ cảm biến tại thời điểm hiện tại được kí hiệu là $x[n]$. Giá trị $p[n]$ đại diện cho tín hiệu DC đã được ước lượng thông qua bộ lọc, còn hệ số α là tham số điều chỉnh mức độ làm mượt: giá trị nhỏ của α sẽ cho phép bộ lọc phản hồi chậm hơn, giúp ổn định kết quả lọc. Bộ lọc được tính bằng công thức:

$$p[n] = (1 - \alpha) \cdot p[n - 1] + \alpha \cdot x[n] \quad PT\ 2.2$$

Tín hiệu đầu ra sau lọc $y[n]$ được xác định là phần dao động AC của tín hiệu gốc, bằng hiệu giữa tín hiệu hiện tại $x[n]$ và thành phần DC đã lọc $p[n]$:

$$y[n] = x[n] - p[n] \quad PT\ 2.3$$

2.2.1.2. Lọc thông thấp

Sau khi loại bỏ thành phần DC, tín hiệu vẫn có thể chứa nhiều tần số cao do các yếu tố như nhiễu điện tử hoặc chuyển động nhỏ của cảm biến. Để làm mượt tín hiệu và chuẩn bị cho việc phát hiện nhịp chính xác hơn, một bộ lọc thông thấp FIR được áp dụng.

Bộ lọc FIR hoạt động bằng cách thực hiện phép tích chập của tín hiệu đầu vào với một tập hợp các hệ số bộ lọc đã định trước. Các hệ số này được thiết kế để loại bỏ các tần số cao trong khi vẫn giữ lại các tần số thấp, nơi chứa thông tin nhịp tim.

Công thức tổng quát của bộ lọc FIR là:

$$y[n] = \sum_{i=0}^N C_i \cdot x[n - i] \quad PT\ 2.4$$

Trong đó:

- $y[n]$: là mẫu tín hiệu đầu ra đã được lọc tại thời điểm hiện tại n .
- N : là bậc của bộ lọc.
- C_i : là hệ số thứ i của bộ lọc.
- $x[n]$: là tín hiệu đầu vào.

2.2.2 Phân đoạn tín hiệu theo cửa sổ trượt

Sau khi tiền xử lý, tín hiệu được phân đoạn thành các cửa sổ nhỏ cố định, nhằm phục vụ cho việc trích xuất đặc trưng và dự đoán theo thời gian thực. Mỗi cửa sổ sẽ được xem là một mẫu đầu vào cho mô hình học máy.

- Kích thước cửa sổ và tỉ lệ trượt cần được chọn tối ưu để đảm bảo cân bằng giữa độ chính xác và độ trễ hệ thống.
- Trong đề tài này, sử dụng cửa sổ trượt 60 giây với trượt 1 giây để đảm bảo tính liên tục và đủ mẫu để thực hiện tính các đặc trưng.

2.2.3 Loại bỏ nhiễu và phát hiện bất thường

Trong một số trường hợp, tín hiệu bị sai lệch nghiêm trọng do cử động mạnh hoặc tiếp xúc không ổn định của cảm biến. Để đảm bảo dữ liệu đầu vào chất lượng:

- Sử dụng ngưỡng biên độ hoặc hàm phát hiện outlier để loại bỏ các phân đoạn tín hiệu bất thường.
- Có thể áp dụng thuật toán như z-score, IQR (Interquartile Range) hoặc Hampel Filter để tự động phát hiện nhiễu.

Việc xử lý tín hiệu kỹ lưỡng giúp giảm sai số trong quá trình trích xuất đặc trưng và huấn luyện mô hình, từ đó cải thiện hiệu suất dự đoán trạng thái buồn ngủ trong thực tế.

2.3 Các thang đo mức độ buồn ngủ

Để đánh giá mức độ buồn ngủ của một cá nhân, đặc biệt trong các nghiên cứu về giấc ngủ và an toàn khi lái xe, nhiều thang đo tiêu chuẩn đã được phát triển. Các thang đo này giúp lượng hóa trạng thái buồn ngủ một cách khách quan hoặc chủ quan, làm cơ sở để xây dựng các mô hình dự đoán và cảnh báo. Sau đây là một số thang đo phổ biến.

2.3.1 Thang đo mức độ buồn ngủ của Epworth

Thang đo cơn buồn ngủ của Epworth (Epworth Sleepiness Scale – ESS) là một công cụ đơn giản và thường được sử dụng trong y khoa để đánh giá mức độ buồn ngủ vào ban ngày của một người. Mục tiêu chính là giúp nhận diện tình trạng buồn ngủ quá mức vào ban ngày, điều này có thể là dấu hiệu của các rối loạn giấc ngủ tiềm ẩn.

Người trả lời sẽ được yêu cầu đánh giá mức độ buồn ngủ của mình trong những tình huống cụ thể. Mỗi tình huống được chấm điểm dựa trên xác suất người đó sẽ buồn ngủ hoặc ngủ gật. Người được hỏi sẽ tự đánh giá khả năng ngủ gật theo mức độ từ 0 đến 3, như sau:

- 0: Không bao giờ ngủ gật.
- 1: Có khả năng nhỏ ngủ gật.
- 2: Khả năng trung bình ngủ gật.
- 3: Khả năng cao ngủ gật.

Các tình huống trong thang đo:

- Khi ngồi đọc sách: Đây là tình huống yên tĩnh và không đòi hỏi sự tương tác. Mức độ buồn ngủ ở tình huống này sẽ phản ánh khả năng duy trì sự tỉnh táo khi không bị phân tâm.
- Khi xem ti vi: Hoạt động này khá phổ biến và ít đòi hỏi sự tập trung cao, dễ khiến một người cảm thấy buồn ngủ.
- Khi ngồi trong một nơi công cộng (ví dụ: rạp hát, cuộc họp): Trong một môi trường yên tĩnh và ít hoạt động, người ta dễ rơi vào trạng thái buồn ngủ, đặc biệt nếu họ thiếu ngủ hoặc gặp các vấn đề về giấc ngủ.

- Khi ngồi trên xe hơi trong một quãng đường dài mà không có nghỉ giữa chặng: Đây là tình huống thường khiến nhiều người cảm thấy mệt mỏi do thời gian ngồi kéo dài và sự đơn điệu của chuyến đi.
- Khi nghỉ ngơi buổi chiều, nằm trên giường: Đây là thời gian nghỉ ngơi tự nhiên trong ngày, và cảm giác buồn ngủ có thể là dấu hiệu của sự thiếu ngủ hoặc quá mệt mỏi.
- Khi ngồi nói chuyện với ai đó: Đây là tình huống đòi hỏi sự tương tác xã hội, nhưng nếu một người cảm thấy buồn ngủ trong tình huống này, có thể là dấu hiệu của buồn ngủ quá mức ban ngày.
- Khi ngồi yên lặng sau bữa trưa mà không uống rượu: Sau bữa ăn trưa, cơ thể sẽ tự nhiên có xu hướng cảm thấy mệt mỏi do quá trình tiêu hóa. Nếu mức độ buồn ngủ quá cao, điều đó có thể là dấu hiệu của sự rối loạn giấc ngủ.
- Khi ngồi trên xe hơi bị kẹt xe trong vài phút: Đây là tình huống mà nhiều người cảm thấy buồn ngủ, đặc biệt nếu họ đang phải ngồi yên mà không có việc gì để làm.

Sau khi hoàn thành đánh giá tất cả 8 tình huống, điểm số của mỗi câu trả lời sẽ được cộng lại. Tổng số điểm có thể nằm trong khoảng từ 0 đến 24, và mức độ buồn ngủ ban ngày được phân loại như Bảng 2.1:

Bảng 2.1 Thang đo mức độ buồn ngủ của Epworth.

0 – 9 điểm:	Mức buồn ngủ bình thường trong các tình huống hàng ngày. Đây là mức độ buồn ngủ không đáng lo ngại.
10 – 12 điểm:	Mức độ buồn ngủ nhẹ, có thể là dấu hiệu cảnh báo về rối loạn giấc ngủ hoặc sự thiếu ngủ.
13 – 15 điểm:	Mức độ buồn ngủ trung bình, cần phải xem xét thêm về giấc ngủ của người đó, có thể liên quan đến các rối loạn giấc ngủ như chứng ngưng thở khi ngủ.
16 – 24 điểm:	Mức độ buồn ngủ nghiêm trọng, có khả năng cao liên quan đến rối loạn giấc ngủ. Người có điểm số này cần được tham khảo ý kiến bác sĩ để kiểm tra và điều trị.

2.3.2 Thang đo mức độ buồn ngủ của Karolinska

Thang đo buồn ngủ của Karolinska (Karolinska's Sleepiness Scale – KSS) là một công cụ hữu ích và thường được sử dụng trong các nghiên cứu về giấc ngủ, rối loạn giấc ngủ, và các điều kiện khác liên quan đến sự mệt mỏi, thiếu ngủ, hoặc sự thay đổi trong mô hình giấc ngủ của con người. Thang đo này cho phép cá nhân tự đánh giá cảm giác buồn ngủ của mình tại một thời điểm cụ thể trong ngày.

Mục tiêu chính của thang đo là để đánh giá mức độ buồn ngủ của một cá nhân trong ngày, thường là trong những tình huống mà sự buồn ngủ có thể ảnh hưởng đến công việc hoặc sinh hoạt hàng ngày. Các nhà khoa học thường sử dụng thang này để nghiên cứu mối liên quan giữa giấc ngủ và hiệu suất làm việc, sự tỉnh táo trong các hoạt động hàng ngày, và rủi ro tai nạn do buồn ngủ gây ra.

Thang đo gồm 9 mức, mỗi mức đại diện cho một cấp độ buồn ngủ từ “rất tỉnh táo” đến “rất buồn ngủ”. Mỗi mức đi kèm với một mô tả cụ thể để người tự đánh giá, dễ dàng xác định mức độ buồn ngủ của mình.

Bảng 2.2 Thang đo mức độ buồn ngủ của Karolinska.

Mức độ	Mô tả
1	Rất tỉnh táo
2	Tỉnh táo
3	Khá tỉnh táo
4	Khá thư giãn
5	Không chắc chắn, không tỉnh táo cũng không buồn ngủ
6	Dấu hiệu đầu tiên của buồn ngủ
7	Buồn ngủ, nhưng không khó để tỉnh táo
8	Buồn ngủ, có khó khăn để tỉnh táo
9	Rất buồn ngủ, cần ngủ ngay lập tức

KSS đánh giá mức độ buồn ngủ chủ quan, giúp các nhà nghiên cứu xác định sự mệt mỏi và ảnh hưởng đến hiệu suất làm việc và nhận thức. Ví dụ, những người ở mức 8 hoặc 9 có thể gặp rủi ro cao về hiệu suất kém trong công việc hoặc thậm chí tai nạn giao thông nếu họ đang lái xe.

2.3.3 Thang đo mức độ buồn ngủ của Stanford

Thang đo mức độ buồn ngủ của Stanford (Stanford's Sleepiness Scale – SSS) là một công cụ đơn giản và phổ biến để đo mức độ buồn ngủ vào bất kỳ thời điểm nào trong ngày. Nó được sử dụng để đánh giá mức độ tỉnh táo hoặc buồn ngủ của một người tại thời điểm đó. Thang đo này bao gồm 7 mức độ, mỗi mức độ tương ứng với một trạng thái cụ thể của cơ thể.

Bảng 2.3 Thang đo mức độ buồn ngủ của Stanford.


Mức độ	Mô tả
1	Hoàn toàn tỉnh táo: Cảm giác tươi tỉnh, nhanh nhẹn.
2	Chút ít mệt mỏi: Tỉnh táo nhưng cảm thấy một chút mệt mỏi hoặc không hoàn toàn nhanh nhẹn.
3	Bắt đầu cảm thấy buồn ngủ: Cảm thấy mệt mỏi, không tập trung tối đa.
4	Rất buồn ngủ: Tâm trí bắt đầu có cảm giác muốn ngủ, khó tập trung.
5	Rất buồn ngủ và kém tỉnh táo: Cảm thấy cần phải nỗ lực lớn để tỉnh táo và tập trung.
6	Ngủ chập chờn: Buồn ngủ đến mức có thể chớp mắt hoặc gật đầu trong thời gian ngắn.
7	Rất khó giữ tỉnh táo: Ngủ gật thường xuyên, cảm thấy rất khó để tỉnh táo và duy trì ý thức

2.4 Trích xuất đặc trưng từ tín hiệu PPG

Sau khi tiền xử lý và phân đoạn tín hiệu PPG, quá trình trích xuất đặc trưng sẽ biến đổi mỗi phân đoạn tín hiệu thành một vector số, chứa các thông tin quan trọng phản ánh trạng thái sinh lý của người lái xe. Trong đề tài này, các đặc trưng được phân tích thành bốn nhóm chính: miền thời gian, biến đổi Fourier, biến đổi Wavelet, và đặc trưng phi tuyến trong không gian pha.

2.4.1 Đặc trưng miền thời gian

Phân tích tín hiệu PPG trong miền thời gian là bước cơ bản nhưng quan trọng, nhằm khai thác trực tiếp các đặc trưng hình thái của tín hiệu. Các đặc trưng này phản ánh sự thay đổi về chu kỳ tim, biên độ co bóp và tốc độ lưu thông máu – những yếu tố chịu ảnh hưởng trực tiếp bởi trạng thái tỉnh táo hay buồn ngủ của con người. Trong hệ thống này, tín hiệu PPG sau tiền xử lý sẽ được tính các đặc trưng được thể hiện ở Bảng 2.4 trong mỗi cửa sổ. Để tính toán được các đặc trưng trong miền thời gian, trước tiên sử dụng thuật toán phát hiện đỉnh và đáy trong mỗi cửa sổ tín hiệu.



Hình 2.6 Thuật toán phát hiện đỉnh và đáy.

Bảng 2.4 Đặc trưng miền thời gian.

BPM	Beats per Minute	Nhịp tim tính bằng số đỉnh nhịp trong một phút.
MPI	Mean Peak-to-Peak Interval	Khoảng cách trung bình giữa các đỉnh liên tiếp.
SPI	Standard Peak-to-Peak Interval	Độ lệch chuẩn của khoảng cách giữa các đỉnh nhịp.
MA	Mean Amplitude	Biên độ trung bình giữa đỉnh và đáy của các chu kỳ PPG.
MRT	Mean Rise Time	Thời gian trung bình từ điểm đáy đến đỉnh trong mỗi chu kỳ.

Số nhịp tim trên phút (BPM) phản ánh tần số tim. Nhịp tim thường có xu hướng tăng khi cơ thể ở trạng thái tỉnh táo hoặc căng thẳng, và có xu hướng giảm nhẹ khi buồn ngủ do hệ thần kinh phó giao cảm chiếm ưu thế. Nhịp tim được tính đơn giản theo công thức:

$$BPM = \frac{60 \times N_{peak}}{T} \quad PT\ 2.5$$

ở đây, N_{peak} là số đỉnh phát hiện được trong khoảng thời gian T .

Khoảng cách trung bình giữa các đỉnh liên tiếp (MPI) với t_i là thời điểm xuất hiện đỉnh thứ i , là nghịch đảo của BPM và thể hiện chu kỳ tim trung bình. Đặc trưng này có mối liên hệ chặt chẽ với sự biến thiên nhịp tim (HRV), cung cấp thông tin về sự đều đặn của các nhịp tim. MPI thường tăng lên khi người lái thư giãn hoặc buồn ngủ. MPI được xác định theo công thức:

$$MPI = \frac{1}{N-1} \sum_{i=1}^{N-1} (t_{i+1} - t_i) \quad PT 2.6$$

với N là số đỉnh phát hiện được.

SPI là độ lệch chuẩn của khoảng cách giữa các đỉnh nhịp, biểu thị sự biến thiên nhịp tim. Một giá trị SPI càng cao cho thấy sự biến động nhịp tim lớn hơn, điều này thường liên quan đến trạng thái thư giãn sâu hoặc các thay đổi trong hoạt động của hệ thần kinh tự chủ.

$$SPI = \sqrt{\frac{1}{N-2} \sum_{i=1}^{N-1} [(t_{i+1} - t_i) - MPI]^2} \quad PT 2.7$$

MA là biên độ trung bình giữa đỉnh và đáy của các chu kỳ PPG. Biên độ này phản ánh cường độ co bóp của mạch máu và lưu lượng máu qua các mao mạch ngoại vi. Biên độ có thể thay đổi tùy thuộc vào sự co thắt hoặc giãn nở mạch máu, thường có xu hướng giảm khi buồn ngủ sâu do hiện tượng giãn mạch. Công thức tính biên độ trung bình với mỗi đỉnh P_i tìm giá trị đáy gần nhất V_i liên trước:

$$MA = \frac{1}{N} \sum_{i=1}^N (P_i - V_i) \quad PT 2.8$$

Trung bình thời gian từ đáy tới đỉnh (MRT) phản ánh mức độ co bóp của tim và sự đáp ứng sinh lý của hệ tuần hoàn. Nếu khoảng thời gian này kéo dài thì đó là dấu hiệu của sự chậm chạp trong đáp ứng tuần hoàn, thường xuất hiện khi mệt mỏi hoặc buồn ngủ. MRT được tính như sau:

$$MRT = \frac{1}{N} \sum_{i=1}^N (t_{P_i} - t_{V_i}) \quad PT 2.9$$

ở đây, t_{P_i} và t_{V_i} là thời điểm phát hiện đỉnh và đáy thứ i .

2.4.2 Đặc trưng từ biến đổi Fourier

Biến đổi Fourier là một công cụ toán học mạnh mẽ cho phép phân tích tín hiệu từ miền thời gian sang miền tần số, bóc tách các thành phần tần số khác nhau tạo nên tín hiệu. Trong ngữ cảnh của tín hiệu PPG, việc áp dụng biến đổi Fourier nhanh (FFT) sẽ cho phép nhìn thấy phổ năng lượng của tín hiệu, từ đó xác định các tần số chủ đạo và cường độ của chúng.

FFT là một thuật toán hiệu quả để tính toán biến đổi Fourier rời rạc (DFT). Công thức của DFT cho một chuỗi tín hiệu rời rạc $x[n]$ với N mẫu là:

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j\frac{2\pi kn}{N}} \quad PT 2.10$$

Trong đó:

- $X[k]$ là giá trị của phổ tại tần số rời rạc thứ k . Đây là một số phức, bao gồm biên độ và pha.
- $x[n]$ là giá trị của tín hiệu PPG tại thời điểm rời rạc thứ n .
- N là tổng số điểm (mẫu) trong tín hiệu.
- k là chỉ số tần số, chạy từ 0 đến $N - 1$.
- $e^{-j\frac{2\pi kn}{N}}$ là nhân tố điều hòa phức tạp, đại diện cho các sóng hình sin và cosin ở các tần số khác nhau.

Khi tín hiệu PPG được chuyển đổi sang miền tần số, trục hoành biểu thị tần số (Hz) và trục tung biểu thị biên độ hoặc năng lượng của các thành phần tần số đó. Tần số cơ bản của tín hiệu PPG thường nằm trong khoảng 0.8 Hz đến 2.5 Hz (tương ứng với nhịp tim từ 48 đến 150 nhịp/phút). Phân tích phổ tần số của PPG có thể tiết lộ các thông tin quan trọng về hoạt động của hệ thần kinh tự chủ, cũng như nhiều định kỳ chưa được loại bỏ hoàn toàn trong quá trình tiền xử lý.

Phổ biên độ thể hiện cường độ dao động của tín hiệu tại từng tần số biên độ. Trong tín hiệu PPG, các thành phần biên độ lớn hơn phản ánh các dao động sinh lý như nhịp tim và các biến độ mạch máu. Việc phân tích phổ biên độ giúp xác định tần số chủ đạo trong tín hiệu. Phổ biên độ được xác định theo công thức:


$$A_k = |X[k]| = \sqrt{Re(X[k])^2 + Im(X[k])^2} \quad PT 2.11$$

Phổ pha biểu diễn góc pha của các thành phần tần số trong tín hiệu, cho biết sự trễ hay dẫn pha của sóng tại từng tần số. Phổ pha giúp phân tích mối quan hệ thời gian giữa các thành phần dao động khác nhau trong tín hiệu. Sự đồng bộ hoặc biến thiên pha tại các tần số quan trọng phản ánh tính nhất quán hoặc mất ổn định trong chu kỳ tim và các tín hiệu sinh lý liên quan. Thay đổi trong phổ pha có thể chỉ ra sự mất cân bằng thần kinh tự động khi người lái bước vào trạng thái buồn ngủ. Phổ pha được định nghĩa như sau:

$$\varphi_k = \arg(|X[k]|) = \arctan\left(\frac{Im(X[k])}{Re(X[k])}\right) \quad PT 2.12$$

Phổ năng lượng là bình phương phổ biên độ, thể hiện mức độ năng lượng hoặc công suất tín hiệu ở từng tần số. Công thức của phổ năng lượng:

$$E_k = |X[k]|^2 \quad PT 2.13$$



Hình 2.7 Biến đổi tần số của tín hiệu PPG.

Các đặc trưng biến đổi Fourier của tín hiệu PPG được thể hiện ở Bảng 2.5:

Bảng 2.5 Đặc trưng từ biến đổi Fourier.

FMA	Frequency of Maximum Amplitude	Tần số có phổ biên độ lớn nhất.
MPP	Mean of Phase Valleys	Trung bình các pha tương ứng với đỉnh trong miền tần số.
SPP	Standard of Phase Peaks	Độ lệch chuẩn của các pha tại đỉnh.
MPV	Mean of Phase Valleys	Trung bình pha tại các đáy trong phổ tần.
SPV	Standard of Phase Valleys	Độ lệch chuẩn pha ở các điểm thấp nhất của phổ.
TE	Total Energy	Tổng năng lượng tín hiệu trong miền tần số.

FMA là tần số tại đó phổ biên độ lớn nhất trong dải tần số quan tâm. Đặc trưng này thường tương ứng với tần số nhịp tim chính của tín hiệu, cung cấp một cách khác để xác định nhịp tim so với phương pháp đếm đỉnh trong miền thời gian.

$$FMA = f_{max} \quad PT 2.14$$

ở đây, f_{max} thỏa mãn $A(f_{max}) = \max A(f)$.

MPP là trung bình đỉnh của phổ pha. Việc phân tích trung bình các đỉnh pha có thể giúp định lượng một số đặc tính pha tổng thể.

$$MPP = \frac{1}{N_p} \sum_{p=1}^N \varphi(f_p) \quad PT 2.15$$

ở đây, f_p là tần số tại đó phổ pha đạt đỉnh, N_p là số đỉnh của phổ pha.

Độ lệch chuẩn đỉnh của phổ pha (SPP) đo lường sự biến động hoặc phân tán của đỉnh pha trong phổ pha. Độ lệch chuẩn cao có thể chỉ ra sự không ổn định hoặc phức tạp trong cấu trúc pha của tín hiệu, có thể liên quan đến sự không

đồng đều của chu kỳ tim hoặc các yếu tố sinh lý khác ảnh hưởng đến độ trễ truyền sóng.

$$SPP = \sqrt{\frac{1}{N_p - 1} \sum_{p=1}^N [\varphi(f_p) - MPP]^2} \quad PT 2.16$$

Trung bình đáy của phổ pha (MPV) và độ lệch chuẩn đáy của phổ pha (SPV) tương tự như MPP và SPP nhưng áp dụng cho các pha cực tiểu, cung cấp một cái nhìn sâu sắc hơn về tính chất biến đổi của pha tín hiệu.

$$MPV = \frac{1}{N_v} \sum_{v=1}^N \varphi(f_v) \quad PT 2.17$$

$$SPV = \sqrt{\frac{1}{N_v - 1} \sum_{v=1}^N [\varphi(f_v) - MPV]^2} \quad PT 2.18$$

TE là tổng năng lượng của tín hiệu trong một tần số cụ thể. Đặc trưng này phản ánh tổng cường độ của tín hiệu PPG. Tổng năng lượng có thể thay đổi tùy thuộc vào mức độ lưu thông máu và cường độ co bóp tim, cung cấp một chỉ số tổng quát về hoạt động tuần hoàn.

$$TE = \sum_{k=0}^{N-1} |X[k]|^2 \quad PT 2.19$$

2.4.3 Đặc trưng từ biến đổi Wavelet


Biến đổi Wavelet là một công cụ phân tích tín hiệu mạnh mẽ, cho phép phân tích tín hiệu ở các mức phân giải khác nhau, đồng thời duy trì thông tin về thời gian. Điều này đặc biệt hữu ích cho các tín hiệu không dừng như PPG, nơi các sự kiện có thể xảy ra trong các khoảng thời gian và tần số khác nhau. Biến đổi Wavelet sử dụng các “wavelet mẹ” có độ dài hữu hạn và được dịch chuyển, co giãn tương ứng với các tần số khác nhau. Công thức của biến đổi Wavelet rời rạc:

$$DWT(f, m, n) = \frac{1}{\sqrt{m_0^x}} \sum_k f(k) \psi^* \left(\frac{y - km_0^x}{m_0^x} \right) \quad PT 2.20$$

Trong đó:

- $f(k)$: là tín hiệu gốc tại thời điểm k .
- $\psi^*(\cdot)$: Hàm wavelet phức liên hợp.
- m_0^x : hệ số tỉ lệ, lũy thừa của giá trị m_0 (thường là 2 trong DWT).
- y : vị trí hiện tại trong tín hiệu.

Biến đổi Wavelet rời rạc (DWT) thường phân rã tín hiệu thành các thành phần chi tiết D_i ở các dải tần số cao và một thành phần xấp xỉ A_i ở dải tần số thấp. Mỗi mức phân rã tương ứng với một dải tần số cụ thể.



Hình 2.8 Quá trình phân rã của DWT.

Bộ lọc thông cao $g[n]$: tạo tín hiệu chi tiết D_i .

$$D_i[n] = f(k) * 2^{i/2} g_i(k - 2^i n) \quad PT 2.21$$

Bộ lọc thông thấp $h[n]$: tạo tín hiệu xấp xỉ A_i .

$$A_i[n] = f(k) * 2^{i/2} h_i(k - 2^i n) \quad PT 2.22$$

Đối với tín hiệu PPG, việc phân tích Wavelet có thể giúp tách biệt các thành phần nhiễu tần số cao, các thành phần liên quan đến nhịp tim, và các thành phần tần số thấp liên quan đến hô hấp hoặc các biến động sinh lý khác. Từ các hệ số Wavelet này, có thể tính toán các đặc trưng thống kê để định lượng hình dạng và phân bố của chúng. Một đặc trưng quan trọng là Kurtosis.

Kurtosis là một thước đo về “độ nhọn” hoặc “độ phẳng” của phân bố xác suất của một tập dữ liệu, so với phân bố chuẩn. Nó cho biết mức độ tập trung của các giá trị xung quanh giá trị trung bình và tần suất xuất hiện của các giá trị ngoại lai.

Công thức Kurtosis được tính toán như sau:

$$K_x(a) = \frac{E[(x - \mu)^4]}{(\sigma^2)^2} - 3 \quad PT 2.23$$

Trong đó:

- $E[\cdot]$: là kỳ vọng toán học.
- μ : là trung bình của tập dữ liệu.
- σ : là độ lệch chuẩn của tập dữ liệu.
- Giá trị -3 là để chuẩn hóa sao cho Kurtosis của phân bố chuẩn bằng 0.

Bảng 2.6 Đặc trưng từ biến đổi Wavelet.

KD1	Kurtosis D1	Độ nhọn thành phần chi tiết mức cao nhất (nhiều cao).
KD2	Kurtosis D2	Độ nhọn chi tiết mức cao hơn.
KD3	Kurtosis D3	Độ nhọn chi tiết mức trung bình.
KA4	Kurtosis A4	Độ nhọn thành phần xấp xỉ mức thấp nhất (tần số thấp).


Trong đồ án này, em thực hiện tính Kurtosis cho các thành phần chi tiết và xấp xỉ ở các mức phân rã khác nhau:

- Kurtosis D1: Kurtosis của các hệ số chi tiết ở mức phân rã 1. Mức này thường chứa các thành phần tần số cao nhất của tín hiệu, có thể liên quan đến nhiễu hoặc các chi tiết nhỏ của sóng PPG.
- Kurtosis D2: Kurtosis của các hệ số chi tiết ở mức phân rã 2 chứa các tần số thấp hơn D1, có thể liên quan đến các đặc điểm nhịp tim chính hoặc các biến đổi nhanh.
- Kurtosis D3: Mức này chứa các tần số thấp hơn D2, có thể liên quan đến các thành phần nhịp tim ổn định hơn hoặc cách ảnh hưởng của hô hấp.
- Kurtosis A4: Kurtosis của các hệ số xấp xỉ ở mức phân rã A4. Thành phần xấp xỉ này chứa các tần số rất thấp của tín hiệu gốc, thường phản ánh xu hướng chung hoặc các thành phần baseline wander chậm. Kurtosis ở đây có thể phản ánh sự ổn định của đường nền tín hiệu.

2.4.4 Đặc trưng phi tuyến trong không gian pha

Phân tích các đặc trưng phi tuyến trong không gian pha là một phương pháp tiên tiến để khám phá động lực học tiềm ẩn của hệ thống sinh học, vượt ra ngoài các phân tích thống kê tuyến tính thông thường. Tín hiệu PPG, với tính chất phức tạp và động, thường được coi là biểu hiện của một hệ thống động lực phi tuyến. Để phân tích các đặc trưng này, bước đầu tiên là tái tạo không gian pha từ chuỗi thời gian một chiều của tín hiệu PPG bằng phương pháp nhúng trễ (delay embedding).

Quy trình tái tạo không gian pha được dựa trên Định lý nhúng của Takens, một lý thuyết nền tảng trong lĩnh vực hệ động lực phi tuyến. Định lý này khẳng định rằng, dưới những điều kiện nhất định, động lực học của một hệ thống phức tạp có thể được tái tạo từ một chuỗi thời gian đơn lẻ của một biến đo được từ hệ thống đó.




Hình 2.9 Tổng quan tái tạo không gian pha.

Để thực hiện điều này, một chuỗi thời gian $x(t)$ có thể được nhúng vào không gian pha m chiều bằng cách tạo ra các vector trạng thái theo công thức:

$$X(t) = [x(t), x(t + \tau), x(t + 2\tau), \dots, x(t + (m - 1)\tau)] \quad PT 2.24$$

Trong công thức này:

- $x(t)$: là giá trị của tín hiệu PPG tại thời điểm i .
- τ : là thời gian trễ. Giá trị này quyết định khoảng cách thời gian giữa các tọa độ trong không gian pha.
- m : là số chiều nhúng. Đây là số lượng tọa độ cần thiết để mở ra attractor của hệ thống, loại bỏ các giao cắt giả và đảm bảo rằng attractor tái tạo có cùng tính chất động học với attractor gốc.



Hình 2.10 Phân tích phi tuyến PPG trong không gian pha.

Việc chọn τ và m phù hợp là rất quan trọng để tái tạo chính xác attractor của hệ thống. Theo định lý của Takens, nếu $m > 2D_A$, với D_A là chiều phân số của attractor gốc, thì attractor tái tạo sẽ bảo toàn các tính chất động học của hệ thống ban đầu. Tuy nhiên trong thực tế, D_A thường không biết trước, do đó cần các phương pháp để ước lượng τ và m một cách tối ưu từ dữ liệu.

Từ không gian pha tái tạo, các đặc trưng phi tuyến ở Bảng 2.7 sẽ được tính toán để phân tích sâu hơn động học của tín hiệu PPG.

Bảng 2.7 Đặc trưng phi tuyến.

MI	Mutual Information	Mức độ thông tin lặp lại giữa các mẫu cách nhau khoảng thời gian delay.
FNN	False Nearest Neighbors	Đánh giá số chiều không gian tối ưu để mô tả đầy đủ động lực học của tín hiệu.
LE	Lyapunov Exponent	Chỉ số cho biết tính không ổn định và phi tuyến trong tín hiệu; giá trị dương cho thấy tính hỗn loạn.
ARE	Attractor Reconstruction Error	Phản ánh mức độ chính xác của mô hình tái tạo không gian pha.

DFA	Detrended Fluctuation Analysis	Đánh giá phi tuyến và tự tương quan trong tín hiệu PPG.
-----	--------------------------------	---

Thông tin tương hỗ (MI) là một thước đo phi tuyến tính về mức độ phụ thuộc giữa hai biến ngẫu nhiên. Trong ngữ cảnh của tái tạo không gian pha, MI được sử dụng để xác định thời gian trễ τ tối ưu. Giá trị τ được chọn là điểm đầu tiên mà MI đạt cực tiểu cục bộ. Điều này cho thấy rằng $x(t)$ và $x(t + \tau)$ cung cấp lượng thông tin mới lớn nhất cho nhau, đảm bảo các tọa độ trong không gian pha không bị trùng lặp quá nhiều hoặc quá ít thông tin. MI được định nghĩa theo công thức:

$$MI = I(X; Y) = \iint p(x, y) \log \left(\frac{p(x, y)}{p(x)p(y)} \right) dx dy \quad PT 2.25$$

ở đây, $p(x, y)$ là phân phối xác suất đồng thời của X và Y . $p(x)$, $p(y)$ là phân phối xác suất biên.

Phương pháp FNN là một phương pháp để xác định số chiều nhúng m tối ưu. Ý tưởng là khi một điểm dữ liệu được chiếu từ không gian chiều cao hơn xuống không gian chiều thấp hơn, các điểm vốn xa nhau có thể trở nên gần nhau một cách giả tạo. Thuật toán FNN tìm kiếm số chiều m mà tại đó tỷ lệ các “láng giềng gần sai” giảm xuống dưới một ngưỡng nhất định. Một giá trị m phù hợp sẽ “mở ra” attractor trong không gian pha, loại bỏ các giao cắt giả do chiếu từ chiều cao xuống, đảm bảo rằng cấu trúc của attractor được tái tạo một cách trung thực. Nếu chọn m quá nhỏ sẽ gây méo mó cấu trúc, làm sai lệch phân tích. Chọn m quá lớn sẽ gây tốn kém tính toán và dữ liệu thừa thớt, tăng ảnh hưởng nhiễu. Thuật toán FNN được thể hiện qua các bước ở Bảng 2.8:

Bảng 2.8 Thuật toán False Nearest Neighbors.

Bước	Mô tả
1	Khởi tạo với chiều nhúng $m = 1$.
2	Với mỗi x_i , tìm lân cận gần nhất x_j . Tính $R_i(m)$.
3	Tăng $m \rightarrow m + 1$, thêm $x_{i+m\tau}$.
4	Tính $R_i(m + 1)^2 = R_i(m)^2 + (x_{i+m\tau} - x_{j+m\tau})^2$.
5	Nếu $\frac{ x_{i+m\tau} - x_{j+m\tau} }{R_i(m)} > R_{tol}$, thì x_j là lân cận giả.
6	Tính tỷ lệ lân cận giả.
7	Lặp lại với m tăng dần cho đến khi tỷ lệ $< R_{tol}$.

Số mũ Lyapunov (LE) là một thước đo định lượng về tính hỗn loạn trong một hệ thống động lực. Nó đo lường tốc độ trung bình mà các quỹ đạo lân cận trong không gian pha phân kỳ hoặc hội tụ theo thời gian.

- Nếu $LE > 0$ cho thấy hệ thống có tính hỗn loạn, tức là các thay đổi nhỏ trong điều kiện ban đầu có thể dẫn đến sự khác biệt lớn về trạng thái sau này, đặc trưng cho các hệ thống phức tạp và phi tuyến.
- Nếu $LE < 0$ cho thấy hệ thống hội tụ về một điểm hút cố định.
- Nếu $LE = 0$ cho thấy hệ thống ở trạng thái chu kỳ.

LE được định nghĩa theo công thức:

$$\lambda = \frac{1}{\Delta t} \left\langle \ln \left(\frac{d_i(t)}{d_i(0)} \right) \right\rangle \quad PT 2.26$$

Trong đó:

- $d_i(0)$ là khoảng cách ban đầu giữa cặp điểm lân cận trong không gian pha.
- $d_i(t)$ là khoảng cách sau thời gian t .
- $\langle \cdot \rangle$: là trung bình trên tất cả các cặp lân cận.
- Δt : là bước thời gian lấy mẫu.

Sai số tái tạo Attractor (ARE) đo lường mức độ khớp giữa quỹ đạo tái tạo và quỹ đạo thực sự của hệ thống. Trong một số ngữ cảnh, một phiên bản của ARE có thể được dùng để đánh giá mức độ “mượt mà” hoặc “tính liên tục” của attractor được tái tạo, phản ánh chất lượng của tín hiệu hoặc sự ổn định của hệ thống sinh học. Nếu có thể tính được, ARE cao có thể chỉ ra tín hiệu nhiễu hoặc hệ thống có động lực bất thường. Sai số tái tạo ARE được tính bằng sai số trung bình bình phương:

$$ARE = \frac{1}{N} \sum_{i=1}^N (x_{i+(m-1)\tau} - \hat{x}_{i+(m-1)\tau})^2 \quad PT 2.27$$

Trong đó, $\hat{x}_{i+(m-1)\tau}$ là giá trị dự đoán tiếp theo từ không gian pha sử dụng K hàng xóm gần nhất (KNN), với NN_j là chỉ số của hàng xóm gần nhất thứ j của X_i :

$$\hat{x}_{i+(m-1)\tau} = \frac{1}{K} \sum_{j=1}^K x_{NN_j+(m-1)\tau} \quad PT 2.28$$

DFA – Phân tích dao động khứ xu hướng là một kỹ thuật mạnh mẽ để xác định tự tương quan và phụ thuộc dài hạn trong các chuỗi thời gian không dừng, thường được sử dụng trong các hệ thống sinh học. Nó đo lường mối quan hệ giữa độ lớn của các biến động và kích thước của cửa sổ thời gian. Kết quả của DFA là một chỉ số tỷ lệ α :

- $\alpha = 0.5$: tương ứng với nhiễu trắng.
- $\alpha = 1.0$: tương ứng với nhiễu $1/f$, đặc trưng cho các hệ thống phức tạp có tính phụ thuộc dài hạn.
- $\alpha = 1.5$: tương ứng với chuyển động Brownian, hoặc sự tích hợp của nhiễu trắng.

Quy trình tính toán DFA:

Bảng 2.9 Thuật toán Detrended Fluctuation Analysis.

Bước	Mô tả
1	Tính tổng tích lũy sau khi trừ trung bình: $Y(k) = \sum_{i=1}^k (x(i) - \bar{x})$.
2	Chia chuỗi $Y(k)$ thành các đoạn không chồng lấp có độ dài s .
3	Trong mỗi đoạn, khớp một xu hướng cục bộ Y_{fit} bằng hồi quy đa thức (thường là bậc 1).
4	Tính độ dao động $F(n) = \sqrt{\frac{1}{N} \sum_{k=1}^N (Y(k) - Y_n(k))^2}$.
5	Lặp lại với các giá trị s khác nhau, vẽ đồ thị $\log F(s)$ theo $\log(s)$ và ước lượng hệ số DFA (α) bằng độ dốc.

2.5 Kết luận chương

Chương này đã cung cấp cơ sở lý thuyết quan trọng về tín hiệu PPG, từ nguồn gốc sinh lý, đặc điểm, cách thu nhận đến các bước xử lý và trích xuất đặc trưng. Đồng thời, các thang đo buồn ngủ được giới thiệu như công cụ gắn nhãn dữ liệu phục vụ huấn luyện mô hình. Những nội dung này là nền tảng cần thiết để xây dựng hệ thống nhận diện buồn ngủ thời gian thực.

CHƯƠNG 3. MÔ HÌNH HỌC MÁY

Sau khi trích xuất các đặc trưng từ tín hiệu PPG, các vector đặc trưng sẽ được sử dụng làm đầu vào cho mô hình học máy nhằm phân loại trạng thái tỉnh táo hoặc buồn ngủ của người lái xe. Việc lựa chọn mô hình phù hợp đóng vai trò quan trọng để đảm bảo độ chính xác, độ tin cậy và khả năng hoạt động trong thời gian thực.

3.1 Tổng quan về học máy (Machine Learning)

Học máy là một nhánh của trí tuệ nhân tạo (AI), cho phép hệ thống từ dữ liệu quá khứ để dự đoán hoặc đưa ra quyết định cho dữ liệu mới. Trong bài toán này, học máy được sử dụng để dự đoán trạng thái buồn ngủ/tỉnh táo dựa trên các đặc trưng sinh lý thu được từ tín hiệu PPG.

3.1.1 Các loại mô hình học máy chính

1. Học có giám sát (Supervised Learning):

- Định nghĩa: Học từ dữ liệu đã được gán nhãn (có input và output mong muốn).
- Mục tiêu: Dự đoán output cho dữ liệu mới.
- Ví dụ:
 - Phân loại (Classification): Phân loại email spam/không spam, nhận diện hình ảnh chó/mèo.
 - Hồi quy (Regression): Dự đoán giá nhà, dự đoán nhiệt độ, dự đoán thời tiết.

2. Học không giám sát (Unsupervised Learning):

- Định nghĩa: Học từ dữ liệu chưa được gán nhãn, tìm kiếm cấu trúc ẩn trong dữ liệu.
- Mục tiêu: Khám phá các mẫu, cấu trúc hoặc nhóm trong dữ liệu.
- Ví dụ:
 - Phân cụm (Clustering): Phân nhóm khách hàng dựa trên hành vi mua sắm, nhóm tài liệu theo chủ đề.
 - Giảm chiều dữ liệu (Dimensionality Reduction): Trực quan hóa dữ liệu phức tạp.

3. Học tăng cường (Reinforcement Learning):

- Định nghĩa: Một tác nhân học cách đưa ra quyết định thông qua tương tác với môi trường, nhận phần thưởng hoặc hình phạt.
- Mục tiêu: Tối đa hóa tổng phần thưởng tích lũy.
- Ví dụ: Chơi game, điều khiển robot tự động, hệ thống tự lái.

3.1.2 Các bước chính trong quy trình học máy

Quy trình triển khai thuật toán học máy thường bao gồm 6 bước:

Bước 1: Thu thập dữ liệu.

Đây là bước khởi đầu quan trọng nhất, cần thu thập tất cả dữ liệu liên quan đến vấn đề muốn mô hình học máy giải quyết. Dữ liệu có thể đến từ nhiều nguồn khác nhau:

- Cơ sở dữ liệu: SQL, NoSQL.
- File: CSV, Excel, JSON, XML, Parquet.
- API: Từ các dịch vụ web.
- Web scraping: Thu thập dữ liệu từ các trang web.
- Cảm biến/thiết bị IoT: Dữ liệu thời gian thực.
- Bộ dữ liệu công khai từ các nguồn.

Mục tiêu: Đảm bảo dữ liệu thu thập đủ lớn, đa dạng và đại diện cho vấn đề thực tế để mô hình có thể học được các quy luật tổng quát.

Bước 2: Tiền xử lý dữ liệu

Dữ liệu thô hiếm khi sạch sẽ và sẵn sàng để sử dụng ngay. Bước này là vô cùng quan trọng để chuẩn bị dữ liệu cho quá trình huấn luyện, đảm bảo mô hình hoạt động hiệu quả nhất.

- Làm sạch dữ liệu: Xử lý các lỗi, thiếu sót, nhiễu và dữ liệu không nhất quán.
- Trích xuất dữ liệu: Lấy ra các thuộc tính cụ thể từ nguồn dữ liệu thô cần cho mô hình.
- Chuyển đổi dữ liệu: Chuyển đổi dữ liệu sang một định dạng hoặc cấu trúc phù hợp hơn cho mô hình học máy.
- Chuẩn hóa dữ liệu: Đưa các đặc trưng có thang đo khác nhau về cùng một thang đo chuẩn, ngăn chặn các đặc trưng có giá trị lớn hơn chi phối quá trình học.

Bước 3: Phân tích dữ liệu

Hiểu rõ hơn về cấu trúc, mối quan hệ và phân phối của dữ liệu:

- Thống kê mô tả: Tính toán trung bình, trung vị, độ lệch chuẩn, min, max để tóm tắt dữ liệu.
- Trực quan hóa dữ liệu: Sử dụng biểu đồ (biểu đồ phân bố, biểu đồ cột, biểu đồ tán xạ,...) để phát hiện xu hướng, mối quan hệ, ngoại lệ và các mẫu ẩn trong dữ liệu.
- Phân tích mối tương quan: Xác định mối quan hệ giữa các đặc trưng và giữa các đặc trưng với biến mục tiêu.

Giúp lựa chọn thuật toán phù hợp, xử lý đặc trưng hiệu quả và xác định các vấn đề tiềm ẩn của dữ liệu.

Bước 4: Xây dựng mô hình học máy

Lựa chọn thuật toán học máy phù hợp nhất với vấn đề và kiến trúc mô hình ban đầu.

- Lựa chọn thuật toán: Dựa trên loại bài toán (phân loại, hồi quy, phân cụm,...), kích thước dữ liệu, và yêu cầu về hiệu suất/khả năng giải thích.
- Chia tập dữ liệu: Chia dữ liệu thành các tập con:
 - Tập huấn luyện: Dùng để huấn luyện mô hình (thường chiếm 70-80% dữ liệu).

- Tập kiểm tra: Dùng để đánh giá hiệu suất cuối cùng của mô hình trên dữ liệu chưa từng thấy (thường chiếm 20-30%).
- Tập xác thực: Dùng để tinh chỉnh các siêu tham số của mô hình trong quá trình huấn luyện, tránh overfitting.
- Khởi tạo mô hình: Khởi tạo một phiên bản của thuật toán đã chọn với các tham số ban đầu.

Bước 5: Huấn luyện mô hình

Đây là mô hình thực sự “học” từ dữ liệu. Điều chỉnh các tham số nội tại của mô hình để tối thiểu hóa lỗi dự đoán trên tập huấn luyện.

- Mô hình được đưa qua tập dữ liệu huấn luyện.
- Trong quá trình này, mô hình sẽ cố gắng tìm ra các mẫu và mối quan hệ giữa các đặc trưng đầu vào và biến mục tiêu đầu ra.
- Sử dụng hàm mất mát để đo lường mức độ sai khác giữa dự đoán của mô hình và giá trị thực tế.
- Sử dụng một thuật toán tối ưu hóa để điều chỉnh các tham số của mô hình theo hướng giảm thiểu hàm mất mát. Quá trình này lặp đi lặp lại qua nhiều epoch (số lần toàn bộ dữ liệu huấn luyện được đưa qua mô hình).

Bước 6: Đánh giá mô hình


Đo lường hiệu suất của mô hình trên dữ liệu mới để đảm bảo mô hình có khả năng tổng quát hóa tốt và không bị học vẹt trên dữ liệu huấn luyện.

Các chỉ số đánh giá phổ biến:

- Đối với bài toán phân loại:
 - Độ chính xác (Accuracy): Tỷ lệ dự đoán đúng.
 - Độ chuẩn xác (Precision): Tỷ lệ dự đoán dương đúng trong tổng số dự đoán dương.
 - Độ phủ (Recall): Tỷ lệ dự đoán dương đúng trong tổng số các trường hợp dương thực tế.
 - F1-Score: Trung bình điều hòa của Precision và Recall.
 - Ma trận nhầm lẫn (Confusion Matrix): Bảng tóm tắt các dự đoán đúng sai.
 - Đường cong ROC và AUC: Đánh giá khả năng phân loại.
- Đối với bài toán hồi quy:
 - Sai số trung bình tuyệt đối (MAE – Mean Absolute Error).
 - Sai số bình phương trung bình (MSE – Mean Squared Error).
 - Căn bậc hai của sai số bình phương trung bình (RMSE – Root Mean Squared Error).
 - R-squared (R^2): Hệ số xác định, đo lường mức độ phù hợp của mô hình với dữ liệu.

Kiểm định chéo (Cross – validation): Một kỹ thuật phổ biến để đánh giá độ bền vững của mô hình bằng cách chia dữ liệu thành nhiều phần và huấn luyện/kiểm tra mô hình nhiều lần.

Dựa trên kết quả đánh giá, có thể quyết định liệu mô hình đã đủ tốt để triển khai, hay cần quay lại các bước trước để cải thiện hiệu suất.




Hình 3.1 Quy trình triển khai thuật toán học máy.

3.2 Các mô hình học máy được sử dụng

Trong đề án này, ba thuật toán học máy phổ biến đã được lựa chọn để xây dựng và đánh giá khả năng phát hiện trạng thái buồn ngủ dựa trên các đặc trưng được trích xuất từ tín hiệu PPG, gồm: K-Nearest Neighbors (KNN), Support Vector Machine (SVM), và Random Forest (RF). Các mô hình được lựa chọn dựa trên tính phù hợp với bài toán phân loại và khả năng xử lý dữ liệu không tuyến tính, nhiều chiều.

3.2.1 K-Nearest Neighbors (KNN)

3.2.1.1. Tổng quan



Hình 3.2 Thuật toán K - Nearest Neighbors.

KNN là một thuật toán học máy phi tham số đơn giản nhưng hiệu quả được sử dụng cho cả bài toán phân loại và hồi quy. KNN không học một mô hình chung từ dữ liệu huấn luyện mà thay vào đó, nó ghi nhớ toàn bộ tập dữ liệu huấn luyện. Khi có một điểm dữ liệu mới cần dự đoán, KNN tìm kiếm 'k' điểm dữ liệu gần nhất trong tập huấn luyện và đưa ra dự đoán dựa trên sự đa số của

các nhãn (đối với phân loại) hoặc giá trị trung bình (đối với hồi quy) của ‘k’ điểm đó. “Phi tham số” có nghĩa là nó không giả định về phân phối của dữ liệu.

Thuật toán KNN chủ yếu dựa vào các phép đo khoảng cách để xác định “sự gần gũi” giữa các điểm dữ liệu. Các công thức khoảng cách phổ biến bao gồm:

- Khoảng cách Euclidean: Đây là công thức phổ biến nhất, tính khoảng cách đường thẳng giữa hai điểm trong không gian pha đa chiều. Giả sử có hai điểm $P_1 = (x_{11}, x_{12}, \dots, x_{1n})$ và $P_2 = (x_{21}, x_{22}, \dots, x_{2n})$ thì:

$$d(P_1, P_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2} \quad PT\ 3.1$$

- Khoảng cách Manhattan: Tính tổng các giá trị tuyệt đối của sự khác biệt giữa các tọa độ.

$$d(P_1, P_2) = \sum_{i=1}^n |x_{1i} - x_{2i}| \quad PT\ 3.2$$

- Khoảng cách Minkowski: Đây là dạng tổng quát của khoảng cách Euclidean (khi $p = 2$) và Manhattan (khi $p = 1$).

$$d(P_1, P_2) = \left(\sum_{i=1}^n |x_{1i} - x_{2i}|^p \right)^{1/p} \quad PT\ 3.3$$

3.2.1.2. Thuật toán

Mô hình KNN thực hiện theo từng bước sau:

Bước 1: Khởi tạo

- Chọn giá trị cho K (số lượng láng giềng gần nhất). Giá trị K thường là số lẻ để tránh trường hợp hòa phiếu trong phân loại nhị phân.
- Có một tập dữ liệu huấn luyện đã được gán nhãn.

Bước 2: Tính khoảng cách

- Với mỗi điểm dữ liệu mới, tính khoảng cách từ điểm này đến tất cả các điểm dữ liệu trong tập huấn luyện.

Bước 3: Tìm kiếm K láng giềng gần nhất

- Sắp xếp khoảng cách đã tính theo thứ tự tăng dần.
- Chọn K điểm dữ liệu từ tập huấn luyện có khoảng cách nhỏ nhất đến điểm dữ liệu mới. Đây chính là các láng giềng gần nhất.

Bước 4: Dự đoán (Phân loại hoặc Hồi quy)

- Đối với bài toán phân loại: Lấy nhãn của điểm dữ liệu mới bằng cách lấy phiếu bầu đa số từ K láng giềng đã chọn. Nhãn xuất hiện nhiều nhất trong số K láng giềng sẽ là nhãn dự đoán cho điểm mới.
- Đối với bài toán hồi quy: Giá trị dự đoán cho điểm dữ liệu mới là giá trị trung bình (hoặc trung vị) của các giá trị của K láng giềng gần nhất.

Bước 5: Kết thúc

- Điểm dữ liệu mới đã được gán nhãn/dự đoán.

3.2.1.3. Ví dụ đơn giản

Giả sử chúng ta có một tập dữ liệu nhỏ về các loại trái cây dựa trên hai đặc trưng: độ ngọt và độ giòn.

Bảng 3.1 Ví dụ đơn giản thuật toán KNN.

Trái cây	Độ ngọt	Độ giòn	Loại
Táo 1	7	8	Táo
Táo 2	6	7	Táo
Chuối 1	9	2	Chuối
Chuối 2	8	3	Chuối
Xoài 1	5	6	Xoài
Xoài 2	4	7	Xoài

Bây giờ, chúng ta có một trái cây mới với độ ngọt là 6 và độ giòn là 5. Chúng ta muốn phân loại nó là loại trái cây nào.

Với $K = 3$ và sử dụng khoảng cách Euclidean:

- Tính khoảng cách từ điểm mới (6, 5) đến từng điểm dữ liệu hiện có:
 - Táo 1 (7, 8): $\sqrt{(6-7)^2 + (5-8)^2} = \sqrt{10} \approx 3.16$
 - Táo 2 (6, 7): $\sqrt{(6-6)^2 + (5-7)^2} = \sqrt{4} = 2$
 - Chuối 1 (9, 2): $\sqrt{(6-9)^2 + (5-2)^2} = \sqrt{18} \approx 4.24$
 - Chuối 2 (8, 3): $\sqrt{(6-8)^2 + (5-3)^2} = \sqrt{8} \approx 2.83$
 - Xoài 1 (5, 6): $\sqrt{(6-5)^2 + (5-6)^2} = \sqrt{2} \approx 1.41$
 - Xoài 2 (4, 7): $\sqrt{(6-4)^2 + (5-7)^2} = \sqrt{8} \approx 2.83$
- Sắp xếp các khoảng cách tăng dần và chọn 3 láng giềng gần nhất:
 - Xoài 1 (1.41) – Loại: Xoài
 - Táo 2 (2) – Loại: Táo
 - Chuối 2 (2.83) – Loại: Chuối hoặc Xoài 2 (2.83) – Loại: Xoài
- Lấy phiếu bầu đa số:
 - Với láng giềng là Xoài 1, Táo 2, Chuối 2: 1 Xoài, 1 Táo, 1 Chuối (không có đa số, cần xem lại K hoặc cách xử lý tie)
 - Với láng giềng là Xoài 1, Táo 2, Xoài 2: 1 Táo, 2 Xoài thì đa số là “Xoài”.

Vậy trái cây mới có thể được phân loại là Xoài.

3.2.1.4. Ưu và nhược điểm

Ưu điểm:

- Đơn giản và dễ hiểu: KNN là một trong những thuật toán học máy cơ bản nhất, dễ dàng triển khai.
- Không có giai đoạn huấn luyện rõ ràng: KNN không cần huấn luyện mô hình trước. Quá trình học xảy ra khi có truy vấn dự đoán.
- Không có giả định về phân phối dữ liệu: Phù hợp với dữ liệu có phân phối phức tạp, không tuyến tính.

- Hiệu quả cho dữ liệu nhỏ: Hoạt động tốt trên các tập dữ liệu có số lượng mẫu nhỏ.

Nhược điểm:

- Tính toán tốn kém: Chi phí tính toán tăng đáng kể khi kích thước tập dữ liệu lớn vì cần tính toán khoảng cách đến tất cả các điểm huấn luyện.
- Nhạy cảm với dữ liệu nhiễu và ngoại lai: Một vài điểm nhiễu có thể làm sai lệch kết quả dự đoán nếu chúng nằm trong K láng giềng gần nhất.
- Nhạy cảm với thang đo của đặc trưng: Các đặc trưng có giá trị lớn hơn sẽ có ảnh hưởng lớn hơn đến khoảng cách, do đó cần chuẩn hóa dữ liệu.
- Khó xác định giá trị K tối ưu: Việc chọn K ảnh hưởng lớn đến hiệu suất mô hình. Giá trị K nhỏ có thể dẫn đến nhiễu, trong khi K lớn có thể dẫn đến việc bỏ qua các ranh giới lớp.
- Không hoạt động tốt với dữ liệu có số chiều cao: Khi số lượng đặc trưng tăng lên, khoảng cách giữa các điểm trở nên gần nhau hơn, làm giảm hiệu quả của các phép đo khoảng cách.


3.2.1.5. Ứng dụng trong nghiên cứu

Trong phát hiện buồn ngủ dựa trên tín hiệu PPG, KNN có thể được sử dụng để phân loại trạng thái buồn ngủ dựa trên các đặc trưng được trích xuất từ tín hiệu PPG:

- Khi có dữ liệu PPG mới từ một đối tượng, các đặc trưng tương tự sẽ được trích xuất.
- KNN sẽ tính toán khoảng cách từ vector đặc trưng mới này đến tất cả các vector đặc trưng đã học.
- Chọn K vector gần nhất.
- Dựa trên phiếu bầu đa số của các nhãn trạng thái buồn ngủ từ K láng giềng này, KNN sẽ phân loại trạng thái hiện tại của đối tượng.

3.2.2 Support Vector Machines (SVM)

3.2.2.1. Tổng quan



Hình 3.3 Thuật toán Support Vector Machines.

SVM là một thuật toán học máy có giám sát mạnh mẽ, được sử dụng chủ yếu cho các bài toán phân loại và cũng có thể mở rộng cho các bài toán hồi quy (Support Vector Regression – SVR). Ý tưởng cốt lõi của SVM là tìm một siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu trong không gian đặc trưng. Siêu phẳng này được chọn sao cho nó có biên độ (margin) lớn nhất giữa các lớp. Các điểm dữ liệu gần nhất với siêu phẳng này, nằm trên ranh giới của biên độ, được gọi là Support Vectors; chính những điểm này đóng vai trò quan trọng trong việc xác định vị trí của siêu phẳng. SVM đặc biệt hiệu quả trong các không gian có chiều cao và khi có sự phân tách rõ ràng giữa các lớp.

Trong không gian hai chiều, một siêu phẳng là một đường thẳng. Trong không gian ba chiều, đó là một mặt phẳng. Tổng quát hơn, trong không gian n chiều, đó là một không gian con $(n - 1)$ chiều.

Một siêu phẳng tuyến tính có thể được biểu diễn bằng phương trình:

$$w \cdot x - b = 0 \quad \text{PT 3.4}$$

Trong đó:

- w là vector trọng số vuông góc với siêu phẳng.
- x là vector đặc trưng của điểm dữ liệu.
- b là độ lệch, xác định vị trí của siêu phẳng.

Đối với một điểm dữ liệu x , hàm quyết định của SVM là:

$$f(x) = \text{sign}(w \cdot x - b) \quad \text{PT 3.5}$$

Nếu $f(x) \geq 0$, điểm thuộc lớp $+1$. Nếu $f(x) < 0$, điểm thuộc lớp -1 .

Mục tiêu của SVM là tối đa hóa biên độ giữa các lớp. Biên độ là khoảng cách giữa siêu phẳng phân tách và các siêu phẳng hỗ trợ đi qua các Support Vectors.

Các siêu phẳng hỗ trợ được định nghĩa là:

$$w \cdot x - b = 1 \text{ (cho lớp +1)}$$

$$w \cdot x - b = -1 \text{ (cho lớp -1)}$$

Khoảng cách từ một điểm x_i đến siêu phẳng $w \cdot x - b = 0$ là:

$$d = \frac{|w \cdot x_i - b|}{\|w\|} \quad PT 3.6$$

Biên độ giữa hai siêu phẳng hỗ trợ là $2/\|w\|$.

Mục tiêu của SVM là tối đa hóa $2/\|w\|$, với điều kiện:

$y_i(w \cdot x_i - b) \geq 1$ cho tất cả các điểm dữ liệu (x_i, y_i) , trong đó $y_i \in \{-1, 1\}$ là nhãn lớp.

Trong thực tế, dữ liệu thường không thể phân tách tuyến tính hoàn hảo. SVM sử dụng biến trượt (slack) $\xi_i \geq 0$ để cho phép một số điểm dữ liệu nằm sai phía của biên độ hoặc thậm chí nằm sai phía của siêu phẳng.

Mục tiêu tối ưu hóa trở thành: $\min (\|w\| + C \sum_{i=1}^n \xi_i)$, với điều kiện:

$$\begin{cases} y_i(w \cdot x_i - b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$


Hằng số $C > 0$ là tham số điều hòa kiểm soát sự đánh đổi giữa việc tối đa hóa biên độ và giảm thiểu lỗi phân loại. C lớn hơn nghĩa là chấp nhận ít lỗi hơn, C nhỏ hơn nghĩa là chấp nhận nhiều lỗi hơn.

Khi dữ liệu không thể phân tách tuyến tính trong không gian ban đầu, SVM sử dụng hàm kernel để ánh xạ dữ liệu sang một không gian có chiều cao hơn, nơi mà chúng có thể phân tách tuyến tính. Hàm kernel tính toán tích vô hướng của các vector trong không gian chiều cao mà không cần thực sự ánh xạ các vector đó:

$$K(x, z) = \langle \phi(x), \phi(z) \rangle \quad PT 3.7$$

$K(x, z)$ là một hàm nhân. Một số hàm nhân thường dùng

- Polynomial: $K(x, z) = (\langle x, z \rangle + \theta)^d$
- Gaussian RBF: $K(x, z) = e^{-\frac{\|x-z\|^2}{2\sigma}}; \sigma > 0$
- Sigmoidal: $K(x, z) = \tanh(\beta \langle x, z \rangle - \lambda) = \frac{1}{1+e^{-(\beta \langle x, z \rangle - \lambda)}}; \beta, \lambda \in R$



Hình 3.4 Chuyển đổi dữ liệu với SVM.

3.2.2.2. Thuật toán

Chi tiết thuật toán SVM theo từng bước:

Bước 1: Chọn Kernel

Xác định hàm kernel phù hợp với bản chất của dữ liệu.

- Polynominal Kernel: Phù hợp khi có mối quan hệ đa thức giữa các đặc trưng.
- RBF Kernel: Phổ biến nhất, hoạt động tốt với dữ liệu không phân tách tuyến tính, có thể ánh xạ dữ liệu vào không gian chiều cao vô hạn.
- Sigmoidal Kernel: Ít phổ biến hơn và thường không hoạt động tốt bằng RBF.

Bước 2: Xây dựng mô hình SVM

- Tối ưu hóa bài toán: SVM giải quyết bài toán tối ưu hóa lồi để tìm siêu phẳng tối ưu. Mục tiêu là tối đa hóa $2/\|w\|$ đồng thời thỏa mãn các ràng buộc phân loại đúng và biên trượt.
- Sử dụng các thuật toán tối ưu hóa như Quadratic Programming (QP) để tìm các tham số w và b , và các nhân tử Lagrange. Các nhân tử Lagrange khác 0 tương ứng với các Support Vectors.

Bước 3: Huấn luyện mô hình

- Sử dụng tập dữ liệu huấn luyện đã được chuẩn bị, thuật toán tối ưu hóa sẽ tìm ra các giá trị w, b , và các Support Vectors. Quá trình này sẽ xác định vị trí của siêu phẳng phân tách và các siêu phẳng hỗ trợ.

Bước 4: Dự đoán (Phân loại):

- Với một điểm dữ liệu mới x_{new} , tính toán giá trị của hàm quyết định: $f(x_{new}) = w \cdot x_{new} - b$ (hoặc sử dụng kernel nếu áp dụng).
- Nếu $f(x_{new}) \geq 0$, dự đoán thuộc lớp +1.
- Nếu $f(x_{new}) < 0$, dự đoán thuộc lớp -1.

3.2.2.3. Ví dụ đơn giản

Giả sử có 2 điểm dữ liệu 2D thuộc hai lớp khác nhau: A(2, 2) có nhãn +1, và B(4, 4) có nhãn -1. Mục tiêu của SVM là tìm một đường thẳng (siêu phẳng) sao cho khoảng cách từ đường thẳng đó đến điểm gần nhất của mỗi lớp là lớn nhất. Tìm đường siêu phẳng:

$$w_1x_1 + w_2x_2 + b = 0$$

Với SVM ta muốn: $y_i(w \cdot x_i - b) \geq 1$.

Áp dụng cho từng điểm:

1. Điểm A: $y = +1, x = [2, 2]$

$$(+1)(w_1 \cdot 2 + w_2 \cdot 2 + b) \geq 1 \Rightarrow 2w_1 + 2w_2 + b \geq 1 \quad (1)$$

2. Điểm B: $y = -1, x = [4, 4]$

$$(-1)(w_1 \cdot 4 + w_2 \cdot 4 + b) \geq 1 \Rightarrow -4w_1 - 4w_2 - b \geq 1 \quad (2)$$

SVM tối ưu: $\min \left(\frac{1}{2} \|w\|^2 \right) = \frac{1}{2} (w_1^2 + w_2^2)$ với điều kiện (1) và (2). Vì bài toán nhỏ, ta thử đoán giá trị w_1, w_2, b sao cho thỏa mãn hai điều kiện.

Giả sử: $w_1 = -1, w_2 = 1, b = 0$. Kiểm tra điều kiện:

- Với điểm A: $2(-1) + 2(1) + 0 = 0 < 1 \Rightarrow \text{Loại}$.

Thử $w_1 = -2, w_2 = 0.5, b = 4$:

- Điểm A: $2(-2) + 2(0.5) + 4 = 1$
- Điểm B: $-4(-2) - 4(0.5) - 4 = 2$

Hai điều kiện thỏa mãn $\Rightarrow$ đây là một nghiệm hợp lệ.

Vậy ta sẽ tìm được một siêu phẳng là: $-2x_1 + 0.5x_2 + 4 = 0$

3.2.2.4. Ưu và nhược điểm

Ưu điểm:

- Hiệu quả trong không gian có chiều cao: SVM hoạt động rất hiệu quả ngay cả khi số lượng đặc trưng lớn hơn số lượng mẫu.
- Sử dụng hiệu quả các Support Vectors: Chỉ một tập con của dữ liệu huấn luyện được sử dụng để xây dựng mô hình, giúp giảm độ phức tạp tính toán và bộ nhớ.
- Có khả năng mở rộng với hàm Kernel: Cho phép phân loại dữ liệu không phân tách tuyến tính bằng cách ánh xạ chúng sang không gian chiều cao hơn.
- Mạnh mẽ trước Overfitting: Khả năng tối đa hóa biên độ tổng thể giúp SVM có khả năng tổng quát hóa tốt.
- Hoạt động tốt với dữ liệu rõ ràng tách biệt: Nếu có một biên độ rõ ràng giữa các lớp, SVM thường rất mạnh mẽ.

Nhược điểm:

- Khó khăn khi lựa chọn tham số Kernel và tham số C: Hiệu suất của SVM phụ thuộc rất nhiều vào việc lựa chọn đúng hàm kernel và các tham số như C và σ . Việc tinh chỉnh tham số có thể tốn thời gian.
- Ít hiệu quả với tập dữ liệu lớn: Thời gian huấn luyện của SVM có thể tăng lên đáng kể với số lượng mẫu lớn, đặc biệt là với các kernel phi tuyến tính.
- Độ nhạy cảm với nhiễu và ngoại lai: Mặc dù Soft Margin SVM có thể xử lý nhiễu, nhưng nếu có quá nhiều nhiễu hoặc ngoại lai, chúng có thể trở thành Support Vectors và ảnh hưởng đáng kể đến siêu phẳng phân tách.

3.2.2.5. Ứng dụng trong nghiên cứu

SVM trong phát hiện buồn ngủ được thực hiện như sau:


- Chọn Kernel và tinh chỉnh tham số: Thường bắt đầu với RBF kernel do tính linh hoạt của nó. Sau đó, sử dụng các kỹ thuật như GridSearchCV hoặc RandomizedSearchCV để tìm các giá trị tối ưu cho C và σ để tối đa hóa hiệu suất phân loại trên tập validation.

- SVM sẽ tìm ra các siêu phẳng (hoặc siêu bề mặt trong không gian chiều cao) phân tách tốt nhất giữa các trạng thái.
- Khi có dữ liệu mới, các đặc trưng sẽ được trích xuất và chuẩn hóa.
- Mô hình SVM đã huấn luyện sẽ sử dụng vector đặc trưng này để dự đoán trạng thái buồn ngủ.

3.2.3 Random Forest (RF)

3.2.3.1. Tổng quan

Random Forest là một thuật toán học máy có giám sát mạnh mẽ được sử dụng phổ biến trong các bài toán phân loại và hồi quy. Ý tưởng chính của RF là xây dựng một “rừng” gồm nhiều cây quyết định (decision tree) độc lập, và sau đó tổng hợp kết quả dự đoán của từng cây để đưa ra dự đoán cuối cùng. Phương pháp này giúp giảm thiểu hiện tượng overfitting mà cây quyết định đơn lẻ thường gặp phải, đồng thời cải thiện độ chính xác và tính ổn định của mô hình. RF đạt được sự đa dạng giữa các cây thông qua hai kỹ thuật chính: bagging để lấy mẫu dữ liệu và ngẫu nhiên hóa lựa chọn đặc trưng trong quá trình xây dựng mỗi cây.



Hình 3.5 Thuật toán Random Forest.

Một cây quyết định trong RF thực hiện phân loại hoặc hồi quy bằng cách chia nhỏ không gian đặc trưng thành các vùng con. Với mỗi cây là một chuỗi các câu hỏi “có/không”. Mỗi câu hỏi này liên quan đến một đặc trưng cụ thể và một ngưỡng giá trị của đặc trưng đó.

Khi một điểm dữ liệu mới đi vào, cây sẽ đặt ra một câu hỏi về một đặc trưng cụ thể và một ngưỡng giá trị. Ví dụ: Đặc trưng X có nhỏ hơn hoặc bằng t không?

- Nếu $X \leq t$, điểm dữ liệu đi theo nhánh trái.
- Nếu $X > t$, điểm dữ liệu đi theo nhánh phải.

Quá trình này lặp lại đến khi điểm dữ liệu đến một nút lá. Nút lá này chính là nơi cây đưa ra dự đoán cuối cùng. Về cơ bản, mỗi cây đang chia không gian dữ liệu thành các vùng nhỏ hơn thông qua các quyết định nhị phân này, và mỗi vùng nhỏ đó tương ứng với một kết quả giá trị dự đoán.

Khi một cây quyết định cần “chia” dữ liệu tại một điểm nào đó, mục tiêu của nó là tạo ra các nhóm (nút con) “sạch” nhất có thể. “Sạch” ở đây có nghĩa là các mẫu trong nhóm đó càng giống nhau về lớp càng tốt.

Có hai công cụ để đo độ “không thuần khiết” của một nhóm:

- Chỉ số Gini: Giống như việc kiểm tra một túi kẹo có bao nhiêu loại kẹo khác nhau. Nếu tất cả đều là socola, túi đó là “sạch” (Gini = 0). Nếu có nhiều loại kẹo lẫn lộn thì Gini càng cao. Công thức tính chỉ số Gini cho một nút t :

$$Gini(t) = 1 - \sum_{i=1}^C p_i^2 \quad PT\ 3.8$$

Trong đó, p_i là xác suất của việc một mẫu thuộc lớp i tại nút t , và C là tổng số lớp.

- Entropy: Tương tự, nó đo lường sự hỗn loạn hoặc không chắc chắn. Một nhóm hoàn toàn hỗn loạn sẽ có Entropy cao, còn một nhóm “sạch” sẽ có Entropy thấp (bằng 0). Công thức tính entropy tại một nút t là:

$$Entropy(t) = - \sum_{i=1}^C p_i \log_2(p_i) \quad PT\ 3.9$$

Khi cây quyết định chọn một đặc trưng để chia một nhóm lớn thành hai nhóm nhỏ hơn, nó sẽ tính toán lợi ích mà việc chia này mang lại. Lợi ích này được gọi là Information Gain (đối với entropy) hoặc Gini Gain (đối với chỉ số gini).

$$Information\ Gain = Impurity(t) - \sum_{k \in \{left, right\}} \frac{N_k}{N} Impurity(t_i) \quad PT\ 3.10$$

Trong đó:

- $Impurity(t)$ là độ thuần khiết tại nút cha.
- $Impurity(t_i)$ là độ không thuần khiết tại các nút con sau khi phân tách.
- N là số lượng mẫu nút cha, và N_k là số lượng mẫu tại nút con k .

RF tạo ra nhiều cây quyết định khác nhau thông qua hai cơ chế ngẫu nhiên chính:

- Bagging: Mỗi cây trong “rừng” không được huấn luyện trên toàn bộ dữ liệu. Thay vào đó, nó học từ một tập con ngẫu nhiên của dữ liệu gốc, với các mẫu có thể được chọn lặp lại. Điều này đảm bảo mỗi cây có một cái nhìn hơi khác về dữ liệu. Công thức tổng hợp dự đoán:
 - Phân loại: $\hat{y} = majority_vote(\hat{y}^{(1)}, \hat{y}^{(2)}, \dots, \hat{y}^{(B)})$
 - Hồi quy: $\hat{y} = \frac{1}{B} \sum_{b=1}^B \hat{y}^{(b)}$

Trong đó:

- $\hat{y}^{(b)}$ là dự đoán của cây quyết định thứ b cho mẫu x .

- B là tổng số cây.
- Ngẫu nhiên hóa đặc trưng: Khi một cây cần tìm cách chia dữ liệu, tại một nút, nó không xem xét tất cả các đặc trưng có sẵn. Thay vào đó, nó chỉ chọn một tập con ngẫu nhiên của các đặc trưng để tìm ra điểm chia tốt nhất. Điều này khiến mỗi cây trở nên độc đáo và ít phụ thuộc vào một vài đặc trưng mạnh mẽ nhất.

RF có thể cho biết đặc trưng nào là quan trọng nhất trong việc đưa ra dự đoán. Nó làm điều này bằng cách theo dõi xem mỗi đặc trưng đã giúp giảm độ “bẩn” của các nút trong cây đến mức nào. Công thức ước tính mức độ quan trọng của đặc trưng X_j :

$$Feature\ Importance(X_j) = \frac{1}{B} \sum_{b=1}^B \sum_{t \in nodes} \Delta I(t) \quad PT\ 3.11$$

Một ưu điểm tiện lợi của RF là khả năng tự đánh giá hiệu suất mà không cần một tập dữ liệu kiểm tra riêng biệt. Khoảng một phần ba dữ liệu ban đầu sẽ không được sử dụng để huấn luyện một cây cụ thể. Những mẫu “không được sử dụng” này được gọi là Out-of-Bag (OOB) samples.

- Cách tính OOB Error: Mô hình sẽ sử dụng các OOB samples này để kiểm tra cây mà chúng không được huấn luyện. Sau đó, nó tổng hợp các lỗi dự đoán từ tất cả các cây trên các mẫu OOB của chúng.

$$OOB\ Error = \frac{1}{N} \sum_{i=1}^N I(\hat{y}_{OOB}(i) \neq y_i) \quad PT\ 3.12$$

- Ý nghĩa: OOB Error là một ước lượng đáng tin cậy về hiệu suất tổng quát hóa của mô hình trên dữ liệu mới, giúp xác định mô hình hoạt động tốt đến đâu mà không cần tốn công chia dữ liệu thành tập huấn luyện/kiểm tra riêng biệt.

3.2.3.2. Thuật toán

Chi tiết thuật toán RF theo từng bước:

Bước 1: Chọn số lượng cây (N_{trees})

- Xác định số lượng cây quyết định sẽ được xây dựng trong rừng.
- Con số này thường là lớn (ví dụ: 100, 200, 500).

Bước 2: Xây dựng từng cây (Lặp lại cho mỗi cây)

- Lấy mẫu ngẫu nhiên: Mỗi cây được huấn luyện trên một tập con dữ liệu được lấy ngẫu nhiên có lặp lại từ tập dữ liệu gốc. Điều này giúp mỗi cây nhìn nhận dữ liệu một cách khác biệt.
- Chia ngẫu nhiên: Tại mỗi điểm chia trong cây, thuật toán chỉ xem xét một tập con ngẫu nhiên của các đặc trưng. Nó chọn đặc trưng và ngưỡng chia tốt nhất để làm cho các nhóm dữ liệu con “sạch” nhất có thể.
- Xây cây sâu: Mỗi cây thường được xây dựng rất sâu mà không cần cắt tỉa.

Bước 3: Dự đoán

- Để dự đoán một mẫu mới, mô hình đưa mẫu đó qua tất cả các cây trong rừng.
- Phân loại: Mỗi cây sẽ “bỏ phiếu” cho một lớp, và lớp nào có nhiều phiếu nhất sẽ là dự đoán cuối cùng.
- Hồi quy: Giá trị dự đoán cuối cùng là giá trị trung bình từ dự đoán của tất cả các cây.

3.2.3.3. Ví dụ đơn giản

Ví dụ muốn dự đoán liệu một khách hàng có mua sản phẩm hay không dựa trên các đặc trưng như: tuổi, thu nhập, số lần truy cập website. Có một tập dữ liệu nhỏ đã được gán nhãn từ trước:

Bảng 3.2 Ví dụ thuật toán Random Forest.

Tuổi	Thu nhập (triệu VND)	Số lần truy cập Web	Mua sản phẩm?
25	50	10	Có
35	80	5	Có
45	60	2	Không
30	70	8	Có
50	40	3	Không
28	55	12	Có

Bây giờ một khách hàng mới đến với Tuổi = 40, Thu nhập = 75 triệu VND, Truy cập = 6 lần. Muốn RF dự đoán liệu họ có mua sản phẩm hay không.

Bước 1: Xây dựng các cây quyết định độc lập

Giả sử RF cần xây dựng 3 cây quyết định.

- Cây 1 (C1):
 - Lấy mẫu ngẫu nhiên: C1 được huấn luyện trên một tập con dữ liệu như: (25, 50, 10, Có), (45, 60, 2, Không), (30, 70, 8, Có), (28, 55, 12, Có).
 - Ngẫu nhiên hóa đặc trưng: Tại mỗi nút, C1 chỉ có thể chọn ngẫu nhiên 1 hoặc 2 đặc trưng để tìm điểm chia tốt nhất.
 - Quy tắc C1 có thể học:
 - Nếu Thu nhập > 65 triệu VND → Có.
 - Nếu Thu nhập ≤ 65 triệu VND và Tuổi > 40 → Không.
 - Nếu Thu nhập ≤ 65 triệu VND và Tuổi ≤ 40 → Có.
- Cây 2 (C2):
 - Lấy mẫu ngẫu nhiên: C2 có thể được huấn luyện trên: (35, 80, 5, Có), (50, 40, 3, Không), (25, 50, 10, Có).
 - Ngẫu nhiên hóa đặc trưng: Tương tự, C2 cũng chỉ xem xét một tập con đặc trưng tại mỗi nút.
 - Quy tắc C2 có thể học:
 - Nếu Tuổi < 30 → Có.
 - Nếu Tuổi ≥ 30 và Truy cập Website ≤ 4 → Không.

- Nếu Tuổi ≥ 30 và Truy cập Website $> 4 \rightarrow$ Có.
- Cây 3 (C3):
 - Lấy mẫu ngẫu nhiên: C3 có thể được huấn luyện trên: (30, 70, 8, Có), (45, 60, 2, Không), (28, 55, 12, Có), (50, 40, 3, Không).
 - Ngẫu nhiên hóa đặc trưng: C3 cũng chỉ xem xét một tập con đặc trưng tại mỗi nút.
 - Quy tắc C3 có thể học:
 - Nếu Truy cập Website $> 7 \rightarrow$ Có.
 - Nếu Truy cập Website $\leq 7 \rightarrow$ Không.

Bước 2: Dự đoán cho khách hàng mới (Tuổi = 40, Thu nhập = 75, Truy cập = 6)

Đưa thông tin khách hàng mới này qua từng cây:

1. Cây 1 (C1) dự đoán:
 - Thu nhập = 75 triệu VND (> 65 triệu VND) $\rightarrow$ C1 dự đoán: Có
2. Cây 2 (C2) dự đoán:
 - Tuổi = 40 (≥ 30 tuổi)
 - Truy cập Web = 6 (> 4 lần) $\rightarrow$ C2 dự đoán: Có
3. Cây 3 (C3) dự đoán:
 - Truy cập Web = 6 (< 7 lần) $\rightarrow$ C3 dự đoán: Không

Bước 3: Tổng hợp kết quả (Bỏ phiếu đa số)

- C1: Có
- C2: Có
- C3: Không

Kết quả bỏ phiếu: 2 phiếu Có, 1 phiếu Không.

Vậy RF sẽ dự đoán rằng khách hàng mới này có khả năng mua sản phẩm.

3.2.3.4. Ưu và nhược điểm

Ưu điểm:

- Xử lý dữ liệu lớn và phức tạp: RF xử lý rất tốt các tập dữ liệu lớn, ngay cả khi chúng có nhiều hoặc không được phân bố đều. Nó cũng hoạt động hiệu quả với dữ liệu có nhiều đặc trưng.
- Chống quá khớp (overfitting) hiệu quả: Đây là một lợi thế lớn. Bằng cách kết hợp nhiều cây quyết định, mỗi cây được huấn luyện trên một phần dữ liệu và đặc trưng ngẫu nhiên, RF giúp giảm đáng kể khả năng mô hình học vẹt dữ liệu huấn luyện mà không tổng quát hóa tốt cho dữ liệu mới.
- Chịu được dữ liệu thiếu: RF có thể đưa ra dự đoán khá tốt ngay cả khi một phần dữ liệu bị thiếu. Vì mỗi cây chỉ sử dụng một tập con dữ liệu và đặc trưng, việc thiếu hụt ở một vài điểm không ảnh hưởng đến toàn bộ "rừng".
- Linh hoạt và dễ mở rộng: Có thể dễ dàng điều chỉnh số lượng cây để cân bằng giữa độ chính xác và tốc độ. Thuật toán này cũng có thể

được áp dụng linh hoạt cho nhiều loại bài toán, từ phân loại nhị phân, đa lớp cho đến hồi quy.

Nhược điểm:

- **Tốn kém tài nguyên tính toán:** Do phải xây dựng và quản lý hàng trăm (hoặc thậm chí hàng nghìn) cây quyết định, RF đòi hỏi nhiều CPU và RAM hơn so với các thuật toán đơn giản khác.
- **Khó tinh chỉnh tham số:** Việc tìm ra các giá trị tối ưu cho các "công tắc điều khiển" của Random Forest (như số cây, độ sâu tối đa của cây, số lượng đặc trưng để chọn) có thể khá phức tạp và tốn thời gian. Thường phải thử nghiệm nhiều lần để tìm ra cấu hình tốt nhất.
- **Kích thước mô hình lớn:** Một rừng với nhiều cây có thể tạo ra một mô hình rất lớn, chiếm nhiều không gian bộ nhớ. Điều này có thể là một vấn đề trong các môi trường có tài nguyên hạn chế.

3.2.3.5. Ứng dụng trong nghiên cứu

Sau khi có tập dữ liệu với các đặc trưng và nhãn, có thể bắt đầu huấn luyện mô hình RF.

- **Chia tập dữ liệu:** Chia tập dữ liệu thành tập huấn luyện và tập kiểm tra.
- **Khởi tạo mô hình RF** với các siêu tham số như số lượng cây, số lượng đặc trưng xem xét tại mỗi nút.
- **Sử dụng cross-validation** trên tập huấn luyện để đánh giá độ ổn định của mô hình.
- **Sử dụng các thuật toán** để tìm ra bộ siêu tham số tối ưu, nhằm tối đa hóa hiệu suất phân loại.

3.3 Đánh giá hiệu suất mô hình

Đánh giá hiệu suất mô hình là một bước cực kỳ quan trọng trong quy trình học máy, giúp chúng ta hiểu được mô hình hoạt động tốt đến mức nào và liệu nó có thể được sử dụng để đưa ra dự đoán đáng tin cậy hay không. Để đánh giá hiệu suất, chúng ta thường sử dụng một tập hợp các chỉ số đánh giá phù hợp với loại bài toán đang giải quyết.

Dưới đây là các phương pháp và chỉ số phổ biến được sử dụng để đánh giá hiệu suất mô hình.

3.3.1 Phân chia dữ liệu

Trước khi đánh giá, dữ liệu thường được chia thành ít nhất hai tập:

- **Tập huấn luyện:** Dùng để huấn luyện mô hình, tức là để mô hình học các mẫu và mối quan hệ từ dữ liệu.
- **Tập kiểm tra:** Dùng để đánh giá hiệu suất của mô hình trên dữ liệu mà nó chưa từng học trước đây. Điều này giúp ước tính khả năng tổng quát hóa của mô hình.

Ngoài ra, đôi khi còn có tập xác thực được sử dụng trong quá trình điều chỉnh siêu tham số để tránh việc lựa chọn siêu tham số dựa trên tập kiểm tra, dẫn đến kết quả đánh giá không thực tế.

3.3.2 Các chỉ số đánh giá cho bài toán phân loại

Trong các bài toán phân loại, chúng ta thường sử dụng các chỉ số dựa trên ma trận nhầm lẫn (Confusion Matrix). Ma trận này cung cấp cái nhìn chi tiết về số lượng dự đoán đúng và sai của mô hình.

Một ma trận nhầm lẫn cơ bản cho bài toán phân loại nhị phân bao gồm:

- True Positive (TP): Số lượng mẫu thực tế là tích cực và được dự đoán là tích cực.
- True Negative (TN): Số lượng mẫu thực tế là tiêu cực và được dự đoán là tiêu cực.
- False Positive (FP): Số lượng mẫu thực tế là tiêu cực nhưng được dự đoán là tích cực (lỗi loại I).
- False Negative (FN): Số lượng mẫu thực tế là tích cực nhưng được dự đoán là tiêu cực (lỗi loại II).

Từ ma trận nhầm lẫn, chúng ta có thể tính toán các chỉ số sau:

- Độ chính xác (Accuracy): Tỷ lệ tổng số dự đoán đúng trên tổng số mẫu.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad PT\ 3.13$$

Đây là chỉ số phổ biến nhất nhưng có thể gây nhầm lẫn trong các tập dữ liệu mất cân bằng lớp.

- Độ chuẩn xác (Precision): Tỷ lệ số lượng mẫu tích cực được dự đoán đúng trên tổng số mẫu được dự đoán là tích cực.

$$Precision = \frac{TP}{TP + FP} \quad PT\ 3.14$$

Chỉ số này quan trọng khi chi phí của lỗi FP là cao.

- Độ thu hồi (Recall) / Độ nhạy (Sensitivity): Tỷ lệ số lượng mẫu tích cực được dự đoán đúng trên tổng số mẫu thực tế là tích cực.

$$Recall = \frac{TP}{TP + FN} \quad PT\ 3.15$$

Chỉ số này quan trọng khi chi phí của lỗi FN là cao.

- Điểm F1-Score: Là trung bình điều hòa của Precision và Recall, cung cấp sự cân bằng giữa hai chỉ số này. Rất hữu ích khi có sự mất cân bằng giữa Precision và Recall.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad PT\ 3.16$$

- Đường cong ROC (Receiver Operating Characteristic) và Diện tích dưới đường cong ROC (AUC – Area Under the Curve): Đường cong

ROC là đồ thị biểu diễn mối quan hệ giữa Tỷ lệ True Positive (TPR – Recall) và Tỷ lệ False Positive (FPR) ở các ngưỡng phân loại khác nhau. AUC là diện tích dưới đường cong ROC, giá trị càng gần 1 thì mô hình càng tốt trong việc phân loại các lớp.

3.3.3 Các chỉ số đánh giá cho bài toán hồi quy

Trong các bài toán hồi quy, mục tiêu là dự đoán một giá trị liên tục. Các chỉ số đánh giá thường tập trung vào sự khác biệt giữa giá trị dự đoán và giá trị thực tế.

- Sai số tuyệt đối trung bình (MAE – Mean Absolute Error): Là trung bình của giá trị tuyệt đối của các sai số.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad PT\ 3.17$$

- Sai số bình phương trung bình (MSE – Mean Squared Error): Là trung bình của bình phương các sai số.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad PT\ 3.18$$

MSE nhạy cảm với các lỗi lớn vì nó bình phương các sai số.

- Căn bậc hai của sai số bình phương trung bình (RMSE – Root Mean Squared Error): Là căn bậc hai của MSE, đưa MSE về cùng đơn vị với biến mục tiêu.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad PT\ 3.19$$

- Hệ số xác định (R-squared hoặc R^2): Biểu thị tỷ lệ phương sai trong biến phụ thuộc có thể được giải thích bởi các biến độc lập trong mô hình. Giá trị R^2 nằm trong khoảng từ 0 đến 1, giá trị càng gần 1 cho thấy mô hình giải thích được càng nhiều sự biến động của dữ liệu.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad PT\ 3.20$$

Trong đó y_i là giá trị thực tế, $\hat{y}_i$ là giá trị dự đoán và $\bar{y}$ là giá trị trung bình của y .

3.3.4 Phương pháp kiểm định chéo (Cross-validation)

Để có được một ước lượng đáng tin cậy hơn về hiệu suất mô hình và giảm thiểu sự phụ thuộc vào cách chia dữ liệu cụ thể, kiểm định chéo (Cross-validation) thường được sử dụng. Phương pháp phổ biến nhất là K-Fold Cross-validation:

- Dữ liệu được chia thành K phần (folds) có kích thước bằng nhau.

2. Mô hình được huấn luyện K lần. Trong mỗi lần, một fold được sử dụng làm tập kiểm tra, và K-1 folds còn lại được sử dụng làm tập huấn luyện.
3. Hiệu suất của mô hình được tính toán dựa trên mỗi tập kiểm tra.
4. Kết quả cuối cùng là trung bình của các chỉ số hiệu suất từ K lần lặp.

Kiểm định chéo giúp đánh giá sự ổn định của mô hình và cung cấp một ước lượng hiệu suất tổng quát hóa tốt hơn.

3.4 Kết luận chương

Chương 3 đã cung cấp cái nhìn tổng quan về học máy, giới thiệu ba mô hình chính: KNN, SVM, và RF. KNN đơn giản dựa trên “hàng xóm gần nhất”, SVM hiệu quả trong việc tìm kiếm siêu phẳng phân tách, còn RF kết hợp nhiều cây quyết định để tăng độ chính xác và giảm quá khớp.

Bên cạnh đó, chương này cũng nhấn mạnh tầm quan trọng của việc đánh giá hiệu suất mô hình. Chúng ta đã xem xét các chỉ số đánh giá cho bài toán phân loại (như Accuracy, Precision, Recall, F1-Score) và hồi quy (MAE, MSE, RMSE, R-squared), cùng với kỹ thuật kiểm định chéo (Cross-validation).

Tóm lại, việc hiểu rõ các mô hình và cách đánh giá hiệu suất của chúng là nền tảng cốt lõi để xây dựng các hệ thống học máy hiệu quả và đáng tin cậy.

CHƯƠNG 4. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG


Trong chương này, đề án trình bày chi tiết quá trình thiết kế và triển khai hệ thống dự đoán sớm cơn buồn ngủ theo thời gian thực từ tín hiệu PPG. Hệ thống được xây dựng gồm ba thành phần chính: phần cứng thu thập tín hiệu sinh lý, phần mềm xử lý tín hiệu và trích xuất đặc trưng, và mô hình học máy thực hiện dự đoán trạng thái của người lái xe.

4.1 Phần cứng sử dụng

Hệ thống dự đoán sớm cơn buồn ngủ theo thời gian thực từ tín hiệu PPG được xây dựng dựa trên mô hình thu thập tín hiệu từ cảm biến sinh lý học, xử lý dữ liệu trên máy tính và hiển thị kết quả. Do đó, phần cứng được lựa chọn phải đảm bảo các tiêu chí: chi phí thấp, nhỏ gọn, dễ triển khai, phù hợp với thời gian thực và có khả năng mở rộng tích hợp.

4.1.1 Cảm biến MAX30102

MAX30102 là cảm biến tích hợp LED đỏ, LED hồng ngoại, photodiode và bộ khuếch đại, được thiết kế để đo nhịp tim và SpO_2 không xâm lấn. Đây là cảm biến phổ biến trong các thiết bị wearable (đeo tay) như đồng hồ thông minh, vòng tay sức khỏe.



Hình 4.1 Module MAX30102.

Thông số kỹ thuật chính:

- Hai LED: Red (660 nm), IR (880 nm).
- Giao tiếp: I2C.
- Tốc độ mẫu có thể điều chỉnh (10 – 1000 Hz).
- Bộ lọc nhiễu tích hợp, khuếch đại lập trình được.
- Điện áp hoạt động thấp (~1.8V logic, 3.3V VCC).

Ưu điểm:

- Nhỏ gọn, tiêu thụ năng lượng thấp.
- Cho tín hiệu rõ ràng, ít nhiễu trong điều kiện bình thường.
- Dễ dàng tích hợp với ESP32 qua I2C.

Vai trò trong hệ thống:

- Đo tín hiệu phản xạ quang học của dòng máu dưới da (PPG).
- Truyền tín hiệu đã xử lý sơ bộ đến ESP32.

4.1.2 Vi điều khiển ESP32


ESP32 là một dòng vi điều khiển hiệu năng cao của Espressif Systems, được tích hợp WiFi, Bluetooth và nhiều ngoại vi giao tiếp (UART, I2C, SPI...). Trong đề tài này, ESP32 đảm nhận vai trò thu thập dữ liệu từ cảm biến PPG và truyền về máy tính qua cổng UART.

Thông số nổi bật của ESP32:

- CPU Xtensa LX6 dual-core, tốc độ đến 240 MHz.
- RAM: 520 KB SRAM.
- Giao tiếp: UART, SPI, I2C, PWM, ADC, DAC,...
- Hỗ trợ WiFi và Bluetooth (dự phòng cho các hướng phát triển mở rộng).
- Tương thích với nhiều công cụ phát triển như Arduino IDE, PlatformIO, ESP-IDF.

Vai trò trong hệ thống:

- Giao tiếp với cảm biến MAX30102 thông qua giao thức I2C.
- Đọc tín hiệu PPG (hồng ngoại hoặc LED đỏ) với tốc độ cao.
- Truyền dữ liệu dạng chuỗi số về máy tính qua UART để xử lý thời gian thực.



Hình 4.2 Vi điều khiển ESP32.

4.1.3 Cáp USB – TTL / Cáp nạp ESP32

Được sử dụng để kết nối ESP32 với máy tính qua UART (thông qua chip USB-to-Serial như CP2102, CH340,...), đảm bảo:

- Truyền dữ liệu PPG theo thời gian thực đến Python.
- Nạp chương trình và debug phần mềm trong quá trình phát triển.

4.1.4 Máy tính xử lý dữ liệu

Máy tính có nhiệm vụ:


- Nhận dữ liệu từ ESP32 qua UART.
- Lưu trữ, xử lý tín hiệu, trích xuất đặc trưng, chạy mô hình học máy.
- Hiển thị kết quả lên màn hình người dùng theo thời gian thực.

Yêu cầu tối thiểu:

- CPU 2 nhân trở lên, RAM ≥ 4 GB.
- Hệ điều hành Windows/Linux.
- Cài đặt Python, các thư viện hỗ trợ và công cụ phát triển như VSCode, PlatformIO.

4.1.5 Kết nối phần cứng

- I2C: Dùng để kết nối MAX30102 với ESP32.
- UART: Dùng để truyền tín hiệu PPG từ ESP32 sang máy tính.
- Nguồn cấp: Hệ thống dùng nguồn USB 5V từ máy tính.



Hình 4.3 Sơ đồ kết nối phần cứng.

4.2 Phần mềm sử dụng

Trong quá trình thiết kế và xây dựng hệ thống nhận diện cơn buồn ngủ sớm theo thời gian thực từ tín hiệu PPG, đề tài sử dụng các công cụ phần mềm phục vụ cho hai giai đoạn chính: (1) thu thập tín hiệu PPG từ cảm biến thông qua vi điều khiển ESP32 và (2) xử lý tín hiệu, trích xuất đặc trưng và dự đoán trạng thái buồn ngủ trên máy tính sử dụng các mô hình học máy. Các công cụ và ngôn ngữ lập trình được lựa chọn theo tiêu chí miễn phí, mã nguồn mở, dễ sử dụng, có cộng đồng hỗ trợ rộng lớn và khả năng mở rộng trong tương lai.

4.2.1 PlatformIO – Môi trường phát triển cho ESP32

Đối với phần lập trình nhúng trên vi điều khiển ESP32, đề tài sử dụng PlatformIO tích hợp trong Visual Studio Code, thay vì Arduino IDE truyền thống. PlatformIO là một hệ sinh thái phát triển phần mềm nhúng hiện đại, hỗ trợ hơn 1000 board vi điều khiển, bao gồm cả ESP32 của Espressif.

Tính năng nổi bật của PlatformIO:

- Quản lý thư viện hiện đại, hỗ trợ cập nhật và theo dõi phiên bản.
- Biên dịch và nạp chương trình nhanh, ổn định hơn Arduino IDE.
- Tích hợp công cụ debug.
- Giao diện hiện đại, hỗ trợ quản lý project theo chuẩn công nghiệp.

Các thư viện chính sử dụng firmware ESP32:

- MAX3010x.h: Đọc dữ liệu nhịp tim (red/IR LED) từ cảm biến MAX30102.

- Wire.h: Hỗ trợ giao tiếp I2C giữa ESP32 và cảm biến MAX30102.

Ngôn ngữ sử dụng: C/C++.

Chức năng của firmware:

- Khởi tạo cảm biến, thiết lập tần số lấy mẫu và các thông số ADC.
- Đọc tín hiệu PPG liên tục từ cảm biến và xử lý sơ bộ.
- Truyền dữ liệu theo thời gian thực về máy tính thông qua UART.

4.2.2 Python – Xử lý tín hiệu và học máy

Trên máy tính, ngôn ngữ Python 3.x được sử dụng làm nền tảng chính để xử lý tín hiệu sinh lý, trích xuất đặc trưng và huấn luyện các mô hình học máy. Python nổi bật nhờ hệ sinh thái thư viện phong phú, dễ học, dễ triển khai nhanh và đặc biệt mạnh trong các bài toán khoa học dữ liệu, học máy và xử lý tín hiệu y sinh.

Các chức năng chính được triển khai bằng Python:

- Nhận dữ liệu từ ESP32 qua cổng serial.
- Lưu trữ dữ liệu thành file .csv để phân tích offline hoặc xử lý thời gian thực.
- Lọc tín hiệu, chuẩn hóa, cắt cửa sổ tín hiệu cố định theo thời gian.
- Trích xuất đặc trưng từ 4 miền: thời gian, tần số (Fourier), wavelet, phi tuyến.
- Huấn luyện mô hình học máy và đánh giá hiệu năng.
- Triển khai dự đoán thời gian thực.
- Hiển thị kết quả bằng giao diện đơn giản.


Các thư viện Python chính được sử dụng:

- numpy: xử lý mảng số liệu.
- pandas: quản lý và xử lý dữ liệu dạng bảng, lưu/trích xuất file CSV.
- scipy.signal: lọc tín hiệu, phát hiện đỉnh.
- pywt: biến đổi Wavelet rời rạc.
- scipy.stats: tính kurtosis.
- nolds: tính đặc trưng phi tuyến.
- sklearn: các mô hình học máy.
- matplotlib.pyplot: vẽ biểu đồ, ma trận nhầm lẫn,...
- serial: đọc tín hiệu qua cổng COM.
- dash: tạo giao diện người dùng.

4.3 Kiến trúc tổng thể của hệ thống

Hệ thống dự đoán sớm cơn buồn ngủ theo thời gian thực từ tín hiệu PPG được thiết kế với hai giai đoạn chính: giai đoạn huấn luyện mô hình (offline) và giai đoạn kiểm tra, dự đoán thời gian thực (online). Việc phân chia rõ ràng giúp tối ưu hiệu quả và độ chính xác của mô hình, đồng thời đảm bảo tính khả thi khi triển khai thực tế.

4.3.1 Giai đoạn huấn luyện mô hình



Hình 4.4 Kiến trúc giai đoạn huấn luyện.

Trong giai đoạn này, hệ thống thực hiện các bước sau:

- Thu thập dữ liệu PPG từ cảm biến MAX30102 gắn với ESP32 qua cổng Serial: Dữ liệu PPG sẽ được thu thập từ đối tượng thử nghiệm trong các trạng thái buồn ngủ khác nhau. Đồng thời, mức độ buồn ngủ sẽ được gán nhãn thủ công theo thang đo buồn ngủ của Karolinska để tạo ra tập dữ liệu huấn luyện có nhãn.
- Tiền xử lý tín hiệu: Loại bỏ thành phần DC, làm mượt, phát hiện đỉnh, chuẩn hóa, đảm bảo chất lượng tín hiệu.
- Phân đoạn tín hiệu: Tín hiệu PPG sẽ được chia thành các cửa sổ thời gian 60 giây để trích xuất đặc trưng. Việc phân đoạn này cần được đồng bộ với quá trình gán nhãn trạng thái buồn ngủ.
- Trích xuất đặc trưng từ tín hiệu PPG ở các miền:
 - Miền thời gian: BPM, MA, MPI,...
 - Biến đổi Fourier: FMA, TE, MPV,...
 - Biến đổi Wavelet: Kurtosis các hệ số D1, D2, D3, A4.
 - Đặc trưng phi tuyến: MI, FNN, LE,...
- Huấn luyện 4 mô hình học máy ứng với 4 miền: Các vector đặc trưng cùng với nhãn trạng thái buồn ngủ tương ứng sẽ được sử dụng để huấn luyện các mô hình học máy như KNN, SVM, và RF. Quá trình này bao

gồm việc phân chia dữ liệu thành tập huấn luyện và tập kiểm tra, điều chỉnh siêu tham số và đánh giá hiệu suất mô hình bằng các chỉ số phù hợp.

- Lưu trữ mô hình đã huấn luyện: Mô hình có hiệu suất tốt nhất sẽ được lưu lại và sử dụng trong giai đoạn kiểm tra.

4.3.2 Giai đoạn kiểm tra

Sau khi có mô hình học máy đã được huấn luyện, hệ thống hoạt động theo chu trình thời gian thực như sau:

- Cảm biến PPG liên tục gửi tín hiệu đến máy tính thông qua ESP32.
- Tín hiệu được xử lý nhanh: lọc, phân đoạn, trích xuất đặc trưng (tương tự như giai đoạn huấn luyện).
- Các đặc trưng mới được đưa vào mô hình học máy đã huấn luyện.
- Kết quả dự đoán trạng thái buồn ngủ được hiển thị ngay lập tức trên giao diện hoặc cảnh báo nếu phát hiện nguy cơ buồn ngủ cao.
- Hệ thống cũng hỗ trợ lưu dữ liệu liên tục để kiểm tra hoặc huấn luyện bổ sung.

Mỗi mô hình học máy ứng với mỗi đặc trưng được dự đoán và có bốn đầu ra riêng biệt:

- $pred_{time}$: Dự đoán từ đặc trưng miền thời gian.
- $pred_{wavelet}$: Dự đoán từ đặc trưng wavelet.
- $pred_{fourier}$: Dự đoán từ đặc trưng Fourier.
- $pred_{nonlinear}$: Dự đoán từ đặc trưng phi tuyến.

Tuy nhiên, các mô hình này có độ chính xác khác nhau, vì vậy để tăng độ tin cậy cho kết quả cuối cùng, hệ thống áp dụng phương pháp bỏ phiếu có trọng số (weight voting) theo công thức:

$$Weight_{sum} = pred_{time} \times acc_{time} + pred_{wavelet} \times acc_{wavelet} + pred_{nonlinear} \times acc_{nonlinear} + pred_{fourier} \times acc_{fourier}$$

Trong đó: $acc_i \in [0,1]$: là độ chính xác của mô hình i đã được xác định sau huấn luyện.

Ngưỡng quyết định:


$$Threshold = \frac{acc_{time} + acc_{wavelet} + acc_{nonlinear} + acc_{fourier}}{2}$$

Dự đoán cuối cùng:

$$final_{predict} = \begin{cases} 1, & \text{nếu } Weight_{sum} \geq Threshold \\ 0, & \text{nếu } Weight_{sum} < Threshold \end{cases}$$

Ưu điểm của phương pháp:

- Tăng cường độ tin cậy của dự đoán cuối bằng cách ưu tiên kết quả từ các mô hình có độ chính xác cao hơn.
- Kết hợp thông tin từ nhiều miền đặc trưng giúp tổng quát hóa tốt hơn.
- Ngưỡng mềm giúp linh hoạt trong điều chỉnh độ nhạy của hệ thống.



Hình 4.5 Kiến trúc giai đoạn kiểm tra.

4.4 Kết luận chương

Chương 4 đã đi sâu vào thiết kế và xây dựng hệ thống dự đoán buồn ngủ. Kiến trúc tổng thể của hai giai đoạn: huấn luyện mô hình và dự đoán thời gian thực đã được phác thảo. Các thành phần phần cứng cốt lõi như cảm biến MAX30102 và vi điều khiển ESP32 đã được mô tả chi tiết, cùng với phương thức kết nối phần cứng qua cổng Serial. Về phần mềm, chương giới thiệu PlatformIO cho lập trình ESP32 và Python cùng các thư viện chuyên dụng để xử lý tín hiệu, học máy và giao diện người dùng trên máy tính.

CHƯƠNG 5. THỰC NGHIỆM VÀ KẾT QUẢ

Chương này trình bày chi tiết quá trình thực hiện các thí nghiệm để kiểm chứng hiệu quả của hệ thống dự đoán trạng thái buồn ngủ. Các kết quả thu thập được từ việc xử lý tín hiệu, trích xuất đặc trưng, huấn luyện mô hình học máy và hiệu suất dự đoán sẽ được trình bày, phân tích và đánh giá một cách khách quan.

5.1 Thu thập dữ liệu thực nghiệm

Phần này mô tả cách thức dữ liệu được thu thập và các bước tiền xử lý đã áp dụng để chuẩn bị dữ liệu cho phân tích.

5.1.1 Thiết lập môi trường thử nghiệm

Môi trường thu thập dữ liệu được thiết lập trong điều kiện ánh sáng không quá mạnh, tương tự với môi trường trong khoang xe. Điều này giúp đảm bảo rằng ánh sáng từ môi trường không gây nhiễu đáng kể đến hoạt động của cảm biến, vốn phụ thuộc vào sự hấp thụ và phản xạ ánh sáng.

Người đo được yêu cầu hạn chế chuyển động trong suốt quá trình thu thập để giảm thiểu nhiễu chuyển động ảnh hưởng đến chất lượng tín hiệu PPG.

5.1.2 Đối tượng thử nghiệm

Dữ liệu được thu thập từ 10 tình nguyện viên, bao gồm 4 nam tuổi 22, 2 năm tuổi 21, 2 nữ tuổi 22, 1 nữ tuổi 25.

Tất cả các tình nguyện viên đều là người trưởng thành khỏe mạnh, không có tiền sử bệnh lý liên quan đến giấc ngủ hoặc các vấn đề tim mạch có thể ảnh hưởng đến tín hiệu PPG. Trước khi tham gia, các tình nguyện viên đã được thông báo đầy đủ về quy trình và đồng ý tham gia nghiên cứu.

5.1.3 Quy trình thu thập và gán nhãn dữ liệu


Dữ liệu PPG được thu thập trong khoảng thời gian đủ dài, với mỗi người tham gia thực hiện nhiều phiên đo tại các thời điểm khác nhau trong ngày.

Để tăng khả năng thu thập được dữ liệu ở trạng thái buồn ngủ, phần lớn các phiên đo được thực hiện sau bữa trưa và bữa tối. Đây là những thời điểm được ghi nhận có nguy cơ buồn ngủ cao do ảnh hưởng sinh lý từ quá trình tiêu hóa và giảm nhịp sinh học tự nhiên của cơ thể.

Trong suốt quá trình đo, trạng thái buồn ngủ của người tham gia được gán nhãn thủ công sử dụng thang đo KSS. Để hỗ trợ quá trình gán nhãn khách quan, người tham gia được theo dõi bởi một camera. Người giám sát sẽ dựa vào hình ảnh từ camera, kết hợp với các tiêu chí của thang KSS, để ý định kỳ gán nhãn mức độ buồn ngủ cho các đoạn dữ liệu. Việc gán nhãn này được thực hiện đồng bộ với quá trình thu thập tín hiệu PPG theo các khoảng thời gian nhất định.


5.1.4 Kết quả tiền xử lý dữ liệu

Tín hiệu PPG được thu thập từ cảm biến MAX30102




Hình 5.1 Tín hiệu PPG thô.

Tín hiệu PPG sau khi loại bỏ thành phần DC:



Hình 5.2 Tín hiệu PPG sau khi loại bỏ thành phần DC.

Tín hiệu sau khi đi qua bộ lọc thông thấp FIR đối xứng bậc 22:



Hình 5.3 Tín hiệu PPG sau khi đi qua bộ lọc FIR.

5.2 Kết quả trích xuất đặc trưng


Phần này phân tích sự thay đổi các đặc trưng đã trích xuất từ tín hiệu PPG theo các mức độ buồn ngủ khác nhau, cung cấp bằng chứng trực quan và định lượng về khả năng phân biệt trạng thái buồn ngủ của chúng và mối quan hệ nội tại giữa các đặc trưng.

5.2.1 Đặc trưng miền thời gian

Các đặc trưng miền thời gian cung cấp thông tin trực tiếp về nhịp đập và biên độ của tín hiệu PPG. Việc phân tích sự biến đổi của chúng theo thời gian, đồng thời so sánh với nhãn KSS, giúp làm rõ mối liên hệ giữa các thông số sinh lý cơ bản và trạng thái buồn ngủ.

Hình 5.4 minh họa sự thay đổi của các đặc trưng miền thời gian bao gồm BPM, MPI, SPI, MA, MRT theo thời gian. Trên đồ thị, các vùng được gán nhãn theo thang đo KSS tại thời điểm đó được đánh dấu rõ ràng. Có thể quan sát thấy xu hướng biến đổi của các đặc trưng này, phản ánh sự điều hòa của hệ thần kinh

tự chủ và sự thay đổi trong huyết động học, có mối tương quan với mức độ buồn ngủ được gán nhãn.




Hình 5.4 Sự thay đổi của các đặc trưng miền thời gian ứng với nhãn KSS.

5.2.2 Đặc trưng từ biến đổi Fourier

Phân tích từ biến đổi Fourier cho phép khám phá các đặc điểm trong miền tần số của tín hiệu PPG, đặc biệt là các thông số liên quan đến phổ biên độ và pha. Sự thay đổi của các đặc trưng này theo thời gian có thể tiết lộ các dấu hiệu quan trọng của trạng thái buồn ngủ.

Hình 5.5 trình bày sự biến đổi của các đặc trưng từ biến đổi Fourier theo thời gian, bao gồm FMA, MPP, SPP, MPV, SPV, và TE. Đồ thị này cũng tích hợp các nhãn KSS tương ứng, cho phép chúng ta nhận diện sự thay đổi của các thành phần phổ và tổng năng lượng khi người tham gia chuyển từ trạng thái tỉnh táo sang các mức độ buồn ngủ khác nhau, làm nổi bật mối liên hệ giữa các thành phần tần số của tín hiệu PPG và trạng thái ý thức.




Hình 5.5 Sự thay đổi của các đặc trưng từ biến đổi Fourier nhãn KSS.

5.2.3 Đặc trưng từ biến đổi Wavelet

Biến đổi Wavelet cho phép phân tích tín hiệu ở các độ phân giải khác nhau, giúp khám phá các thông tin ẩn mà biến đổi Fourier có thể bỏ lỡ. Cụ thể, việc sử dụng chỉ số Kurtosis từ các hệ số phân rã Wavelet cung cấp thông tin về độ nhọn của phân bố, có thể phản ánh sự thay đổi trong tính chất thống kê của tín hiệu PPG theo thời gian và mức độ buồn ngủ.


Hình 5.6 thể hiện sự thay đổi của chỉ số Kurtosis từ các hệ số phân rã Wavelet theo thời gian. Trên đồ thị, các vùng được gán nhãn theo thang đo KSS tại các thời điểm tương ứng được đánh dấu rõ ràng. Sự biến động của Kurtosis ở các mức phân rã này có thể chỉ ra sự thay đổi trong tính chất thống kê của tín hiệu PPG khi người tham gia chuyển đổi giữa các trạng thái tỉnh táo và buồn ngủ.



Hình 5.6 Sự thay đổi của Kurtosis từ các hệ số Wavelet ứng với nhãn KSS.

5.2.4 Đặc trưng phi tuyến

Các đặc trưng phi tuyến trong không gian pha cung cấp cái nhìn sâu sắc về động lực học phức tạp của tín hiệu sinh học, thường không thể hiện rõ qua các phân tích tuyến tính. Chúng có thể tiết lộ những thay đổi tinh tế trong hoạt động sinh lý khi buồn ngủ xuất hiện.



Hình 5.7 Sự thay đổi của các đặc trưng phi tuyến ứng với nhãn KSS.


Hình 5.7 trình bày sự thay đổi của các đặc trưng phi tuyến theo thời gian. Các vùng trên đồ thị được đánh dấu bằng nhãn KSS tại các thời điểm tương ứng, cho phép chúng ta quan sát sự biến đổi trong độ phức tạp, tính hỗn loạn và tự tương quan của tín hiệu PPG khi người tham gia trải qua các mức độ buồn ngủ khác nhau.

5.2.5 Đánh giá sự tương quan giữa các đặc trưng

Để hiểu rõ hơn mối quan hệ nội tại giữa các đặc trưng trong từng nhóm và đánh giá khả năng độc lập thông tin của chúng, một phân tích tương quan đã được thực hiện riêng biệt cho mỗi miền đặc trưng. Việc hiểu rõ mối quan hệ này là quan trọng để tránh đưa ra các đặc trưng có thông tin trùng lặp cao vào mô hình, có thể dẫn đến hiện tượng đa cộng tuyến và làm giảm hiệu quả dự đoán.

5.2.5.1. Phân tích tương quan nội tại của các đặc trưng miền thời gian


Hình 5.8 trình bày ma trận tương quan giữa các đặc trưng miền thời gian đã trích xuất. Phân tích này giúp xác định mức độ tương quan giữa các thông số cơ bản như BPM, MPI, SPI, MA và MRT.



Hình 5.8 Ma trận tương quan của các đặc trưng miền thời gian.

5.2.5.2. Phân tích tương quan nội tại của đặc trưng từ biến đổi Fourier


Hình 5.9 minh họa ma trận tương quan giữa các đặc trưng được trích xuất từ biến đổi Fourier. Ma trận này cho phép đánh giá mối liên hệ giữa các thông số phổ như FMA, MPP, SPP, MPV, SPV và TE.



Hình 5.9 Ma trận tương quan của các đặc trưng từ biến đổi Fourier.

5.2.5.3. Phân tích nội tại của các đặc trưng từ biến đổi Wavelet


Hình 5.10 thể hiện ma trận tương quan giữa các đặc trưng Kurtosis từ biến đổi Wavelet (KD1, KD2, KD3, KA4).



Hình 5.10 Ma trận tương quan của các đặc trưng từ biến đổi Wavelet.

5.2.5.4. Phân tích tương quan nội tại của các đặc trưng phi tuyến

Hình 5.11 trình bày ma trận tương quan giữa các đặc trưng phi tuyến như MI, FNN, LA, ARE, DFA.



Hình 5.11 Ma trận tương quan của các đặc trưng phi tuyến.

5.3 Kết quả huấn luyện và đánh giá mô hình học máy

Phần này tập trung vào hiệu suất của mô hình học máy đã được huấn luyện trên tập dữ liệu PPG đã được xử lý và trích xuất đặc trưng. Các kết quả sẽ được trình bày thông qua các chỉ số đánh giá tiêu chuẩn và phân tích trực quan, nhằm xác định mô hình tối ưu cho bài toán dự đoán buồn ngủ.

5.3.1 Thiết lập thử nghiệm huấn luyện

Quá trình huấn luyện và đánh giá mô hình được thực hiện một cách có hệ thống để đảm bảo tính khách quan và khả năng tổng quát hóa của kết quả.

- Phân chia dữ liệu: Để đánh giá độc lập hiệu suất của mô hình, toàn bộ dữ liệu đã được phân chia thành tập huấn luyện và tập kiểm tra (80/20). Phương pháp kiểm định chéo đã được áp dụng. Phương pháp này giúp đảm bảo rằng mỗi phần của dữ liệu đều được sử dụng cả trong quá trình huấn luyện và kiểm tra, giảm thiểu sai lệch do cách chia dữ liệu ngẫu nhiên và cung cấp một ước lượng hiệu suất tổng quát hơn của mô hình.
- Điều chỉnh siêu tham số: Đối với mỗi mô hình học máy, các siêu tham số quan trọng đã được điều chỉnh một cách cẩn thận để đạt được hiệu suất tối ưu.
 - Đối với KNN, giá trị K (số lượng hàng xóm gần nhất) đã được tối ưu hóa là $K = 20$.
 - Đối với SVM, các tham số như C (hệ số điều chuẩn) đã được chọn bằng 1 và loại kernel được chọn là RBF do phổ biến.
 - Đối với RF, số lượng cây quyết định được chọn là 100.

5.3.2 Kết quả đánh giá trên tập kiểm tra

Hiệu suất của các mô hình đã huấn luyện được đánh giá định lượng trên tập kiểm tra độc lập bằng nhiều chỉ số khác nhau.

5.3.2.1. Hiệu suất của thuật toán với từng miền đặc trưng

Để đánh giá chi tiết ảnh hưởng của các nhóm đặc trưng lên hiệu suất dự đoán, ba thuật toán phân loại chính (KNN, SVM, RF) đã được huấn luyện và đánh giá trên bốn tập đặc trưng riêng biệt: miền thời gian, biến đổi Fourier, Wavelet và phi tuyến. Bảng 5.1 đến Bảng 5.4 dưới đây trình bày tóm tắt hiệu suất đánh giá của mỗi thuật toán khi sử dụng từng nhóm đặc trưng. Các chỉ số được sử dụng bao gồm precision (độ chuẩn xác), recall (độ thu hồi), f1-score, được tính toán dưới dạng macro-average và weighted-average để phản ánh hiệu suất tổng thể qua các lớp buồn ngủ.

Bảng 5.1 Hiệu suất của các thuật toán với đặc trưng miền thời gian.

		precision	recall	f1-score	support
RF	0	0.95	0.97	0.96	9080
	1	0.95	0.92	0.93	5529
	macro avg	0.95	0.94	0.95	14609
	weighted avg	0.95	0.95	0.95	14609
SVM	0	0.85	0.88	0.87	9080
	1	0.79	0.74	0.77	5529
	macro avg	0.82	0.81	0.82	14609
	weighted avg	0.83	0.83	0.83	14609
KNN	0	0.80	0.86	0.83	9080
	1	0.74	0.65	0.69	5529
	macro avg	0.77	0.76	0.76	14609
	weighted avg	0.78	0.78	0.78	14609

Bảng 5.2 Hiệu suất của các thuật toán với đặc trưng từ biến đổi Fourier.

		precision	recall	f1-score	support
RF	0	0.85	0.90	0.88	9331
	1	0.82	0.74	0.78	5528
	macro avg	0.84	0.82	0.83	14859
	weighted avg	0.84	0.84	0.84	14859
SVM	0	0.82	0.88	0.85	9331
	1	0.76	0.68	0.72	5528
	macro avg	0.79	0.78	0.78	14859
	weighted avg	0.8	0.8	0.8	14859
KNN	0	0.81	0.85	0.83	9331
	1	0.72	0.65	0.69	5528
	macro avg	0.77	0.75	0.76	14859
	weighted avg	0.78	0.78	0.78	14859

Bảng 5.3 Hiệu suất của các thuật toán với đặc trưng từ biến đổi Wavelet.

		precision	recall	f1-score	support
RF	0	0.83	0.9	0.86	9209
	1	0.8	0.68	0.73	5400
	macro avg	0.82	0.79	0.8	14609
	weighted avg	0.82	0.82	0.82	14609
SVM	0	0.82	0.86	0.84	9209
	1	0.74	0.68	0.71	5400
	macro avg	0.78	0.77	0.78	14609
	weighted avg	0.79	0.8	0.79	14609
KNN	0	0.8	0.84	0.82	9209
	1	0.7	0.64	0.67	5400
	macro avg	0.75	0.74	0.74	14609
	weighted avg	0.76	0.76	0.76	14609

Bảng 5.4 Hiệu suất của các thuật toán với đặc trưng phi tuyến.

		precision	recall	f1-score	support
RF	0	0.88	0.93	0.91	9137
	1	0.88	0.79	0.83	5526
	macro avg	0.88	0.86	0.87	14663
	weighted avg	0.88	0.88	0.88	14663
SVM	0	0.81	0.88	0.85	9137
	1	0.77	0.66	0.71	5526
	macro avg	0.79	0.77	0.78	14663
	weighted avg	0.8	0.8	0.79	14663
KNN	0	0.8	0.85	0.82	9137
	1	0.72	0.65	0.68	5526
	macro avg	0.76	0.75	0.75	14663
	weighted avg	0.77	0.77	0.77	14663

5.3.2.2. Độ chính xác của các mô hình ứng với từng miền đặc trưng


Để cung cấp một cái nhìn trực quan rõ ràng về độ chính xác giữa các mô hình và các miền đặc trưng khác nhau, Hình 5.12 minh họa độ chính xác của KNN, SV và RF khi sử dụng các đặc trưng từ mỗi miền. Hình ảnh này giúp nhanh chóng nhận diện sự kết hợp giữa mô hình và miền đặc trưng nào mang lại độ chính xác cao nhất cho bài toán phát hiện buồn ngủ.




Hình 5.12 Độ chính xác của các mô hình theo từng miền đặc trưng.

5.3.2.3. Ma trận nhầm lẫn cho từng thuật toán và miền đặc trưng


Để hiểu rõ hơn về các loại lỗi phân loại và hành vi của từng mô hình khi sử dụng các tập đặc trưng khác nhau, các ma trận nhầm lẫn tương ứng đã được tạo ra. Hình 5.13 đến Hình 5.24 trình bày các ma trận nhầm lẫn cho mỗi thuật toán khi được huấn luyện với một miền đặc trưng cụ thể. Các ma trận này trực quan hóa số lượng các trường hợp được phân loại đúng và sai cho mỗi lớp buồn ngủ, làm nổi bật các trường hợp False Positive (dự đoán buồn ngủ nhưng thực tế tỉnh táo) và False Negative (dự đoán tỉnh táo nhưng thực tế buồn ngủ), đây là những yếu tố cực kì quan trọng trong các ứng dụng an toàn thực tế.




Hình 5.13 Ma trận nhầm lẫn của RF với đặc trưng miền thời gian.




Hình 5.14 Ma trận nhầm lẫn của SVM với đặc trưng miền thời gian.




Hình 5.15 Ma trận nhầm lẫn của KNN với đặc trưng miền thời gian.




Hình 5.16 Ma trận nhầm lẫn của RF với đặc trưng từ biến đổi Fourier.




Hình 5.17 Ma trận nhầm lẫn của SVM với đặc trưng từ biến đổi Fourier.




Hình 5.18 Ma trận nhầm lẫn của KNN với đặc trưng từ biến đổi Fourier.




Hình 5.19 Ma trận nhầm lẫn của RF với đặc trưng từ biến đổi Wavelet.




Hình 5.20 Ma trận nhầm lẫn của SVM với đặc trưng từ biến đổi Wavelet.




Hình 5.21 Ma trận nhầm lẫn của KNN với đặc trưng từ biến đổi Wavelet.



Hình 5.22 Ma trận nhầm lẫn của RF với đặc trưng phi tuyến.



Hình 5.23 Ma trận nhầm lẫn của SVM với đặc trưng phi tuyến.



Hình 5.24 Ma trận nhầm lẫn của KNN với đặc trưng phi tuyến.

5.3.2.4. Phân tích so sánh mô hình và miền đặc trưng

Dựa trên các bảng tổng hợp hiệu suất, đồ thị độ chính xác và ma trận nhầm lẫn, kết quả cho thấy thuật toán RF luôn đạt hiệu suất cao nhất trong số ba thuật toán được thử nghiệm trên tất cả các miền đặc trưng. Cụ thể, RF đạt độ chính xác cao nhất là 95% khi sử dụng đặc trưng miền thời gian, theo sau là đặc trưng phi tuyến (88%), Wavelet (82%), và Fourier (84%). Trong khi đó, các mô hình SVM đạt độ chính xác dao động xung quanh 80% đối với các miền đặc trưng, thể hiện sự ổn định nhưng không đột phá. Ngược lại, KNN cho thấy hiệu suất thấp nhất trong cả ba thuật toán trên tất cả các miền đặc trưng.

Sự vượt trội của RF có thể được giải thích bởi khả năng của nó trong việc xử lý các mối quan hệ phi tuyến phức tạp trong dữ liệu, cũng như khả năng tổng hợp thông tin từ nhiều cây quyết định, giúp giảm thiểu hiện tượng quá khớp và

tăng tính tổng quát hóa. Do hiệu suất vượt trội và sự phù hợp với yêu cầu về an toàn trong các ứng dụng thực tế, thuật toán Random Forest được lựa chọn để tích hợp vào hệ thống chính thức của đề án.

5.4 Kết luận chương

Chương 5 đã trình bày chi tiết quá trình thực nghiệm và phân tích kết quả dự đoán trạng thái buồn ngủ. Dữ liệu PPG được thu thập, tiền xử lý và trích xuất các đặc trưng đa miền (thời gian, Fourier, Wavelet, phi tuyến).

Các mô hình học máy (KNN, SVM, Random Forest) đã được huấn luyện và đánh giá kỹ lưỡng trên từng tập đặc trưng. Kết quả cho thấy thuật toán Random Forest đạt hiệu suất vượt trội nhất trên tất cả các miền, đặc biệt với đặc trưng miền Thời gian (độ chính xác 95%). SVM duy trì độ chính xác khoảng 80%, trong khi KNN cho hiệu suất thấp nhất.

Dựa trên hiệu suất cao và tính phù hợp với thực tế, Random Forest được chọn làm thuật toán chính cho hệ thống. Những kết quả này khẳng định tính khả thi và hiệu quả của phương pháp sử dụng tín hiệu PPG trong dự đoán buồn ngủ, mở ra hướng phát triển cho các ứng dụng thực tế.

CHƯƠNG 6. KẾT LUẬN

Chương này tổng kết những kết quả chính đã đạt được trong đồ án, đồng thời đề xuất các hướng nghiên cứu và phát triển tiềm năng trong tương lai nhằm nâng cao hơn nữa hiệu quả và tính ứng dụng.

6.1 Kết luận

Đồ án đã thành công trong việc nghiên cứu, thiết kế và xây dựng một hệ thống phát hiện trạng thái buồn ngủ theo thời gian thực dựa trên tín hiệu Photoplethysmography (PPG). Các mục tiêu đề ra ban đầu đã được hoàn thành:

- Về cơ sở lý thuyết và phương pháp: Đồ án đã nghiên cứu sâu về nguồn gốc sinh lý, đặc điểm, và các phương pháp xử lý tín hiệu PPG. Các thang đo mức độ buồn ngủ được tìm hiểu và áp dụng để gán nhãn dữ liệu thực nghiệm. Đồng thời, các phương pháp trích xuất đặc trưng đa miền và các mô hình học máy đã được nghiên cứu và áp dụng hiệu quả.
- Về thu thập và xử lý dữ liệu: Hệ thống đã được thiết kế và triển khai để thu thập tín hiệu PPG từ các tình nguyện viên trong môi trường có kiểm soát, mô phỏng điều kiện thực tế, đồng thời gán nhãn trạng thái buồn ngủ một cách đáng tin cậy bằng thang đo KSS có sự hỗ trợ của camera theo dõi. Dữ liệu thô đã được tiền xử lý kỹ lưỡng để loại bỏ nhiễu và chuẩn bị cho quá trình trích xuất đặc trưng.
- Về phân tích đặc trưng và huấn luyện mô hình: Các đặc trưng từ bốn miền khác nhau của tín hiệu PPG đã được trích xuất và phân tích chi tiết, cho thấy sự thay đổi rõ rệt của chúng theo mức độ buồn ngủ. Qua quá trình huấn luyện và đánh giá trên dữ liệu thực nghiệm, thuật toán Random Forest đã chứng minh hiệu suất vượt trội so với SVM và KNN. Sự lựa chọn RF cho hệ thống là hoàn toàn phù hợp với yêu cầu về độ chính xác và tính ổn định trong các ứng dụng an toàn.
- Về xây dựng hệ thống thời gian thực: Đồ án đã thành công trong việc tích hợp phần cứng và phần mềm để xây dựng một hệ thống có khả năng thu nhận, xử lý tín hiệu và đưa ra dự đoán về trạng thái buồn ngủ theo thời gian thực.

Những kết quả đạt được đã chứng minh tính khả thi và tiềm năng ứng dụng của hệ thống trong việc cảnh báo sớm buồn ngủ, góp phần nâng cao an toàn trong các hoạt động đòi hỏi sự tập trung cao như lái xe hoặc vận hành máy móc.

6.2 Hướng phát triển của đồ án trong tương lai

Để tiếp tục phát huy những kết quả đã đạt được và nâng cao hơn nữa hiệu quả cũng như tính ứng dụng của hệ thống dự đoán sớm trạng thái buồn ngủ, một số hướng nghiên cứu và phát triển tiềm năng trong tương lai có thể được đề xuất như sau:

- Mở rộng và đa dạng hóa tập dữ liệu:
 - Tiến hành thu thập dữ liệu từ một số lượng tình nguyện viên lớn hơn, với sự đa dạng về nhân khẩu học (độ tuổi, giới tính, vùng miền) và tình trạng sức khỏe tổng quát. Điều này sẽ giúp tăng cường tính khái quát hóa và độ bền vững của mô hình đối với các cá thể khác nhau.
 - Thực hiện các phiên đo trong nhiều điều kiện môi trường thực tế khác nhau, bao gồm môi trường có biến động về ánh sáng, nhiệt độ, rung động và tiếng ồn (ví dụ: trong môi trường lái xe thực tế), nhằm kiểm tra và cải thiện khả năng hoạt động của hệ thống trước các yếu tố nhiễu phức tạp.
 - Tích hợp việc thu thập dữ liệu với các phương pháp gán nhãn trạng thái buồn ngủ khách quan và chính xác hơn để làm giàu và chuẩn xác hóa dữ liệu huấn luyện, từ đó nâng cao độ tin cậy của nhãn.
- Tích hợp đa nguồn sinh lý:
 - Nghiên cứu và phát triển khả năng tích hợp tín hiệu PPG với các tín hiệu sinh lý khác như điện não đồ (EEG), điện tâm đồ (ECG), điện cơ (EMG), hoặc các thông số chuyển động mắt (EOG). Việc kết hợp dữ liệu từ nhiều cảm biến (multi-modal fusion) có thể cung cấp một bức tranh toàn diện hơn về trạng thái sinh lý của cá nhân, từ đó cải thiện đáng kể độ chính xác và độ tin cậy của hệ thống dự đoán buồn ngủ.
- Ứng dụng các thuật toán học sâu:
 - Khám phá tiềm năng của các kiến trúc mạng nơ-ron sâu tiên tiến, như Mạng nơ-ron tích chập (Convolutional Neural Networks - CNN) để tự động trích xuất đặc trưng từ tín hiệu PPG thô hoặc các biểu diễn thời gian-tần số (ví dụ: spectrogram, scalogram).
 - Nghiên cứu ứng dụng Mạng nơ-ron hồi quy (Recurrent Neural Networks - RNN, đặc biệt là Long Short-Term Memory - LSTM) để nắm bắt các phụ thuộc thời gian phức tạp trong tín hiệu, vốn là yếu tố quan trọng trong việc dự đoán trạng thái buồn ngủ diễn tiến. Học sâu có khả năng phát hiện các mẫu phức tạp và phi tuyến mà các phương pháp học máy truyền thống có thể bỏ lỡ.
- Phát triển hệ thống cảnh báo và phản hồi thông minh:
 - Thiết kế và tích hợp các cơ chế cảnh báo thông minh, đa dạng (ví dụ: cảnh báo âm thanh với cường độ tăng dần, rung, thay đổi màu sắc ánh sáng trong khoang lái) phù hợp với mức độ và tốc độ diễn tiến của trạng thái buồn ngủ.
 - Nghiên cứu các phương pháp phản hồi cá nhân hóa, có khả năng học hỏi và điều chỉnh chiến lược cảnh báo dựa trên thói quen, mức độ nhạy cảm và phản ứng của từng người dùng.
- Tối ưu hóa hệ thống nhúng và hiệu quả năng lượng:
 - Nghiên cứu các kỹ thuật nén mô hình và tối ưu hóa mã nguồn để cho phép triển khai mô hình học máy trực tiếp lên các nền tảng

phần cứng nhưng có tài nguyên hạn chế (ví dụ: vi điều khiển ESP32 với firmware được tối ưu hóa, hoặc các vi xử lý chuyên dụng cho AI). Điều này sẽ giảm sự phụ thuộc vào máy tính ngoại vi và tăng tính độc lập của thiết bị.

- Tối ưu hóa các thành phần phần cứng và phần mềm để giảm thiểu tiêu thụ năng lượng, đặc biệt quan trọng đối với các thiết bị đeo tay hoặc hệ thống hoạt động liên tục trên xe.
- Đánh giá trong môi trường thực tế và tích hợp ứng dụng cụ thể:
 - Tiến hành các thử nghiệm thực địa hoặc thử nghiệm lâm sàng quy mô lớn để đánh giá hiệu suất và độ tin cậy của hệ thống trong điều kiện sử dụng hàng ngày, đối mặt với các nhiễu phức tạp và hành vi người dùng đa dạng không kiểm soát.
 - Phát triển giao diện người dùng (UI) trực quan và thân thiện, tối ưu hóa cho các ứng dụng cụ thể như hệ thống hỗ trợ lái xe nâng cao (ADAS), thiết bị giám sát sức khỏe cho người làm việc ca đêm, hoặc thiết bị đeo tay theo dõi tình trạng tinh thần.

Những hướng phát triển này hứa hẹn sẽ không chỉ mở rộng khả năng của hệ thống hiện tại mà còn đưa công trình nghiên cứu này đến gần hơn với các ứng dụng thực tiễn, đóng góp vào việc nâng cao an toàn và chất lượng cuộc sống cho cộng đồng.

TÀI LIỆU THAM KHẢO

- [1] X. Zhang, X. Wang, X. Yang, C. Xu, X. Zhu, and J. Wei, "Driver drowsiness detection using mixed-effect ordered logit model considering time cumulative effect," *Accident Analysis & Prevention*, vol. 160, p. 106310, 2021.
- [2] Y. Saito, M. Itoh, and T. Inagaki, "Bringing a vehicle to a controlled stop: Effectiveness of a dual control scheme for identifying driver drowsiness and preventing lane departures under partial driving automation requiring hands-on-wheel," *IEEE Transactions on Human-Machine Systems*, vol. 51, pp. 450-461, 2021.
- [3] T. S. Delwar, M. Singh, S. Mukhopadhyay, A. Kumar, D. Parashar, Y. Lee, M. H. Rahman, M. A. S. Sejan, and J. Y. Ryu, "AI- and deep learning-powered driver drowsiness detection method using facial analysis," *Applied Sciences*, vol. 15, p. 1102, 2025.
- [4] F. Makhmudov, D. Turimov, M. Xamidov, F. Nazarov, and Y.-I. Cho, "Real-time fatigue detection algorithms using machine learning for yawning and eye state," *Sensors*, vol. 24, p. 7810, 2024.
- [5] Z. Ren, R. Li, B. Chen, H. Zhang, Y. Ma, C. Wang, Y. Lin, and Y. Zhang, "EEG-based driving fatigue detection using a two-level learning hierarchy radial basis function," *Frontiers in Neurorobotics*, vol. 15, p. 618408, 2021.
- [6] F. Wang, D. Chen, and X. Zhang, "Real-time driving fatigue detection of ECG signals acquired based on novel electrodes using wavelet scattering networks," *Measurement*, vol. 229, p. 116438, 2025.
- [7] Panicos A Kyriacou, John Allen, Photoplethysmography Technology, Signal Analysis and Applications, Academic Press Elsevier, 2019.
- [8] Holger Kantz and Thomas Schreiber, Nonlinear Time Series Analysis, Cambridge University Press, 2010.
- [9] M. E. Shaik, "A systematic review on detection and prediction of driver drowsiness," *Materials Today: Proceedings*, vol. 80, pp. 2126-2132, 2023.
- [10] N. Q. Trung, XỬ LÝ TÍN HIỆU và LỘC SỐ, Khoa học và Kỹ thuật, 2006.
- [11] D. Cvetkovic, E. D. Übeyli, and I. Cosic, "Wavelet transform feature extraction from human PPG, ECG, and EEG signal responses to ELF PEMF exposures: A pilot study," *Digital Signal Processing*, vol. 18, pp. 861-874, 2008.
- [12] A. M. Fraser and H. L. Swinney, "Independent coordinates for strange attractors from mutual information," *Physical Review A*, vol. 33, pp. 1134-1140, 1986.

- [13] A. ARORA, "ANALYTICS ARORA," 22 JULY 2022. [Online]. Available: <https://analyticsarora.com/8-unique-machine-learning-interview-questions-about-k-nearest-neighbors/>.
- [14] huytuong010101, "CODELEARN," 15 08 2020. [Online]. Available: <https://codelearn.io/sharing/thuat-toan-k-nearest-neighbors-knn>.
- [15] N. V. Otten, "SPOT INTELLIGENCE," 06 May 2024. [Online]. Available: <https://spotintelligence.com/2024/05/06/support-vector-machines-svm/>.
- [16] "Machine Learning cơ bản," 9 Apr 2017. [Online]. Available: <https://machinelearningcoban.com/2017/04/09/smv/>.
- [17] Aicandy, "Aicandy," [Online]. Available: <https://aicandy.vn/thuat-toan-random-forest-giai-thich-chi-tiet-va-ung-dung/>.
- [18] M. T. Rosenstein, J. J. Collins, and C. J. De Luca, "A practical method for calculating largest Lyapunov exponents from small data sets," *Physica D: Nonlinear Phenomena*, vol. 65, pp. 117-134, 1993.
- [19] C. K. Peng, S. Havlin, H. E. Stanley, and A. L. Goldberger, "Quantification of scaling exponents and crossover phenomena in nonstationary heartbeat time series," *Chaos*, vol. 5, pp. 82-87, 1995.
- [20] M. B. Kennel, R. Brown, and H. D. Abarbanel, "Determining embedding dimension for phase-space reconstruction using a geometrical construction," *Physical Review A*, vol. 45, pp. 3403-3411, 1992.

PHỤ LỤC

A1. So sánh kết quả với các nghiên cứu trước

Phần này trình bày sự so sánh hiệu suất của hệ thống dự đoán buồn ngủ được phát triển trong đề án này với các kết quả từ những nghiên cứu đã được công bố trước đây trong lĩnh vực tương tự. Mục tiêu của so sánh là nhằm xác định đóng góp của công trình nghiên cứu, đánh giá tính cạnh tranh và nhận diện những điểm mạnh, điểm yếu so với các phương pháp hiện hành.

Các tiêu chí so sánh bao gồm:

- Loại tín hiệu: Các tín hiệu được sử dụng để phân tích (ví dụ: tín hiệu sinh lý như PPG, EEG, ECG, ...; tín hiệu hành vi như góc vô lăng, độ lệch làn đường; tín hiệu hình ảnh từ camera như trạng thái mắt, khuôn mặt).
- Phương pháp trích xuất đặc trưng: Các phương pháp được áp dụng để chuyển đổi tín hiệu thô thành các đặc trưng có nghĩa.
- Thuật toán học máy/học sâu: Các mô hình phân loại được sử dụng.
- Độ chính xác: Chỉ số Accuracy – Độ chính xác được sử dụng để đánh giá hiệu quả phân loại của mô hình.
- Điều kiện thực nghiệm: Các yếu tố về bố cảnh nghiên cứu như số lượng đối tượng tham gia, môi trường thu thập dữ liệu và thang đo buồn ngủ được sử dụng.

Bảng 0.1 tóm tắt so sánh hiệu suất của hệ thống được đề xuất trong đề án này với một số nghiên cứu tiêu biểu khác, bao gồm cả phương pháp đơn lẻ và đa phương thức.

Dựa trên Bảng 0.1, có thể thấy kết quả của nghiên cứu này đã đạt được độ chính xác cạnh tranh cao (95% với Rando Forest và đặc trưng miền thời gian) khi so sánh với các hệ thống dựa trên một loại tín hiệu đơn lẻ khác (như ECG, EEG, hoặc một số phương pháp hành vi/hình ảnh) và thậm chí với một phương pháp học sâu. Điều này minh chứng cho hiệu quả của việc lựa chọn đặc trưng và thuật toán học máy được áp dụng trên tín hiệu PPG.

Bảng 0.1 So sánh hiệu suất dự đoán buồn ngủ với các nghiên cứu trước.

Nghiên cứu	Loại tín hiệu	Phương pháp	Thuật toán học máy/ học sâu	Độ chính xác	Điều kiện thực nghiệm
Nghiên cứu này	Thể tích quang phổ (PPG)	Đa miền (thời gian, biến đổi Fourier, biến đổi Wavelet, phân tích phi tuyến)	RF, KNN, SVM	Cao nhất là RF với đặc trưng miền thời gian (95%)	10 sinh viên tình nguyện, môi trường ít ánh sáng, hạn chế cử động.
X. Zhang et al. (2021)	Vị trí làn đường, chuyển động vô lăng và chuyển động mắt (PERCLOS).	Độ lệch chuẩn của vị trí làn đường ngang, PERCLOS.	MOL - TCE	62.84%	Mô phỏng lái xe thực tế ảo.
T. S. Delwar et al. (2025)	Hình ảnh/ video khuôn mặt (ngáp, mắt, đầu)	Haar cascade, Extract Face Landmarks, thời gian nhắm mắt, tần suất ngáp.	CNN, VGG16, MobileNet	MobileNet: 92.75%.	Bộ dữ liệu Kaggle Yawn Eye và Health Informatics.
F. Makhmudov et al. (2024)	Biểu cảm khuôn mặt	Haar cascade, Tỷ lệ Khía cạnh Mắt (EAR), hình dạng/chuyển động miệng.	CNN	96.54%	Bộ dữ liệu YawDD & MRL Eye.
Z. Ren et al. (2021)	Tín hiệu Điện não đồ (EEG)	Phân tích thành phần chính (PCA).	Mạng RBF phân cấp học hai cấp độ (RBF-TLLH)	92.71%	6 tình nguyện viên, mô phỏng lái xe (tỉnh táo/mệt mỏi)
F. Wang et al. (2025)	Tín hiệu điện tâm đồ (ECG)	Mạng tán xạ Wavelet, PCA.	Mạng tán xạ wavelet	97.93%	Thu thập ECG bằng điện cực từ lòng bàn tay.

A2. Giao diện người dùng hệ thống

Phần này mô tả giao diện người dùng (User Interface – UI) của hệ thống dự đoán trạng thái buồn ngủ theo thời gian thực. Giao diện được phát triển nhằm cung cấp một công cụ trực quan để theo dõi tín hiệu sinh lý, các đặc trưng được trích xuất và kết quả dự đoán buồn ngủ, hỗ trợ quá trình thử nghiệm và vận hành hệ thống.


A2.1 Công nghệ phát triển

Giao diện người dùng được xây dựng bằng Dash, một framework Python mã nguồn mở của Plotly. Dash cho phép xây dựng các ứng dụng web tương tác hoàn toàn bằng Python, không yêu cầu nhiều kiến thức về HTML, CSS hay JavaScript phức tạp. Điều này giúp tích hợp chặt chẽ với các module xử lý tín hiệu và học máy đã được phát triển bằng Python.

A2.2 Các thành phần chính của giao diện

Giao diện được thiết kế để hiển thị nhiều thông tin quan trọng, cập nhật theo thời gian thực vs chu kỳ 1 giây:

- Đồ thị tín hiệu PPG theo thời gian thực: Cho phép người dùng quan sát trực quan chất lượng và dạng sóng của tín hiệu đầu vào.
- Trạng thái cảm biến và dữ liệu: hiển thị dữ liệu đang được cập nhật hay không và đưa ra cảnh báo nếu không nhận được tín hiệu.
- Trạng thái dự đoán buồn ngủ: Hiển thị kết quả dự đoán cuối cùng của mô hình.
- Khi trạng thái buồn ngủ được phát hiện, hệ thống có khả năng tự động gửi cảnh báo thông qua dịch vụ Telegram, thông báo đến người quản lý hoặc người thân để có hành động kịp thời.
- Bảng kết quả dự đoán và các đặc trưng được trích xuất: cho phép xem lại các dự đoán gần nhất và các giá trị đặc trưng mới nhất được trích xuất từ mỗi miền.



Hình 0.1 Giao diện hiển thị tín hiệu PPG và trạng thái dự đoán.

Time Domain Features

BPM	AVG Interval (s)	STD Interval (s)	Amplitude	Time V2P (s)
84	0.7121744738386389	0.0447073792962151	825.6547619047619	0.590094480169825

Fourier Features

AVG Peak	STD Peak	AVG Trough	STD Trough	FMA	Total Power
2.402378242163224	0.5643576852672136	-2.138144462387675	0.692519962847249	1.3996961058269015	6409596891.000002


Wavelet Features

Kurtosis D1	Kurtosis D2	Kurtosis D3	Kurtosis A4
2.232211656923316	2.2084606985311304	0.065001910279113	-1.3320733723946565

Nonlinear Features

API	FNN	Lyapunov	ARE	DFA
0.5954628305021394	7.333102732618471	0.2117824044624537	163.59938090239743	0.5900011820488756

Hình 0.2 Giao diện hiển thị giá trị các đặc trưng.



Hình 0.3 Giao diện cảnh báo được gửi qua Telegram.

A2.3 Mã nguồn dự án

Link github: <https://github.com/DyHynek/FinalDATN.git>.

A.3 Kiểm tra thực nghiệm

Phần này trình bày kết quả thu được từ quá trình thực nghiệm dự đoán buồn ngủ trong trạng thái mô phỏng.

A3.1 Điều kiện thực nghiệm dự đoán

Quá trình dự đoán buồn ngủ theo thời gian thực được thực hiện trong môi trường mô phỏng nhằm tái tạo các điều kiện gần giống với thực tế nhất có thể, đồng thời kiểm soát được các yếu tố ảnh hưởng.

- Thiết bị sử dụng:
 - Cảm biến PPG: MAX30102 được kết nối với vi điều khiển ESP32 để thu thập tín hiệu PPG từ ngón tay.
 - Phần mềm: Môi trường phát triển Python được sử dụng để xử lý tín hiệu, trích xuất đặc trưng và chạy mô hình học máy. Ứng dụng giao diện người dùng được dùng để hiển thị kết quả theo thời gian thực.
 - Máy tính: Được sử dụng để chạy các thuật toán xử lý và giao diện người dùng.
 - Mô hình đã huấn luyện: Mô hình Random Forest đã được huấn luyện với các đặc trưng từ tín hiệu PPG, được lưu trữ và tải lên để dự đoán.
- Đối tượng thử nghiệm: Quá trình thử nghiệm được tiến hành với 2 người khỏe mạnh, độ tuổi 22, không có tiền sử bệnh lý về tim và giấc ngủ.
- Môi trường thử nghiệm: Thử nghiệm được tiến hành trong một phòng yên tĩnh, kiểm soát ánh sáng. Người tham gia được yêu cầu giữ trạng thái thoải mái, thư giãn và thực hiện một nhiệm vụ đơn điệu để khuyến khích sự xuất hiện tự nhiên của trạng thái buồn ngủ.
- Quy trình dự đoán:
 - Tín hiệu PPG được thu thập liên tục từ cảm biến.
 - Dữ liệu thô được truyền về máy tính, tiền xử lý và các đặc trưng miền thời gian được trích xuất trong các cửa sổ thời gian xác định.
 - Các đặc trưng này được đưa vào mô hình Random Forest đã huấn luyện.
 - Mô hình đưa ra dự đoán về trạng thái buồn ngủ (tỉnh táo/buồn ngủ) trong mỗi cửa sổ.
 - Kết quả dự đoán được hiển thị trên giao diện người dùng và đồng thời được ghi lại.
- Gán nhãn thực tế để đối chiếu: Trạng thái buồn ngủ thực tế của người tham gia được ghi nhận theo thang đo KSS (Karolinska Sleepiness Scale) để phục vụ cho việc đối chiếu và đánh giá độ chính xác của dự đoán theo thời gian thực.


A3.2 Kết quả thực nghiệm

Kết quả dự đoán được đánh giá dựa trên sự đối chiếu giữa kết quả dự đoán của mô hình và nhãn thực tế của trạng thái buồn ngủ. Các chỉ số được sử dụng để

đánh giá bao gồm Độ chính xác tổng thể (Overall Accuracy) và số lượng/tỷ lệ dự đoán đúng cho từng trạng thái: "Tỉnh táo" (Alert) và "Buồn ngủ" (Drowsy).

1. Ma trận nhầm lẫn trong thực nghiệm

Ma trận nhầm lẫn dưới đây Hình 0.4 thể hiện kết quả phân loại của mô hình Random Forest trên tập dữ liệu thực nghiệm, minh họa số lượng các trường hợp dự đoán đúng và sai cho từng trạng thái.



Hình 0.4 Ma trận nhầm lẫn kết quả dự đoán trong thực nghiệm.

2. Độ chính xác cho từng trạng thái và tổng thể

Từ ma trận nhầm lẫn trên, các chỉ số hiệu suất quan trọng được tính toán như sau:

- Độ chính xác cho trạng thái “Tỉnh táo”:
 - Số lần dự đoán đúng: 18 lần.
 - Độ chuẩn xác: $Precision = \frac{TP}{TP+FP} = \frac{18}{18+2} = \frac{18}{20} = 0.9 = 90\%$.
- Độ chính xác cho trạng thái “Buồn ngủ”:
 - Số lần dự đoán đúng: 16 lần.
 - Độ chuẩn xác: $Precision = \frac{TN}{TN+FN} = \frac{16}{16+4} = \frac{16}{20} = 0.8 = 80\%$.
- Độ chính xác tổng thể:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} = \frac{18 + 16}{18 + 2 + 16 + 4} = \frac{34}{40} = 0.85 = 85\%$$

Kết quả thực nghiệm cho thấy mô hình Random Forest hoạt động hiệu quả trong việc nhận diện cả hai trạng thái “Tỉnh táo” và “Buồn ngủ” dựa trên tín hiệu PPG.

- Độ chính xác 90% cho trạng thái "Tỉnh táo" và 80% cho trạng thái "Buồn ngủ" minh chứng cho khả năng đáng tin cậy của hệ thống trong việc phân biệt hai trạng thái này.
- Đặc biệt, việc dự đoán đúng trạng thái "Buồn ngủ" (16 lần TP) là rất quan trọng trong các ứng dụng an toàn, vì nó đảm bảo rằng hầu hết các trường hợp buồn ngủ nguy hiểm đều được phát hiện.

- Số lần dự đoán sai (False Negative = 2 trường hợp buồn ngủ bị dự đoán là tỉnh táo; False Positive = 4 trường hợp tỉnh táo bị dự đoán là buồn ngủ) là tương đối thấp, cho thấy mô hình có khả năng tổng quát hóa tốt trên dữ liệu thực nghiệm đã thu thập.
- Việc báo cáo chi tiết này cung cấp bằng chứng cụ thể về khả năng hoạt động của hệ thống trong một môi trường thực tế (mô phỏng) và là cơ sở để khẳng định tính khả thi của đề án.